

学校代码: 10286

分类号: TP391

密 级: 公开

U D C: 621.3

学 号: 198826



东南大学

博士学位论文

基于深度学习的双域 CT 重建方法研究

研究生姓名: 张谊坤

导师姓名: 陈 阳

申请学位类别 工学博士 学位授予单位 东南大学

一级学科名称 计算机科学与技术 论文答辩日期 2023年05月21日

二级学科名称 学位授予日期

答辩委员会主席 罗守华 评 阅 人 盲审

盲审

2023 年 06 月 10 日

東南大學

博士学位论文

基于深度学习的双域 CT 重建方法研究

专 业 名 称: 计算机科学与技术

研究生姓名: 张谊坤

导 师 姓 名: 陈阳 教授

DEEP LEARNING BASED DUAL-DOMAIN CT RECONSTRUCTION

A Dissertation Submitted to

Southeast University

For the Academic Degree of Doctor of Engineering

BY

Yikun Zhang

Supervised by

Prof. Yang Chen

School of Computer Science and Engineering

Southeast University

June 2023

摘要

X 射线计算机断层成像 (Computed Tomography, CT) 是一种应用广泛的成像技术, 能够无侵入地可视化物体内部的三维结构, 因具有扫描速度快和成像分辨率高的优点而成为临床核心影像模态之一, 广泛应用于疾病的筛查、诊断、分级和疗效评估, 在手术和放疗场景中还可以提供影像引导。然而, X 射线照射有一定几率诱发癌症或导致基因损伤, 降低 X 射线照射剂量可有效降低 CT 扫描的辐射风险。理论上, 可以通过低管电流扫描、稀疏角度扫描或有限角度扫描等方式来降低 X 射线照射剂量, 然而在上述非理想采样条件下获得的测量数据严重退化; 此外, 在手术和放疗等临床应用中, 不可避免地导致采集的测量数据是稀疏或者缺失的。上述情况下, 直接重建的断层图像中存在严重的噪声或伪影, 无法为后续的诊断和治疗程序提供精确的影像信息。如何在非理想采样条件下实现高质量的 CT 重建具有重要的研究意义和临床价值。

此外, 与普通 CT 相比, 双能 CT (Dual-Energy CT, DECT) 具有材料分辨的能力, 在临床上有其独特的优势和应用。然而, 当前 DECT 成像严重依赖于专用的成像系统, 比如美国通用电气的快速 kV 切换系统、德国西门子的双源系统、荷兰飞利浦的双层探测器系统, 更新 DECT 专用设备成本昂贵, 这阻碍了更多患者从 DECT 成像中受益。而且, 随着 DECT 在诊断放射领域获得广泛认可, 使用 DECT 技术来改进介入手术和放射治疗等应用的兴趣持续增长, 然而现有相关设备通常未集成双能成像功能。因此, 研究适用于现有设备的新型 DECT 成像方案临床意义显著。

本研究利用计算机学科前沿的深度学习技术, 结合成像模型, 针对具体临床场景需求设计相应的成像算法, 旨在实现非理想采样条件下的高质量 CT 重建, 为后续的诊断和治疗程序提供精确的影像信息。具体内容如下:

(1) 针对低剂量 CT 提出基于双域生成器网络的对抗学习重建算法。低管电流扫描会导致测量数据出现高强度的噪声, 而传统的在单一投影空间或图像空间处理的深度学习算法忽略了 CT 数据在投影空间和图像空间紧密关联的特性, 易导致二次伪影或结构失真。针对这一问题, 本研究提出基于双域生成器网络的低剂量 CT 对抗学习重建算法。与常规的建立在单一投影空间或图像空间的生成器不同, 双域生成器网络有助于超越空间的限制, 提取更加丰富的信息。采用的 3D 模型能够利用相邻帧之间的相关性来增强算法的细节恢复能力。设计的双空间损失函数可以在重建的不同阶段施加监督以鼓励网络的各个组件朝着高质量重建的方向更新。引入的对抗学习机制能够鼓励生成器输出在统计分布上和高质量 CT 图像更加相似的结果, 进而避免模糊效应。提出方法在模拟数据上的 MAE、PSNR 和 SSIM 指标分别为 15.38HU、40.10dB 和 97.71%, 在真实腹部体膜 1/6 常规剂量数据上的 MAE、PSNR 和 SSIM 指标分别为 14.15HU、37.85dB 和 95.25%。与竞争方法结果的对比分析表明, 提出方法在噪声抑制、微小结构恢复和视觉感受增强等方面更有潜力。

(2) 针对稀疏角度 CT 提出基于双域网络正则的深度迭代重建算法。对于 3D 血管成像等单个角度需要长时间曝光的应用, 稀疏角度扫描能够显著降低累积辐射并缩短扫描时间。为解决随之而来的测量数据稀疏的问题, 本研究考虑到投影补全在提高数据一

致性方面的潜力,提出了基于双域网络正则的稀疏角度 CT 深度迭代重建算法。与常规方法仅在图像空间进行约束不同,每次迭代中,提出方法使用投影补全、残差感知和图像增强三个模块同时在投影空间、残差空间和图像空间约束,以协同提高投影数据一致性、残差图像准确性和重建图像保真度。用于平衡不同项权重的超参数均隐藏到了深度神经网络中,不再需要显式地学习或经验调整。基础网络采用高效的轻量级 UNet 结构,有助于使用更少的迭代达到更优的性能,从而节省计算资源。提出方法在模拟人体 1/6 稀疏采样数据上的 MAE、PSNR 和 SSIM 指标分别为 12.07HU、42.07dB 和 98.49%,在真实小鼠 1/6 稀疏采样数据上的 MAE、PSNR 和 SSIM 指标分别为 9.28HU、37.31dB 和 95.63%。三种不同稀疏配置下的对比实验表明提出方法能够以渐进改进的方式逐步提高图像质量,在伪影移除和细节恢复方面的性能优于同类方法。

(3) 针对稀疏角度 DECT 提出基于互补扫描的双域优化重建算法。在诊断 DECT 中,快速 kV 切换系统高度依赖复杂的专用硬件,且存在电流调制困难的问题。鉴于此,本研究考虑到 DECT 不同能量通道数据之间的冗余性,提出基于慢速 kV 切换的互补稀疏扫描方案。该方案具有降低技术成本的潜力,且能够尽可能多地采集物体信息并降低 X 射线照射剂量。同时,开发了相应的稀疏角度 DECT 双域优化重建算法,协同数据空间缺失信息恢复和图像空间残留伪影移除以实现高质量重建。投影域子网络和图像域子网络均使用针对 DECT 成像设计的双流 ResUNet 网络,其共享编码器能够利用双能数据之间的互补信息提升重建精度,高低能编码器可以有效针对不同能量通道数据进行差别学习。提出方法在模拟腹部 1/8 稀疏采样的 DECT 数据上的 MAE、PSNR 和 SSIM 分别为 9.39HU、44.08dB 和 98.99%,且使用提出方法重建的 DECT 图像生成的 VNC 图像和碘材料图像的噪声水平更低,不同组织结构的边界也更加清晰。三种不同稀疏配置下的对比实验展现了提出方法在条纹伪影移除和结构保真等方面更有潜力的性能。

(4) 针对有限角度 DECT 提出基于双域先验增强的深度迭代重建算法。随着 DECT 在诊断放射领域被广泛接受,使用 DECT 技术来改进介入手术和放射治疗等应用的兴趣持续增长,然而相关设备通常未集成双能成像功能。鉴于这些场景中通常使用有限角度扫描采集数据,本研究提出基于双 1/4 圆周扫描的 DECT 互补采集方案,该方案能够满足在有限角度范围内采集双能数据的需求,且可以减少 X 射线辐射并缩短扫描时间。相应地,开发了基于双域先验增强的有限角度 DECT 深度迭代重建算法,该算法在传统先验约束迭代重建框架的基础上引入 DECT 先验信息同时在投影空间和图像空间增强,有望实现可解释的 DECT 并行重建。此外,采用的密集连接可以融合不同迭代时刻的信息,有效避免梯度消失并稳定模型性能。最后,将深度迭代重建网络作为生成器嵌入到对抗学习框架中,以增强生成的 DECT 图像的视觉效果。提出方法在模拟腹部数据上的 MAE、PSNR 和 SSIM 分别为 10.83HU、43.09dB 和 98.60%,在真实小鼠数据上的 MAE、PSNR 和 SSIM 分别为 10.15HU、37.74dB 和 96.89%。与竞争方法结果的对比分析表明提出方法在楔形伪影移除、HU 值校正和图像细节恢复等方面更有优势。

关键词: CT 成像,深度学习,双域处理,深度迭代重建,生成对抗网络,先验约束

Abstract

X-ray computed tomography (CT) is an advanced non-invasive imaging technique that enables three-dimensional visualization of the internal structure of the scanned object. Due to its fast scanning speed and high-resolution imaging, CT has become a primary medical imaging modality. It is widely used for disease screening, diagnosis, and efficacy assessment, as well as providing image guidance in scenarios such as interventional procedures and radiotherapy. However, radiation exposure in CT may lead to genetic damage and induce cancers in a probability. The well-known ALARA (as low as reasonably achievable) principle has been proposed to prevent radiation abuse. Theoretically, the radiation dose can be reduced by lowering the x-ray tube current, decreasing the measured views, or narrowing the scan range. However, the measured data acquired under the above non-ideal configurations are severely degraded. Moreover, some specific clinical applications inevitably result in the acquired measurement data being sparse or incomplete. In these cases, the directly reconstructed CT images suffer from severe noise and artifacts and thus cannot provide accurate image information for the follow-up diagnostic or therapeutic procedures. Achieving high-quality CT reconstruction under non-ideal scanning configurations is a hot topic of great scientific and clinical significance.

In addition, dual-energy CT (DECT) has advantages over conventional CT in identifying different materials, which makes it unique in clinical practice. However, current DECT imaging heavily relies on dedicated systems such as the dual-source scheme from Siemens in Germany, the fast kV switching scheme from General Electric in the US, and the dual-layer detector scheme from Philips in the Netherlands. Updating proprietary devices for DECT requires expensive hardware costs, hindering more patients from benefiting from DECT imaging. What's more, as DECT gains widespread acceptance in the diagnostic radiology community, the interest in applying DECT technology to improve applications such as interventional procedures and radiotherapy is also increasing. However, the related devices have not yet integrated the dual-energy imaging technique. Hence, developing new DECT imaging schemes compatible with existing devices is of great clinical significance.

In this context, this study utilizes the advanced deep learning technique in the field of computer science to design appropriate imaging algorithms for specific clinical applications, aiming to achieve high-quality CT reconstruction under non-ideal sampling configurations and provide accurate image information for subsequent diagnostic or therapeutic procedures. Details of this study are provided below.

(1) Dual-Domain Generator based Adversarial Reconstruction for Low-Dose CT. In clinical practice, the radiation dose is usually reduced by lowering the x-ray tube current, which will result in severe noise in the directly reconstructed images. Existing algorithms that work only in the projection domain or only in the image domain may lead to secondary artifacts or subtle structural distortions because they ignore the inherent correlation between the projection data and image data. To address this problem, this study proposes the dual-domain generator based adversarial reconstruction for low-dose CT. Different from

generators built in the data domain or image domain, the dual-domain generator network help to surpass the limitations of the data space and can extract richer information. The adopted 3D model can also exploit correlations between neighbouring slices to enhance the algorithm's performance in detail restoration. The designed dual-domain loss function can impose supervision at the different reconstruction stages to encourage all the generator components to be updated toward high-quality reconstruction. The introduced adversarial learning mechanism encourages the generator to produce results consistent with high-quality CT images regarding statistical distribution to avoid the blurring effect. Experimental results on simulated abdominal data and real phantom data have demonstrated the promising performance of the proposed method in terms of noise suppression, tiny structure restoration, and visual perception enhancement.

(2) Dual Deep Regularizers Enhanced Iterative Reconstruction for Sparse-View CT. For applications such as 3D angiography that require long exposure times per projection angle, sparse-view scanning can significantly reduce the accumulated radiation dose and acquisition time. To reconstruct high-quality images for sparse-view CT, this study takes into account the potential of projection inpainting in improving data consistency and proposes the dual deep regularizers enhanced iterative reconstruction algorithm. Different from the conventional unrolled iterative reconstruction algorithms that only perform constraints in the image domain, the proposed method imposes constraints in the projection domain, residual domain, and image domain through three cascaded modules (i.e., projection inpainting, residual awareness, and image enhancement), improving data consistency, residual accuracy, and image fidelity simultaneously. The hyperparameters involved in the iterative algorithm for balancing different terms are implicitly included in network modules and do not require empirical adjustment or explicit learning. The base networks utilize efficient and lightweight encoder-decoder architecture rather than several cascaded convolutional layers, which helps achieve promising performance using fewer iterations. Experimental results on simulated abdominal data and real mouse data show that the proposed method can gradually improve image quality in a progressive improvement manner and outperform related methods in artifact removal and detail restoration.

(3) Dual-Domain Learning Enhanced Reconstruction for Sparse-View DECT. The fast kV switching system for DECT is highly dependent on sophisticated and costly hardware and suffers from the difficulty of tube current modulation. Taking into account the data correlation between low- and high-energy channels in DECT, this study proposes a complementary sparse scanning scheme based on the slow kV switching technique and develops the dual-domain learning enhanced reconstruction algorithm for sparse-view DECT. The scanning scheme has the potential to reduce the technical cost, and it can acquire the information about the scanned object as much as possible and reduce the x-ray exposure dose. Meanwhile, this study develops the dual domain joint learning enhanced reconstruction algorithm for sparse-view DECT, which simultaneously performs projection inpainting in the data domain and residual artifact removal in the image domain. Both the projection domain sub-network and the image domain sub-network adopt the dual-stream ResUNet designed for DECT, in which the shared encoder can fully exploit the complementary information between

low- and high-energy data while the low-energy and high-energy encoders can effectively perform differential learning for dual-energy data. Experiments on the simulated abdominal data under three different sparse-view configurations demonstrate that the proposed method has promising performance in streaking artifact removal and fine feature restoration.

(4) Dual-Domain Prior Enhanced Deep Iterative Reconstruction for Limited-Angle DECT. With the widespread acceptance of DECT in the diagnostic radiology community, the interest in using DECT technology to improve applications such as interventional procedures and radiotherapy is increasing. However, the related devices do not integrate dual-energy imaging. Considering that the limited-angle scan is usually used to acquire data in these scenarios, this study proposes a DECT acquisition scheme based on dual-quarter scans. This scheme enables the acquisition of dual-energy data in a limited angular range and can reduce the x-ray exposure dose and shorten the scan time. To reconstruct high-quality images from incomplete measurement data, this study proposes the dual-domain prior enhanced deep iterative reconstruction algorithm for limited-angle DECT. Based on the traditional prior constrained iterative reconstruction framework, this algorithm further introduces the projection prior and image prior to improve the performance in projection inpainting and image restoration. Furthermore, the dense connections fusing information from different iterations can effectively avoid gradient vanishing and stabilize the model performance. Finally, the deep iterative reconstruction network is embedded as a generator in the adversarial learning framework to enhance the visual appearance of the generated DECT images. Experimental results on simulated abdominal data and real mouse data demonstrate that the proposed method performs better than the competing methods regarding wedge artifact removal, HU value correction, and image detail recovery.

Keywords: Computed tomography, deep learning, dual-domain processing, deep iterative reconstruction, generative adversarial networks, prior constrained

目 录

第一章 绪论.....	1
1.1 研究背景及意义.....	1
1.2 国内外研究现状.....	4
1.2.1 CT 重建方法.....	4
1.2.2 新型 DECT 成像方法	11
1.3 论文研究内容与组织结构	12
1.3.1 论文研究内容.....	12
1.3.2 论文组织结构.....	13
第二章 基于双域生成器网络的低剂量 CT 对抗学习重建	15
2.1 噪声模型.....	17
2.2 基于双域生成器网络的低剂量 CT 对抗学习重建算法	17
2.2.1 双域生成器.....	19
2.2.2 图像域判别器.....	19
2.3 实验和结果.....	20
2.3.1 模拟数据实验.....	20
2.3.2 真实数据实验.....	24
2.3.3 应对噪声的鲁棒性.....	27
2.3.4 剂量水平转换.....	29
2.3.5 消融研究.....	31
2.4 本章小结.....	33
第三章 基于双域网络正则的稀疏角度 CT 深度迭代重建	35
3.1 ACID 算法	36
3.2 基于双域网络正则的稀疏角度 CT 深度迭代重建算法	36
3.2.1 图像增强.....	38
3.2.2 残差感知.....	38
3.2.3 投影补全	38
3.2.4 网络结构.....	39
3.2.5 损失函数.....	39
3.3 实验和结果.....	39
3.3.1 模拟数据实验.....	40
3.3.2 真实数据实验.....	44
3.3.3 消融实验.....	47
3.3.4 算法复杂性分析.....	50
3.4 本章小结.....	51

第四章 基于互补扫描的稀疏角度 DECT 双域优化重建.....	53
4.1 基于互补扫描的稀疏角度 DECT 双域优化重建算法.....	54
4.1.1 互补稀疏采样.....	54
4.1.2 双域优化重建.....	55
4.1.3 复合损失函数.....	56
4.1.4 双流网络模型.....	57
4.2 数据预处理.....	58
4.2.1 预处理网络.....	58
4.2.2 训练与测试.....	59
4.3 实验和结果.....	60
4.3.1 数据说明.....	60
4.3.2 实验设置.....	61
4.3.3 消融研究.....	61
4.3.4 图像重建结果.....	63
4.3.5 材料分解结果.....	67
4.4 本章小结.....	71
第五章 基于双域先验增强的有限角度 DECT 深度迭代重建.....	73
5.1 基于双域先验增强的有限角度 DECT 深度迭代重建算法.....	73
5.1.1 基于双 1/4 圆周扫描的采集方案.....	74
5.1.2 传统先验信息约束的图像重建.....	74
5.1.3 双域先验增强的深度迭代重建.....	75
5.2 实验和结果.....	78
5.2.1 模拟数据实验.....	79
5.2.2 真实数据实验.....	82
5.2.3 消融研究.....	87
5.2.4 算法复杂性分析.....	89
5.3 本章小结.....	90
第六章 总结与展望	93
6.1 研究工作总结.....	93
6.2 未来工作展望.....	94
参考文献.....	96

第一章 绪论

1.1 研究背景及意义

X 射线计算机断层成像 (Computed Tomography, CT) 是一种非侵入式的成像技术, 通过对穿透物体的 X 射线衰减信息的多次不同角度的测量并使用相应的计算机程序处理, 能够可视化被扫描物体的内部三维结构^[1], 在医学^[2]、工业^[3]、安检^[4]、科研^[5]等多个领域均有广泛应用, 如图 1-1 (a) 所示。因具有扫描速度快和成像分辨率高的优点, CT 已成为临床上核心的影像模态之一, 普遍应用于癌症、心脑血管疾病、肺炎等诸多疾病的筛查、诊断、分级以及疗效评估, 且在手术和放疗等场景中提供影像引导, 部分应用实例展示在图 1-1 (b) 中。根据不同需求, 目前已经发展出多排螺旋 CT、大型 C-arm CT、机载 CBCT (Cone Beam Computed Tomography) 等多种形式的设备, 如图 1-1 (c) 所示。




图 1-1 CT 应用示例。(a) CT 在不同领域应用示例; (b) CT 具体临床应用示例; (c) 不同类型 CT 设备示例。

然而, CT 扫描使用的 X 射线会产生电离辐射, 有可能在活体组织中引起生物效应, 有一定概率导致基因损伤或诱发癌症^[6], 更需要关注的是, 孕妇和儿童对辐射损伤更加敏感^[7]。因此, 国际放射防护委员会 (International Commission on Radiological Protection,

ICRP) 提出“任何必要的照射应保持在可以合理做到的最低水平”的放射防护原则, 即后为人熟知的 ALARA (As Low As Reasonably Achievable) 原则, 以尽可能降低 X 射线成像中潜在的辐射风险。低剂量 CT (Low-dose CT) 也是近二十年来医学影像领域的热门研究课题^[8]。理论上, 可以通过图 1-2 所示的低管电流扫描、稀疏角度扫描以及有限角度扫描等三种方式来降低辐射剂量。




图 1-2 三种可降低 X 射线辐射剂量的扫描方式。(a) 低管电流扫描及其导致的严重噪声；(b) 稀疏角度扫描及其导致的条纹伪影；(c) 有限角度扫描及其导致的楔形伪影。

图 1-2(a)所示的低管电流扫描是临床上最常用的降低 X 射线辐射的方式。特别是, 在灌注 CT 等需要多期扫描的场景中, 尽可能降低单次扫描的剂量能够显著降低整个扫描过程中累积的辐射剂量, 进而减少诊疗过程中的副作用。然而, 在低管电流模式下, 采集的测量数据信噪比较低, 解析算法直接重建的 CT 图像中存在高强度的噪声, 会湮没图像中的诊断信息。

除了降低管电流, 还可以通过图 1-2 (b) 所示的稀疏扫描方式来降低辐射剂量。特别是, 在 3D 血管成像等需要在每个角度进行长时间曝光的场景中, 稀疏扫描不仅可以显著降低辐射剂量, 而且能够大幅缩短扫描时间^[9], 不过, 这会导致稀疏的测量数据。此外, 在肿瘤运动成像等场景中, 不可避免地导致每个运动相位下的测量数据都是稀疏的^[10]。在这些情况下, 直接使用稀疏测量数据重建的图像中存在严重的条纹伪影, 关键的诊断信息会被破坏。

此外, 还可以通过图 1-2 (c) 所示的有限角度扫描来降低 X 射线辐射剂量, 此种方式在手术和放疗等场景中较为普遍。在这些应用中, 龙门架通常以较低的速度旋转^[11, 12], 以防止其与患者或其他医疗设备发生碰撞, 有限角度扫描不仅可以降低 X 射线辐射剂

量,还能够缩短扫描时间。不过,有限角度扫描采集的投影数据不完备,直接重建的图像中存在严重的楔形伪影,导致诊断信息丢失。

在上述临床实际存在的非理想采样场景中,直接重建的 CT 图像往往存在高强度的噪声和伪影,无法为后续的诊断和治疗程序提供可靠的影像信息。在过去几十年中,迭代重建一直作为解决上述问题的金标准。迭代重建算法通过正则化项引入各种类型的先验信息约束来提高重建图像的质量,并通过数据保真项验证图像退化过程来保证重建的准确性,迭代地校正当前图像直至误差降低到可接受范围内。然而,迭代重建通常依赖于经验调整的超参数和人工设计的正则项^[13],而且无法提供一致的图像质量改进^[14]。此外,在测量数据退化严重时,迭代重建算法往往表现不佳。近年来,深度学习技术迅速发展,无论是 2017 年战胜了世界围棋冠军柯洁的 AlphaGo,还是近期十分流行的智能聊天机器人 ChatGPT,均体现了深度学习强大的潜力。当前,深度学习更是活跃在计算机视觉、自然语言处理以及专家系统等各个领域。深度学习也为医学影像领域带来了新的机遇^[13, 15-17],并已经发展为医学影像领域的一个新的前沿方向^[18]。结合深度学习技术、成像模型和优化理论以在非理想采样条件下实现高质量 CT 重建是一项极具研究意义和临床价值的课题,也是本研究关注的重点。

另外,普通 CT 在单能谱下进行扫描,通过物质对 X 射线吸收率的不同来区分不同的材料,然而由不同成分构成的物质在 CT 图像中可能显示为接近甚至相同的数值(比如碘和钙),普通 CT 无法对这些物质进行区分。在这种情况下,双能 CT (Dual-Energy Computed Tomography, DECT) 技术应运而生。与普通 CT 不同的是,DECT 在两个不同的 X 射线能谱下采集衰减数据,这使其获得了区分不同物质的能力,特别是,DECT 能够在已知元素组成的混合物中对两种或三种材料的质量密度进行量化^[19]。凭借其材料分辨的优势,DECT 已经发展出很多临床应用^[20],如虚拟单能成像(Virtual Monoenergetic Imaging^[21])、自动骨移除(Automated Bone Removal^[22])、灌注血容量成像(Perfused Blood Volume Imaging^[23])、尿路结石表征(Urinary Stone Characterization^[24])、结晶性关节炎病检查(Imaging of Crystalline Arthropathies^[25])等。目前,临床使用的 DECT 设备主要为三种,如图 1-3 所示,分别是德国西门子医疗的双源系统、美国通用电气医疗的快速 kV 切换系统、以及荷兰飞利浦医疗的双层探测器系统。双源系统使用两套光源和探测器来分别采集低能和高能数据;快速 kV 切换系统快速切换电压交替地采集低能和高能数据;双层探测器系统通过分层探测器分别接收低能和高能数据。




图 1-3 三种临床使用的 DECT 成像系统。(a) 西门子医疗双源系统; (b) 通用电气医疗快速 kV 切换系统; (c) 飞利浦医疗双层探测器系统。

可以看出,当前 DECT 成像严重依赖于专用的硬件设备和成像系统,在技术垄断的背景下,从软件的角度降低对专有硬件的依赖,对我国自主研发 DECT 成像系统具有积极意义。而且,随着 DECT 在诊断社区得到了广泛认可,使用 DECT 技术来优化放射治疗^[26-28]和介入手术^[29-31]等应用的兴趣也在持续增长,而相关设备通常没有集成 DECT 成像功能,改造或更换专用的设备将带来昂贵的技术成本,基于现有硬件设计可用的 DECT 成像方案临床意义显著。此外,DECT 成像中仍然存在辐射损伤的风险,在设计相关的成像系统时,也应遵循 ALARA 原则。


1.2 国内外研究现状

1.2.1 CT 重建方法

传统 CT 重建方法主要为解析重建和迭代重建,这两种技术目前已经比较成熟。解析算法通过对成像的正向模型进行数学反演将采集的投影数据直接重建为断层图像,滤波反投影算法 (Filtered Back-Projection, FBP^[32]) 就是一种经典的解析重建算法。在高质量投影数据可以获取时,解析算法可快速重建出高质量断层图像。然而,真实的成像物理过程在许多方面都与模型不符,传感器数据也与模型预测不符。特别是,临床实践中诸多非理想采样的需求会导致低信噪比甚至不完备的投影数据。在这些情况下,基于理想模型的解析算法重建的 CT 图像往往存在严重的噪声和伪影,无法用于后续的诊断和治疗程序。在过去的几十年中,迭代重建算法为解决上述问题的金标准。该类方法通常优化一个由数据保真项和正则化项组成的目标函数,不断地将当前图像的投影误差反向传递到图像空间并更新当前图像,直至重建误差降低到可接受范围内。迭代重建过程中,数据保真项通过验证预测图像的退化过程来保证重建图像的准确性,正则化项则通过引入各种类型的先验信息约束 (比如平滑性、稀疏性、低秩性、非局部自相似性等) 来提高重建图像的质量。迭代类算法有成熟的数学理论作为支撑,有潜力实现高质量重建,且具有良好的泛化性和稳定性,目前仍是医学成像领域的一个研究热点^[14],然而,超参数依赖经验调整和重建过程相对耗时两个主要问题^[13]在一定程度上限制了其临床应用。

自 2016 年以来,解析重建和迭代重建之外的第三类 CT 成像算法——基于深度学习的成像算法迅速发展,目前已经成为医学成像领域的新前沿方向^[8, 15, 16, 18, 33-35]。该类方法基于大量的训练数据建立输入到输出的映射关系,对精确的物理或数学模型依赖较低 (不过在深度学习框架中引入物理或数学知识也是一个很有潜力的研究方向)。随着更大和更有代表性的数据集^[10, 36-38]的建立,基于深度学习的成像算法有潜力实现超越传统的解析重建和迭代重建的性能。截止目前,已有大量基于深度学习的 CT 重建工作发表,参考 Ge Wang 教授等人的综述文献^[15, 39],本研究根据算法的驱动方式将有监督学习的 CT 成像方法分为两大类:即完全数据驱动的方法和数据-模型共同驱动的方法,同时根据学习的映射类型将完全数据驱动的方法归结为四类,分别是投影预处理、图像后处理、双域混合处理和完全学习的方法,根据算法框架的不同将数据-模型共同驱动的方法分

为两类，分别是展开的深度迭代重建算法和深度学习嵌入的迭代算法，如图 1-4 所示。除了有监督学习的 CT 成像算法，还有无监督^[40-46]和自监督^[47-52]等其他类型的基于深度学习的 CT 成像算法，但这些方法不是本研究关注的内容，本文不作详细介绍。



1.2.1.1 完全数据驱动的方法

完全数据驱动类方法通过大量配对样本对使用的深度神经网络（Deep Neural Network, DNN）进行训练以建立能够描述当前数据集输入到输出之间关系的非线性映射，根据映射的输入输出不同和映射方式的不同，完全数据驱动的方法可进一步细分为四类：投影预处理、图像后处理、双域混合处理以及完全学习的方法，以稀疏角度 CT 重建为例，各类方法的算法原理如图 1-5 所示。

（1）投影预处理。投影预处理类方法使用深度神经网络在投影数据域处理，期望对高质量投影数据进行精确预测，然后使用解析算法或者迭代算法重建出高质量断层图像，这类方法通常用于稀疏角度或有限角度 CT 重建。例如，Lee 等人^[53]和 Xu 等人^[54]将 UNet 中用于下采样的池化层替换成步长为 2 的卷积层，然后使用提取的投影块进行训练，在模拟人体数据和真实小鼠数据上均验证了 UNet 网络在稀疏投影恢复方面的有效性；此外，Ghani 等人^[55]和 Li 等人^[56]分别使用 C-GAN（Conditional Generative Adversarial Network）和 Patch-GAN 来生成全角度的投影。随后，为了进一步提升投影恢复的精度，Li 等人^[57]还引入基于图像的重建损失进行约束。无独有偶，Tan 等人^[58]为了更好地保持生成投影的边缘信息额外使用基于图像梯度的损失进行约束。Ghani 等人^[59]还进一步将 C-GAN 用于金属伪影移除，在投影空间恢复被金属伪影湮没的信息。在 DECT 方面，Wang 等人^[60]考虑到不同能量通道数据之间的相关性，有针对性地设计了一个生成对抗网络，该网络由一个生成器和两个判别器组成，生成器利用能量域相关性来提升投影恢复的精度，两个判别器分别用于评估生成的高低能投影的质量。投影数据非常敏感，处理不当很容易导致重建的图像中出现二次伪影^[39]，故而此类方法并未被大量研究，通常与图像后处理策略一起使用。




图 1-5 完全数据驱动类方法不同策略的算法原理图（以稀疏角度 CT 重建为例）。(a) 投影预处理类算法原理；(b) 图像后处理类算法原理；(c) 双域混合处理类算法原理；(d) 完全学习类算法原理。

(2) 图像后处理。与投影预处理类方法不同，图像后处理策略从解析算法或者迭代算法重建的图像开始，使用深度神经网络在图像空间处理，学习退化图像与高质量图像之间的映射关系。此类方法具有良好的泛化性，能够设计各种复杂的网络结构和损失函数来提升模型性能，广泛应用于去噪、伪影移除、散射校正等多项任务中。在初期研究中，使用的网络结构都比较简单。例如，Jin 等人^[61]直接将 UNet 应用于 CT 图像稀疏伪影移除，并展现了其优于传统 TV（Total Variation）约束重建算法的性能；Chen 等人^[62]设计了一个同样具有编码器-解码器结构的深度神经网络 RED-CNN 用于低剂量 CT 图像去噪；Zhang 等人^[63]将 DenseNet 密集连接的思想 and 反卷积结合设计了 DD-Net 并用于稀疏角度 CT 的条纹伪影移除；Liu 等人^[64]通过 3D ResNet 建立解析重建图像与迭代重建图像之间的映射关系，能够快速对 3D 图像进行降噪。随后，更丰富的图像特征被提取和利用以提升图像恢复的性能。比如，Yang 等人^[65]在常规重建损失的基础上增加了基于 Wasserstein 距离的对抗损失和基于特征空间的感知损失进行约束以生成内容和风格上均更加真实的图像；Li 等人^[66]在上述工作的基础上进一步加入自注意力（Self-Attention）机制利用 CT 图像层间相关性和层内相关性来提高模型性能；Kang 等人^[67]通过小波变换提取不同频率的图像特征用于低剂量 CT 图像降噪，随后 Kang 等人^[68]进一步引入一个递归校正的过程提高算法在纹理恢复方面的性能；Han 等人^[69]利用小波变换增强 UNet 提取多尺度特征的能力进而增强稀疏角度 CT 图像高频边缘的恢复效果；Huang 等人^[70]将 One-Hot 编码的解剖先验信息融入到网络中，仅训练一个模型便可以鲁棒地处理人体不同部位的数据；Xia 等人^[71]提出了一个参数依赖框架 PDF

(Parameter-Dependent Framework), 可以使网络关注到数据成像几何和剂量水平的不同, 进而使其能够鲁棒地处理在不同配置下采集的数据, 而且该框架可以用来改进不同类型的深度学习算法; Shan 等人^[13]设计了一个模块化的深度神经网络, 具有很好的泛化性, 使用模拟的低剂量数据训练后可直接用于多个供应商提供的真实低剂量数据上, 展现了可媲美甚至超越商业迭代重建算法的性能; Zhu 等人^[72]在经典的解码器-编码器网络中引入 Swin Transformer 模块来提取全局特征, 并使用基于 MAE (Mean Absolute Error) 和 MS-SSIM (Multi-Scale Structure SIMilarity) 的复合损失约束, 以提高网络的稳定性和降噪效果。在 DECT 成像中, 研究人员倾向于探索能量域相关性来设计先验以提升算法性能。例如, Zhang 等人^[73]提出具有三个编码器两个解码器的 TIME-Net (Transformer-Integrated Multi-Encoder Network) 用于 DECT 有限角度伪影移除, 其中先验编码器用于从融合的有限角 DECT 图像中提取先验特征; 进一步, 为了充分利用先验信息, Zhang 等人^[74]设计了一个在普通 CT 数据上预训练的网络来生成无伪影的先验图像, 然后通过一个编码器提取先验图像特征以增强算法在细节恢复方面的表现; Wu 等人^[75]为了避免 L_2^2 范式损失导致的模糊效应, 设计了一个基于 L_p^p 范式的损失函数, 并将表征不同能量通道数据之间相关性的正则集成到该损失函数中。图像后处理类方法灵活有效, 但是由于缺乏对数据一致性的约束, 难以恢复出被噪声和伪影湮没的结构特征, 且容易将退化图像中的噪声伪影当作有用特征保留在处理后的图像中。

(3) 双域混合处理。双域混合处理类方法将投影预处理策略和图像后处理策略组合使用, 先在投影空间提高数据一致性, 然后在图像空间进一步移除残留的噪声和伪影, 能够实现超越单一空间处理策略的性能, 其间根据实际情况在线或者离线进行图像重建。例如, Yin 等人^[76]使用两个 3D ResNet 先后在投影空间和图像空间进行降噪, 并在 UIH (United Imaging Healthcare) 公司提供的真实螺旋 CT 低剂量数据上进行了验证, 由于可用计算资源的限制, Yin 等人使用解析算法进行离线重建; 随后, Cai 等人和 Hu 等人分别将这一策略用于低剂量 Micro-CT 重建^[77]和稀疏角度 CBCT 重建^[78]中。Lin 等人^[79]设计了一个 DuDoNet (Dual Domain Network) 进行金属伪影移除, 使用 Radon 反演层进行在线域变换; 随后, Zhou 等人^[80]提出了改进版本的 DuDoUFNet (Dual-Domain Under-to-Fully-Complete Progressive Restoration Network) 同时进行低剂量 CT 重建和金属伪影移除; Chao 等人^[81]采用多阶段的渐进处理策略进行稀疏角度 CBCT 重建, 先通过两个投影域子网络进行 2 次 2 倍上采样将稀疏采集的投影数据补全, 然后使用 FDK (Feldkamp Davis Kress) 算法重建, 最后使用图像域子网络在图像空间进行微调; Pan 等人^[82]将 Swin Transformer 同时集成到投影空间和图像空间的子网络中, 提取全局信息提升稀疏角度 CT 重建精度; Yang 等人^[83]也在投影空间子网络中集成了一个 Transformer 模块, 与常规提取图像块的方式不同, Yang 等人考虑到了 CT 投影数据的特性, 将不同角度的投影分割成不同的块, 以对不同角度投影数据之间的依赖建模。基于双域混合处理的 DECT 重建算法研究相对较少, 在 2020 年, Zhang 等人^[84]将双域混合处理策略应用在稀疏角度 DECT 重建中, 随后, Chen 等人^[85]又将这一策略用于有限角度 DECT 重建; 另外, Wang 等人^[86]根据 DECT 成像特点设计了 DM-GAN (Dual-way Mapping GAN)

网络对缺失的高低能投影进行恢复，然后采用 TV 约束的迭代算法重建出相应的 DECT 图像，最后通过一个后处理网络进一步改善图像质量。以渐进的方式交替在投影空间和图像空间进行恢复，双域混合处理策略更有潜力实现高质量的 CT 重建。

(4) 完全学习类方法。完全学习类方法直接学习投影数据到断层图像之间的映射关系，不使用解析算法或者迭代算法进行域变换。2018 年，Zhu 等人^[15]提出 AUTOMAP 方法用于图像重建，并在 MRI (Magnetic Resonance Imaging) 和 PET (Positron Emission Tomography) 模式下进行了验证；同年，Würfl 等人^[87]提出了直接用于有限角度 CT 重建的网络，该网络由权重层、卷积层、全连接层和激活函数组成，旨在通过大量数据的训练学习一种更好的滤波反投影算法，特别值得指出的是，此项工作根据平行束成像几何、扇束成像几何和锥束成像几何的特点针对性地设计了不同的加权层。随后，Li 等人和 He 等人分别提出了 iCT-Net^[88]和 iRadonMAP^[89]实现 CT 投影数据到断层图像的直接映射。总体来说，这类方法^[90, 91]期望通过不同神经网络单元的组合实现一种更加鲁棒的滤波反投影算法或反投影滤波算法。最近，一些工作^[17, 92-95]展示了通过深度学习从极少角度投影（甚至单角度投影）直接进行三维重建的潜力，这些方法通常先使用一个或多个 2D 编码模块来提取投影数据的特征表示，然后采用转换模块将特征从投影空间变换到图像空间，最后利用 3D 解码器输出需要的体积图像；几项类似的研究^[96-99]还探索了使用 2.5D 深度神经网络来重建扫描对象主要结构（例如骨骼和工业组件）的可能性，这些方法通过增加特征图的通道数来实现与 3D 体积图像的维度匹配，隐式地进行域变换；与上述方法不同，Montoya 等人^[100]先使用一个显式的反投影层进行在线域变换，然后使用一个 2.5D 的 UNet 在图像空间恢复所需的 3D 体积图像。

1.2.1.2 数据-模型共同驱动的方法

随着深度学习强大的表征能力得到广泛认可，使用深度学习来改进传统基于模型的迭代算法的兴趣在医学成像社区迅速传播。此外，完全数据驱动的方法虽然在众多医学图像重建任务中展现了优异的性能，但这些方法本质上很少利用由物理和数学推导而来的传统算法，可能导致次优结果^[39]，而且这些方法的稳定性也让人担忧^[101, 102]。在这种背景下，研究人员开始探索数据-模型共同驱动的重建方法以期协同深度学习和传统算法的优势，本文根据总体框架的不同将这类算法细分为两种：展开的深度迭代重建算法和深度学习嵌入的迭代重建算法。

(1) 展开的深度迭代重建算法。顾名思义，此类方法将传统迭代算法展开成由重复网络模块组成的深度固定的神经网络，通过端到端的训练实现算法的收敛。例如，Zhang 等人^[103]将 ISTA (Iterative Shrinkage-Thresholding Algorithm) 算法展开成 ISTA-Net 并在自然图像的降噪任务上进行了验证；随后，Xiang 等人^[104]进一步将 FISTA (Fast Iterative Shrinkage-Thresholding Algorithm) 算法展开为 FISTA-Net 并应用于稀疏角度 CT 重建。此外，Adler 等人^[105]使用卷积神经网络取代了近端算子将近端对偶算法展开为 LPDR (Learned Primal-Dual Reconstruction) 算法，并用于低剂量 CT 去噪。He 等人^[106]和 Su 等人^[107]基于 ADMM (Alternating Direction Method of Multipliers) 算法分别提出

了用于低剂量 CT 重建的 3pADMM (Parameterized Plug-and-Play ADMM) 和用于稀疏角度 CT 重建 DIR-Net (Deep Iterative Reconstruction Network)。2017 年, Chen 等人^[108]展开了基于 FoE (Fields of Experts) 的迭代重建算法并构建了 LEARN 框架; 随后, Xia 等人^[71, 109]分别引入了图卷积 (Graph Convolution) 和参数依赖框架 (Parameter-Dependent Framework) 来增强原始的 LEARN 算法; 近来, Zhang 等人^[110]进一步引入双域混合处理的思想改进了 LEARN 算法, 提出 LEARN++ 框架并将其用于稀疏角度 CT 重建。用于 DECT 成像的深度迭代重建方法仅有少量报道, 2019 年, Wu 等人^[111]将 LPDR 算法^[105]应用于 DECT, 最近, Zhang 等人^[112]提出了展开的 SOUL-Net (Sparse and lOw-rank UnroLling Network) 用于能谱 CT 图像重建, 以数据驱动的方式学习传统迭代算法中的正则项和超参数。此外, 一些研究^[113, 114]还尝试将传统的图像域材料分解算法展开为迭代的材料分解网络并用于 DECT。

展开的深度迭代重建网络通常根据参考的迭代算法的形式针对性地设计具体结构, 本文以 LEARN 算法^[108]为例讲解此类算法的原理。一般地, 具有约束项的迭代重建算法目标函数如下:

$$x = \underset{x}{\operatorname{argmin}} \frac{\lambda}{2} \|Ax - b\|_2^2 + \mathcal{R}(x), \quad s.t. x \geq 0 \quad (1.1)$$

式(1.1)等号后的第一项为数据保真项, 第二项为正则项, 其中正则项可以利用各种先验知识来改进图像质量, 例如平滑性、稀疏性、低秩性、非局部自相似性等等。 λ 是平衡不同项权重的超参数; A 是系统矩阵; x 是重建的图像; b 是测量数据。

根据 Roth 等人^[115]提出的广义上的正则, 式(1.1)可转化成如下形式:

$$x = \underset{x}{\operatorname{argmin}} \frac{\lambda}{2} \|Ax - b\|_2^2 + \sum_{k=1}^K \phi_k(G_k x), \quad s.t. x \geq 0 \quad (1.2)$$

其中, K 是正则化器的个数, G_k 是第 k 种正则的变换矩阵, $\phi_k(\cdot)$ 是相应的势函数, G_k 和 $\phi_k(\cdot)$ 均可通过训练数据学习得到。使用梯度下降算法求解式(1.2)中的最小化问题:

$$\begin{aligned} x^t &= x^{t-1} - \alpha \cdot \left(\lambda A^T (Ax^{t-1} - b) + \sum_{k=1}^K (G_k)^T \gamma_k(G_k x^{t-1}) \right) \\ &= x^{t-1} - \alpha \cdot \lambda \cdot A^T (Ax^{t-1} - b) - \alpha \cdot \sum_{k=1}^K (G_k)^T \gamma_k(G_k x^{t-1}) \end{aligned} \quad (1.3)$$

其中, α 是搜索步长, 通常需要经验调整; $\gamma_k(\cdot) = \phi'_k(\cdot)$ 。考虑到人工神经网络强大的非线性映射能力, 可将式(1.3)中关于正则项的部分使用一个网络模块 $\mathcal{R}_{\text{CNN}}^t(\cdot)$ 替代, 标量 α 可直接由网络模块学习, 故可以省略, 另一个标量 $(\alpha \cdot \lambda)$ 使用一个可以训练参数 λ^{t-1} 替代, 式(1.3)中传统的更新步骤便转化为下式中基于深度学习的更新步骤:

$$x^t = x^{t-1} - \lambda^{t-1} A^T (Ax^{t-1} - b) - \mathcal{R}_{\text{CNN}}^t(x^{t-1}) \quad (1.4)$$

根据更新公式便可设计出展开的深度迭代重建网络, LEARN 算法的网络架构如图 1-6 所示。可以看出, LEARN 由 n 个迭代模块组成, 通常在训练之前固定, 每个迭代模块由式(1.4)定义。在 LEARN 中, 神经网络模块使用是级联的三层卷积, 不同算法可根据需求来使用其他更复杂的结构, 比如, Zhang 等人^[116]提出的 MetaInv-Net (Meta-Inversion

Network) 尝试了将 6 层级联的卷积和 UNet 作为基础网络。




图 1-6 展开的深度迭代重建算法 LEARN 的总体结构^[108]。

(2) **深度学习嵌入的迭代重建算法。**将深度学习与迭代重建相结合的另一种方案是将在单一空间（通常是图像空间）训练的网络作为替代项或者新增项嵌入到传统的迭代重建框架中去，与展开的深度迭代重建算法不同，深度学习嵌入的迭代重建算法仍然使用传统的迭代方式更新直至收敛，而不是端到端的训练，将其划分到有监督学习的类别中是因为使用的神经网络模块通常是通过有监督方式训练的。比如，Chen 等人^[117]将低剂量 CBCT 重建分解为三个子问题，通过深度神经网络来求解原本由传统算法处理的降噪子问题，以获得更好的重建结果；类似地，Ma 等人^[118]首先使用共轭梯度（Conjugate Gradient）算法实施数据保真约束，然后通过一个 U 型结构的自编码器来实施正则约束以改进图像的质量，算法流程如下所示：

算法 1：流形先验增强的迭代重建^[118]

- 1 初始化：FBP 重建的噪声图像 x_0 ，测量数据 b ，投影矩阵 A ，权重系数 β ；
 - 2 迭代步数 $t = 0$ ；
 - 3 迭代直至达到停止条件：
 - 4 计算 $\hat{x}_t = \text{CG}(A, x_{t-1}, b)$ ；注：CG 表示共轭梯度法求解。
 - 5 计算 $x_t = (\hat{x}_t + \beta \cdot \Phi(\hat{x}_t, \Theta^*)) / (1 + \beta)$ ；注： $\Phi(\cdot, \Theta^*)$ 为预先训练的自编码器。
 - 6 $t \leftarrow t + 1$ ；
 - 7 $x^* = \max(x_t, 0)$ ；注： $\max(\cdot, 0)$ 非负约束。
-

与上述方法不同, Wu 等人^[119]和 Zhang 等人^[120]分别使用 k 空间自编码器 KSAE (k -space Auto-Encoders) 和迭代伪影残差学习网络 IRLNet (Iterative Residual-Artifact Learning ConvNet) 获得一个映射函数作为正则化项用于低剂量 CT 重建。其中, Zhang 等人^[120]提出算法的目标函数如式(1.5)所示, 式(1.5)后一项即为基于深度学习的正则项。目标函数确定后, 可以使用多种成熟的算法来优化式(1.5)定义的问题, 比如分别使用 SQS (Separable Quadratic Surrogate) 算法和最陡下降法 (Steepest Descent) 来求解数据保真项和正则项, 本文不再赘述。

$$x, y = \underset{x, y}{\operatorname{argmin}} \|Ax - b\|_w^2 + \beta \sum_{m=1}^M \|P_m x - D(E(y_m))\|_2^2 \quad (1.5)$$

$$s. t. \|E(y_m)\|_0 \leq 0, \quad m = 1, 2, \dots, M$$

其中, x 为重建图像; A 为系统矩阵; b 为测量数据; w 是一个对角加权矩阵; β 为权重系数; P_m 是块提取算子, $y_m = P_m x$; M 为图像块数目; D 和 E 分别为 KSAE 的解码器和编码器, 可通过式(1.6)优化。

$$E, D = \underset{E, D}{\operatorname{argmin}} \sum_k \|x_k - D(E(x_k))\|_2 \quad (1.6)$$

$$s. t. \|E(x_k)\|_0 \leq 0$$

其中, x_k 是训练样本, K 是控制隐空间稀疏性的超参数。

除了使用深度学习来增强传统迭代重建算法, 最近, 一些研究提出使用迭代重建框架来稳定和提高深度学习算法的性能。比如, Wu 等人^[121, 122]提出 ACID (Analytic Compressed Iterative Deep) 框架来对抗深度重建网络的三种不稳定性^[101]: 1) 微小的扰动会导致高强度的伪影; 2) 微小特征的丢失或形变, 3) 采样率增加性能却下降; 随后, Hu 等人进一步改进 ACID 算法并将其应用于有限角度 CT^[123]和 4D CBCT^[124]以提高重建精度。Li 等人^[125]为了使训练好的神经网络能够鲁棒地处理不同部位以及不同扫描设置下采集的数据, 在测试阶段构建了基于高斯混合模型 (Gaussian Mixture Model) 的无监督重建网络, 并采用 EM (Expectation-Maximization) 算法进行优化。

1.2.2 新型 DECT 成像方法

研究人员一直在探索不依赖于专用硬件系统的 DECT 成像方案。早在 2010 年, Szczykutowicz 等人^[85]就提出通过慢速 kV 切换方案使用单一光源来交替采集双能数据, 并使用 PICCS (Prior Image Constrained Compressed Sensing) 算法解决相应的稀疏角度 DECT 重建问题。2020 年, 佳能医学研究中心 Zhang 等人^[84]提出了基于慢速 kV 切换的多步 DECT 深度重建算法, 先使用一个 UNet 进行投影补全, 然后进行投影域材料分解并重建出相应的基材料图像, 最后在图像空间使用另一个 UNet 进一步微调以输出最终的高质量材料图像。一些研究尝试^[126-128]在光源前放置一个光栅来分离出低能和高能 X 射线, 然后通过一次旋转采集双能数据, 再使用迭代算法进行重建。为使介入手术和放射治疗等应用从双能技术中获益, Chen 等人^[11]提出有限角度 DECT 成像, 并采用基于 DTV (Directional-Total-Variation) 约束的迭代算法来实现高质量重建。随后, Chen 等人^[129]进一步提出能够通过慢 kV 切换技术实现的两个正交弧形轨迹来采集双能数据。

最近,一些研究尝试使用深度学习直接通过单能数据来估计双能数据^[130-132]、材料图像^[133, 134]或者虚拟图像^[135],以摆脱对专用 DECT 设备的依赖。目前,三种主流系统之外的 DECT 成像方法仍在不断探索中,尚未有获得广泛认可的其他方案,本研究结合深度学习技术和 DECT 成像的特点,对新型 DECT 成像方法也进行了一定的探索。

1.3 论文研究内容与组织结构

1.3.1 论文研究内容

本研究从临床上 CT 成像面临的实际问题出发,先提炼出共性的科学问题,然后结合任务的特点设计相应的深度学习重建算法,总体研究思路如图 1-7 所示,具体如下:




图 1-7 论文主要研究内容

(1) 针对临床上通常采用降低管电流方式来降低 X 射线辐射导致的投影数据信噪比低的问题,本研究考虑到 CT 数据在投影空间和图像空间密切关联的特性,提出了基于双域生成器网络的低剂量 CT 对抗学习重建算法。与常规建立在图像空间或者投影空间的生成器不同,设计的双域生成器网络集成了投影滤波、解析重建和图像处理,能够超越不同数据空间的限制,提取更加丰富的信息。同时,采用一个双空间复合损失函数在成像的不同阶段进行监督,以保证生成器的各个组件向着高质量重建的方向优化。同

步处理连续的三帧数据有利于利用相邻帧之间的相关性来增强微小组织特征恢复性能。进一步,为了避免产生过度平滑的结果,引入了生成对抗网络来学习真实 CT 图像的统计分布,进而缓解模糊效应,增强生成图像的视觉效果。

(2) 针对临床上 3D 血管成像等需要在每个角度进行长时间曝光的应用中采用稀疏角度扫描来降低 X 射线辐射导致的测量数据稀疏的问题,本研究考虑到投影补全在提高数据一致性方面的潜力,提出了基于双域网络正则的稀疏角度 CT 深度迭代重建算法。每次迭代中均采用投影补全、残差感知和图像增强三个模块同时在投影空间、残差空间和图像空间进行约束。投影补全模块以监督学习的方式强制提高数据一致性,残差感知模块用以预测更精确的残差图像,图像增强模块进一步微调当前迭代图像。迭代重建中用以平衡不同项的超参数均隐含到网络模块中,无需根据经验调整或者显式学习。

(3) 针对临床上快速电压切换 DECT 系统对专用设备依赖程度高的问题,本研究提议使用慢速电压切换的方式来采集双能投影数据,为解决由此导致的采样稀疏的问题,本研究考虑到双能 CT 中不同能量通道数据之间存在大量的信息冗余,提出基于互补扫描的稀疏角度 DECT 双域优化重建算法。双能投影数据交替稀疏采集,可有效降低能级切换频率,进而降低技术成本。采用针对 DECT 成像设计的双流 ResUNet 在投影空间和图像空间同时恢复,以提高重建精度。双流 ResUNet 由共享编码器和高低能解码器构成,共享编码器将不同能量通道的数据编码成共享特征,高低能解码器针对不同能量通道数据进行差别学习,从共享特征中恢复出对应能级的投影或图像。

(4) 针对临床上想要通过 DECT 来改进介入手术和放射治疗等的应用但这些场景下难以进行完整圆周扫描的问题,本研究注意到 DECT 中可以利用能量域冗余性来放宽采集条件,提出基于双 1/4 圆周扫描的 DECT 互补采集方案,相应地开发了基于双域先验增强的有限角度 DECT 深度迭代重建算法。首先基于传统先验信息约束的重建算法模型推导出深度迭代重建算法框架,然后同时在投影空间和图像空间引入先验信息约束来增强算法性能。进一步,将提出的深度迭代重建框架嵌入到生成对抗网络中,使用对抗学习机制来增强生成的 DECT 图像的视觉效果,避免产生过度平滑的结果。

整体来看,本研究第四章和第五章分别是第二章和第三章研究内容在 DECT 成像应用中的扩展,第三章和第五章分别是第二章和第四章研究内容在算法层面的改进。

1.3.2 论文组织结构

本文分六个章节对研究的基于深度学习的双域 CT 重建课题进行讲解,论文具体组织结构如下:

第一章,绪论。介绍了课题的研究背景和意义,分析了 CT 成像在临床实践中存在的非理想采样场景以及相关场景下图像质量下降的原因;概述了当前 CT 成像领域的研究现状,并对基于深度学习的 CT 重建算法以及新型 DECT 成像方案进行了详细的分类讲解;最后,简要介绍了本文的研究内容和论文组织结构。

第二章,基于双域生成器网络的低剂量 CT 对抗学习重建。首先分析了投影空间和图像空间单独处理的深度学习算法的局限性以及处理后图像过度平滑的原因,并简要说

明了构建双域生成器网络用于 CT 重建和使用对抗学习机制缓解模糊效应的潜力；然后详细介绍了提出的基于双域生成器网络的低剂量 CT 对抗学习重建的算法框架、优化目标以及关键组件；接着在模拟人体低剂量数据和真实腹部体模低剂量数据上评估了算法性能，并探究了算法应对噪声的鲁棒性以及剂量水平之间的转换关系，最后采用消融实验验证了双空间联合处理策略和生成对抗机制的作用。

第三章，基于双域网络正则的稀疏角度 CT 深度迭代重建。首先介绍了新颖的 ACID 算法框架；然后采用渐进式改进的策略逐步引入图像增强、残差感知和投影补全等模块构建基于双域网络正则的稀疏角度 CT 深度迭代重建算法；随后采用模拟人体 CT 数据和真实小鼠 Micro-CT 数据评估算法的性能；接着采用消融实验探究了不同模块的影响、模型大小的影响以及不同迭代的结果；最后对不同算法的复杂性进行了对比分析。

第四章，基于互补扫描的稀疏角度 DECT 双域优化重建。首先分析了快速 kV 切换方式 DECT 系统对专有硬件的强依赖性以及在电流调制方面的困难，说明了慢速 kV 切换 DECT 成像在降低技术成本方面的优势；然后介绍了 DECT 成像中不同能量通道数据之间的相关性，并基于此提出了基于互补扫描的 DECT 稀疏采样方案；接着对稀疏角度 DECT 双域优化重建的算法流程以及设计的 DECT 专用的双流 ResUNet 进行了详细介绍；然后对采用的数预处理操作进行了简要说明；最后在腹部 DECT 数据上评估了算法的性能，并通过材料分解应用评估了使用提出方法重建的 DECT 图像得到的材料图像的临床效用。

第五章，基于双域先验增强的有限角度 DECT 深度迭代重建。首先简要介绍了传统先验图像约束的迭代重建算法，在此基础上提出基于双域先验增强的有限角度 DECT 深度迭代重建算法，并对算法框架、优化目标和关键组件进行了详细介绍，然后在模拟的腹部 DECT 数据和真实的小鼠 DECT 数据上评估了算法性能，最后采用消融实验探究了不同组件和对抗学习机制的作用，并对不同算法的复杂性进行了分析比较。

第六章，总结与展望。对本文的工作进行总结，并对未来工作进行展望。

第二章 基于双域生成器网络的低剂量 CT 对抗学习重建

在螺旋 CT 中,通常采用降低管电流的方式来降低 X 射线辐射剂量,然而低管电流模式下采集的投影数据信噪比较低,直接重建的 CT 图像中存在高强度的噪声甚至产生伪影,无法用于诊断。为了解决这个问题,过去的几十年中,模型驱动的迭代算法^[136-141]被广泛研究,然而这些方法不能提供一致的图像质量改善^[13, 14],且性能依赖于人工设计的正则项和经验调整的超参数,耗时的重建过程也阻碍了其在临床上的广泛应用。

近年来,数据驱动的深度学习方法成为医学影像领域新的前沿方向^[15, 16, 18],这类方法不完全依赖精确的数学或物理模型,而是基于大量的训练数据建立输入与高质量图像之间的映射关系,具有超越传统迭代重建的潜力。目前,基于深度学习的低剂量 CT 成像方法已有大量研究,其中,投影预处理^[54, 55, 142]和图像后处理^[61, 62, 64, 67, 68, 143]是最为常见的两类方法。投影预处理通常用于解决稀疏角度或有限角度重建问题,旨在通过深度神经网络弥补缺失的投影信息,进而减少直接使用解析算法重建的图像中的伪影。投影预处理的优势在于能够提高数据一致性,有助于恢复图像中丢失的信息,局限在于投影数据需要谨慎处理,否则容易导致二次伪影。图像后处理方法直接对解析算法重建的图像进行恢复,不需要原始投影数据,具有广泛的适用性,能够设计较为复杂的深度神经网络提取各种图像特征以改进性能。这类方法的不足之处在于难以恢复出已经被噪声和伪影湮没的图像细节^[13, 65],尽管这些微小组织特征可能对于诊断来说十分重要。




图 2-1 CT 图像数据和投影数据具有显著特征差异但又紧密关联

在 CT 中,不同空间数据的特征具有明显差异,如图 2-1 所示,图像数据空间结构信息丰富、对比度高,而投影数据具有明显的正弦曲线结构且不同角度投影是序列相关的。图像后处理和投影预处理策略仅在相应的空间进行独立处理,虽然取得了令人印象深刻的结果,但是并未考虑 CT 图像数据和投影数据密切相关的特性。研究人员提议进行双域协同处理,即将投影空间处理和图像空间处理联合起来^[13, 65],以提高 CT 重建的精度,初步研究^[76, 79, 144-146]也表明了这种策略的潜力。受到启发,本研究设计了一个端到端的低剂量 CT 重建网络,将投影滤波、解析重建以及图像处理集成到一个框架中进行联合优化,同时使用三维模型引入相邻帧之间的相关性来提升重建精度。

此外,常规基于深度学习的方法主要是通过最小化预测图像与标签图像像素级的均方误差 (Mean Squared Error, MSE) 或平均绝对误差 (Mean Absolute Error, MAE) 来优化,这可能会导致模糊效应和结构失真^[65, 147-149]。如图 2-2 所示,在降噪后的图像中,

黄色箭头指示的肝脏血管和红色箭头标记的肝脏病灶均存在不同程度的形变,且降噪后的图像过度平滑。根本原因是最小化欧式距离鼓励平均所有可能的解^[150-152]。生成对抗网络(Generative Adversarial Networks, GANs)在解决这个问题上具有极大的潜力。作为一种强大的生成模型,GAN的工作原理是交替训练两个目标不同的组件。其中,判别器(Discriminator)是一个分类网络,致力于甄别真假样本,而生成器(Generator)则专注于生成尽可能逼真的假样本来迷惑判别器。得益于上述对抗学习机制,GAN在医学成像领域众多任务中均取得了优异的表现^[153]。不过,在CT成像中,现有方法均只在图像空间构建生成器,生成过程没有考虑数据一致性,构建一个融合投影滤波、解析重建以及图像处理的双域生成器网络有望进一步提高重建精度^[13, 65]。




图 2-2 最小化欧式距离导致的模糊效应和结构失真。降噪图像由 FBPCovNet 算法^[61]获得。图像显示窗口为[-140,260] HU。

综上,本章提出 CLEAR (Comprehensive Learning Enabled Adversarial Reconstruction) 方法用于低剂量 CT 成像。首先,与常规的构建在图像域的生成器不同,双域生成器网络可以通过可微的解析重建算子超越不同数据空间的限制,进而捕获更丰富的信息,而且能够直接将原始投影映射为高质量的 CT 图像,对数据一致性的约束也有助于 CLEAR 恢复微小结构特征。其次,采用双空间复合损失函数在成像的不同阶段进行约束,可以推动所有网络组件朝着高质量重建方向更新,保证生成图像与金标准图像之间的一致性。最后,基于 Wasserstein 距离的对抗学习机制可以将真实 CT 图像的统计特性转移到生成的 CT 图像中,以缓解模糊效应,产生视觉上改善的结果。定性和定量分析均表明了 CLEAR 算法在噪声抑制、结构保真和视觉效果改善方面的潜力。本章相关成果已发表在《IEEE Transactions on Medical Imaging》期刊。

本章 2.1 节简要介绍了 CT 成像中的噪声模型;2.2 节详细讲解了基于双域生成器网络的低剂量 CT 对抗学习重建算法的整体框架、优化目标和关键部件;2.3 节首先对使用的数据集和实验设置进行了说明,然后对比分析了不同方法结果并探究了不同方法应对噪声的鲁棒性,最后探索了模拟噪声和真实剂量水平之间的转换关系并展示了消融研究的结果;2.4 节对本章进行总结并对需要进一步解决的问题进行探讨。

2.1 噪声模型

根据先前工作^[154]，本研究采用泊松噪声模型来近似 CT 成像中测量数据的物理效应。假设光子是单能量的，正向投影过程可以描述为：

$$Z_i \sim \text{Poisson}\{Z_{0i}e^{-P_i} + E_i\}, i = 1, 2, 3, \dots, N. \quad (2.1)$$

其中， Z_i 和 Z_{0i} 分别为出射和入射光子数； P_i 是衰减系数的线积分； E_i 是沿着第 i 条 X 射线路径的电子噪声； N 为 X 射线路径的总数。

无论在投影空间还是图像空间，低剂量 CT 数据均可以解耦为高质量数据及其对应噪声成分：

$$I_{LD} = I_{RD} + I_N = \mathcal{R}(P_{RD} + P_N). \quad (2.2)$$

其中， I_{RD} 和 P_{RD} 分别常规剂量下的高质量 CT 图像和投影数据； I_N 和 P_N 分别表示图像空间和投影空间的噪声成分； I_{LD} 为被噪声污染的低剂量 CT 图像，对应的低剂量投影 $P_{LD} = P_{RD} + P_N$ ； $\mathcal{R}$ 表示图像重建。

2.2 基于双域生成器网络的低剂量 CT 对抗学习重建算法

作为一种一步式重建方法，CLEAR 致力于训练一个生成器网络 g ，直接将低剂量投影 P_{LD} 映射为常规剂量下的高质量 CT 图像 I_{RD} ，可以描述为：

$$g^*(P_{LD}) \approx I_{RD} \quad (2.3)$$

为了找到最优的生成器 g^* ，本研究采用一种渐进改进的策略来设计最终的目标函数。

通常，使用 MSE 损失约束的基于深度学习的后处理算法的优化目标可以描述为：

$$\min_{\phi_{ID}} \mathcal{L}_{MSE}(\phi_{ID}(I_{LD}), I_{RD}), I_{LD} = \text{FBP}(P_{LD}) \quad (2.4)$$

图像域网络 ϕ_{ID} 以 FBP 直接重建的退化图像为输入并输出对高质量 CT 图像 I_{RD} 的估计。然而，由于没有考虑到投影数据的一致性，这类算法无法准确恢复出已被噪声和伪影淹没的微小结构特征^[13, 65]。本研究考虑到在投影空间恢复缺失信息的可能性，首先构造一个双域生成器网络 ϕ_{CD} ，将投影预处理、解析重建和图像后处理集成到一个框架中：

$$\min_{\phi_{CD}} \mathcal{L}_{MSE}(\phi_{CD}(P_{LD}), I_{RD}) \quad (2.5)$$

对于深度模型，使用简单的 MSE 损失约束难以达到最优性能。先前研究表明，设计一个合适的损失函数有助于提高深度学习模型的性能^[65, 155-157]。因此，构建了一个双空间复合损失函数（Dual-Domain Loss, DDL），来监督不同阶段的网络组件使其参数朝着高质量重建的方向优化，具体如下：

$$\min_{\phi_{CD}} \mathcal{L}_{DDL}(\phi_{CD}) = \min_{\phi_{PD}, \phi_{ID}} \left(\alpha \cdot \mathcal{L}_{PL}(\phi_{PD}(P_{LD}), P_{RD}) + \mathcal{L}_{IL} \left(\phi_{ID} \left(\text{FBP}(\phi_{PD}(P_{LD})) \right), I_{RD} \right) \right) \quad (2.6)$$

其中， $\mathcal{L}_{PL}$ 和 $\mathcal{L}_{IL}$ 分别为投影空间约束和图像空间约束； α 为投影空间损失的权重系数。投影空间损失 $\mathcal{L}_{PL}$ 以监督学习的方式提高数据一致性，仅更新投影空间网络 ϕ_{PD} 的参数；图像空间损失 $\mathcal{L}_{IL}$ 计算重建图像的误差并通过反向传播算法更新图像空间网络 ϕ_{ID} 的参数，同时，图像误差还会通过可微的 FBP 算子传递到投影空间，进而更新投影空间网络 ϕ_{PD} 的权重。具体地， $\mathcal{L}_{IL}$ 采用 MSE 损失因为 l_2 范式具有良好的噪声抑制效果， $\mathcal{L}_{PL}$ 采

用 MAE 损失因为 l_1 范式倾向于产生尖锐的边缘^[158]。

在保证重建精度的情况下，进一步引入 WGAN-GP (Wasserstein GAN with Gradient Penalty^[159]) 来处理模糊效应的问题，最终的目标函数定义为：

$$\min_g \max_d [\mathcal{L}_{DDL}(g) + \eta \cdot \mathcal{L}_{GAN}(g, d)] \quad (2.7)$$

其中，前一项为式(2.6)定义的双空间复合损失函数，后一项为 WGAN-GP 的优化目标。

η 是平衡对抗损失和重建损失的权重系数； g 和 d 分别表示生成器和判别器， $g = \phi_{CD}$ 。




图 2-3 CLEAR 网络框架及其关键组件。(a) CLEAR 网络详细结构，CLEAR 主要由两个部件组成：双域生成器和图像域判别器，其中双域生成器由投影域网络 (PD-Net)、可微滤波反投影算子 (Differentiable FBP) 和图像域网络 (ID-Net) 构成；(b) PD-Net 和 ID-Net 的具体结构；(c) 图像域判别器的具体结构。

WGAN-GP 引入 Wasserstein 距离和梯度惩罚 (Gradient Penalty) 来稳定网络的训练，其优化目标如下：

$$\min_g \max_d \mathcal{L}_{GAN}(g, d) = \mathbb{E}_{I_{RD}}[d(I_{RD})] - \mathbb{E}_{g(P_{LD})}[d(g(P_{LD}))] - \lambda_{gp} \cdot \mathbb{E}_{\hat{I}} \left[\left(\|\nabla_{\hat{I}} d(\hat{I})\|_2 - 1 \right)^2 \right] \quad (2.8)$$

其中，前两项计算 Wasserstein 距离，最后一项进行梯度惩罚。 λ_{gp} 是梯度惩罚项的权重系数； $\mathbb{E}$ 表示期望； $\nabla_{\hat{I}} d(\hat{I})$ 为生成器 d 对 $\hat{I}$ 的梯度， $\hat{I} = \epsilon \cdot I_{RD} + (1 - \epsilon) \cdot g(P_{LD})$ ， $\epsilon \sim U[0, 1]$ 。

本章提出了 CLEAR 网络来解决式(2.7)描述的问题, 其具体结构如图 2-3 所示。从图 2-3 (a) 可以看出, CLEAR 主要由两个部件组成, 即双域生成器网络和图像域判别器网络。以低剂量投影 P_{LD} 为输入, 生成器输出对高质量 CT 图像 I_{RD} 的估计 $g(P_{LD})$ 。然后, 判别器通过缩小 $g(P_{LD})$ 和 I_{RD} 的 Wasserstein 距离来鼓励生成器产生更加逼真的图像。参考先前研究^[66], CLEAR 同时处理连续的多帧数据以提取和利用相邻帧之间的关联信息提高微小结构恢复性能。

2.2.1 双域生成器

如图 2-3(a)所示, 双域生成器由投影域网络(Projection-Domain Network, PD-Net)、可微滤波反投影算子(Differentiable FBP)和图像域网络(Image-Domain Network, ID-Net)构成。PD-Net 首先在投影空间抑制噪声, 然后可微 FBP 算子将处理后的投影数据实时重建为 CT 图像, ID-Net 进一步在图像空间移除残留的噪声和伪影成分。上述操作集成在一个完整的成像通道中, 可以直接将低剂量投影映射为高质量 CT 图像。具体地, PD-Net 以低剂量投影 P_{LD} 为输入, 对 P_{LD} 中的噪声成分 P_N 进行预测, 然后, 通过逐像素的减法操作获得对常规剂量投影的估计 $\widehat{P_{RD}}$; 接下来, 可微 FBP 算子将 $\widehat{P_{RD}}$ 重建为中间图像 $\widehat{I_{RD}}$; 最后, ID-Net 对 $\widehat{I_{RD}}$ 中残留的噪声和伪影成分进行估计, 并输出最终的对高质量 CT 图像的估计 I_{RD}^* 。PD-Net 和 ID-Net 都被设计为估计相应的残差特征, 而不是直接学习对应的高质量投影或者图像, 以加速网络收敛并稳定训练^[67]。

(1) **投影域网络和图像域网络。**图 2-3 (b) 所示的 3D ResUNet 为 PD-Net 和 ID-Net 的具体结构。3D ResUNet 结构具有三方面的优点。首先, 残差连接可以避免梯度消失并稳定深度神经网络的训练; 其次, 跳跃连接可以同时映射局部和全局特征, 有助于捕获更加丰富的信息; 最后, 3D 模型能够利用相邻帧之间的相关性来提升重建精度。3D ResUNet 的基本元素包括卷积(Conv)、反卷积(DeConv)、残差块(ResBlock)和拼接操作(Concat)。残差块由两个连续卷积和一个残差连接构成^[160]。采用步长为 2 的卷积进行下采样, 采用相同步幅的反卷积进行上采样, 其余层卷积步长均为 1。除最后一层外, 所有卷积和反卷积的核大小均为 $3 \times 3 \times 3$, 最后一层的卷积核为 $1 \times 1 \times 1$ 。编码阶段特征图通道数从 32 逐步增加到 256, 解码阶段特征图通道数从 256 逐步减少为 1。每层卷积之后均使用 Leaky ReLU (Leaky Rectified Linear Unit^[161]) 激活函数。

(2) **可微 FBP 算子。**在网络训练时, 需要反投影算子将投影数据映射到图像空间, 同时, 反向传播时, 需要正向投影算子将计算的图像梯度传递到投影空间。本章使用开源的 torch-radon 库^[162]提供的与深度学习框架兼容的可微 FBP 算子。该算子具有 GPU 加速的投影和滤波反投影功能, 且和反向传播算法兼容, 支持根据成像几何和临床需要来设置不同的重建参数。

2.2.2 图像域判别器

图像域判别器采用简洁紧凑的结构, 共有 8 层网络, 包括 6 个卷积层, 一个全局池化层和一个全连接层, 如图 2-3 (c) 所示。样本在输入判别器之前, 被提取为 3D 图像块, 以增加判别器的表征能力同时保留相邻帧之间的相关性。6 个级联的卷积层用来提

取不同尺度的图像特征，步长为 1 的卷积后跟随批量归一化（Batch Normalization^[163]）和 Leaky ReLU 激活函数。采用全局池化层而不是全连接层来压缩特征维度，这样有助于防止过拟合^[164]。最后，采用输出维度为 1 的全连接层用于 Wasserstein 距离计算。

2.3 实验和结果

本节通过模拟人体数据和真实腹部体模数据来评估提出的 CLEAR 算法的性能。对比方法包括 FBP^[32]、TV^[165]、RED-CNN^[62]、DD-UNet^[146]和 CLEAR w/o GAN 等不同类型的算法。其中，FBP 是常用的解析重建算法；TV 是经典的使用全变分（Total Variation）正则的迭代重建算法；RED-CNN 是代表性的具有编码器-解码器结构的低剂量 CT 图像去噪网络；DD-UNet 是一种双域联合优化的 CT 重建网络，除了常用的均方根误差（Root Mean Square Error, RMSE）损失，DD-UNet 还引入了感知损失（Perceptual Loss^[156]）在特征空间进行监督；CLEAR w/o GAN 是 CLEAR 的退化版本，用于探究对抗学习机制的影响。除了视觉评估，还采用了三个常用的指标，平均绝对误差（Mean Absolute Error, MAE^[149]）、结构相似性（Structural SIMilarity, SSIM^[144]）和峰值信噪比（Peak Signal to Noise Ratio, PSNR^[69]）来量化评估。实验在台式电脑（Ubuntu 20.04、i7-10700K 3.8GHz CPU、24GB Geforce RTX 3090 GPU、64GB RAM）上使用 Python 和 Pytorch 库实现。

2.3.1 模拟数据实验

2.3.1.1 数据集

AAPM 低剂量 CT 大挑战数据（<https://www.aapm.org/grandchallenge/lowdosect/>）用于模拟实验（后简称 AAPM 数据）。该数据集的患者数据是在比赛主办机构（梅奥诊所）的机构审查委员会批准后回顾性收集的，本研究申请了数据的使用许可（仅学术研究用途）。AAPM 数据集中 10 名匿名患者的腹部对比增强 CT 图像用于本项研究，按照 8:1:1 的比例随机分为训练集、验证集和测试集；此外，为增强实验的说服力，测试时还使用了来自美国国家癌症研究所的 5 名匿名患者数据（<https://wiki.cancerimagingarchive.net/>）。采用表 2-1 中的成像几何获得模拟投影数据并添加泊松噪声，参考先前研究^[76, 166]，将式(2.1)中的入射光子数 Z_{0i} 设置为 5.0×10^4 。

表 2-1 扇束成像几何

参数	值	参数	值
光源-探测器距离	108.56 cm	光源-旋转中心距离	59.50 cm
探测器矩阵尺寸	736×1	探测器单元尺寸	1.2858×1.0 mm ²
图像矩阵尺寸	512×512	图像像素尺寸	0.8×0.8 mm ²
投影数目	576	全扫描角度范围	(0°, 360°]

2.3.1.2 参数设置

式(2.6)中平衡投影损失权重的 α 设置为 0.2，以保证和图像损失数值在相同数量级。参考先前工作^[13]，式(2.7)中重建损失权重 η 设置为 0.02。式(2.8)中梯度惩罚项的系数 λ_{gp} 设置为默认值 10。受限于可用的计算资源，将三帧相邻数据作为一组，即生成器中投

影域网络 PD-Net 的输入输出维度为 $N \times 1 \times 3 \times 576 \times 736$ ，图像域网络 ID-Net 的输入输出维度为 $N \times 1 \times 3 \times 512 \times 512$ ， N 为批量大小，本研究中设置为 1。判别器的输入是在线提取的三维图像块，尺寸为 $(N \times 16) \times 1 \times 3 \times 128 \times 128$ 。训练时，首先稳定 CLEAR 生成器的重建性能，此阶段仅最小化式中(2.6)中定义的双空间复合损失函数，使用默认的 Adam 优化器训练 15 轮，学习率从 10^{-4} 逐步衰减到 10^{-5} 。从第 16 轮开始，生成器和判断器交替优化，生成器仍使用默认设置的 Adam 算法，判别器使用的 Adam 算法的两个指数衰减系数 β_1 和 β_2 分别设置为 0.5 和 0.9，学习率均固定为 10^{-5} 。在训练稳定后，通过验证集权衡图像视觉效果和量化指标来确定最终的用于测试的模型参数。为了公平比较，所有竞争方法的参数均依据相关文献和经验进行调优，基于深度学习的方法均采用和 CLEAR 相同的数据训练。

2.3.1.3 重建结果




图 2-4 不同方法在模拟人体低剂量 CT 数据上的轴状面结果。第 1 列为参考的常规剂量 CT 图像；第 2-7 列分别为低剂量条件下 FBP、TV、RED-CNN、DD-UNet、CLEAR w/o GAN 和 CLEAR 方法重建/处理的结果。黄色方框内 ROI 放大在相应图像下方。图像显示窗口为 $[-160, 240]$ HU。

图 2-4 展示了不同方法在模拟人体低剂量 CT 数据上的轴状面结果。第 2 列中 FBP 直接重建的低剂量 CT 图像存在高强度的噪声，血管和病灶等重要诊断信息均被噪声淹没，难以辨识。第 3 列中 TV 重建的图像虽然噪声被有效抑制，但存在过度平滑的现象，

图 2-4 (b3)中蓝色箭头指示的肝脏血管以及红色圆圈标记的肝脏病灶均因模糊效应而失真。相比之下, RED-CNN 处理后的图像清晰度比 TV 重建的结果更高,但是,从图 2-4 (b4)中 ROI 放大图可以发现, RED-CNN 处理后的肝脏病灶存在明显形变。而且,从图 2-4 (d4)和(f4)中红色箭头标记可以看出,由于没有考虑到数据一致性, RED-CNN 容易把低剂量 CT 图像中噪声导致的伪影结构当成有用信息保留下来,形成一些假阳性特征。同 RED-CNN 相比,融合了投影预处理的 DD-UNet 重建的图像中没有出现明显的假阳性特征。而且, DD-UNet 使用的基于特征空间的感知损失一定程度上缓解了模糊效应,从图 2-4 第 5 列结果中放大的 ROI 可以看出, DD-UNet 重建的图像较 RED-CNN 的结果更加清晰。不过, DD-UNet 的结果存在轻微的棋盘伪影,这是因为用来计算感知损失 VGG 模型是在自然图像上训练的,未在 CT 数据上进行调整,故而导致了一定的负面效应。从图 2-4 第 6、7 列中多处蓝色箭头标记可以看出,与其他方法结果相比, CLEAR w/o GAN 和 CLEAR 重建的图像中的细节和参考结果更加一致,特别是,图 2-4 (b6)、(b7)中红色圆圈标记的肝脏病灶和图 2-4 (b1)中的结果最为匹配。此外,与 CLEAR w/o GAN 的结果相比, CLEAR 重建的图像更加清晰。




图 2-5 不同方法在模拟人体低剂量 CT 数据上的冠状面结果。第 1 列为参考的常规剂量 CT 图像;第 2-7 列分别为低剂量条件下 FBP、TV、RED-CNN、DD-UNet、CLEAR w/o GAN 和 CLEAR 方法重建/处理的结果。黄色方框内 ROI 放大在相应图像下方。图像显示窗口为 $[-160, 240]$ HU。

为进一步比较,图 2-5 和图 2-6 分别展示了不同方法在模拟人体低剂量 CT 数据上的冠状面和矢状面结果。解析重建算法无法抑制噪声,图 2-5 第 2 列中 FBP 重建的图像仅能辨别大致结构,图像细节信息几乎完全被噪声淹没。整体上来看,图 2-5 第 3 列中 TV 重建的图像过于模糊,且红色箭头指示的多处肝脏血管存在形变现象。由于没有对数据一致性进行约束,RED-CNN 处理后的图像多处细节特征与参考图像不匹配,如图 2-5 第 4 列中红色箭头所示。与 RED-CNN 的结果相比,图 2-5 (b5)和(d5)中 DD-UNet 的结果没有明显的优势,但(f5)中黄色箭头指示的 DD-UNet 重建的肝脏血管结构与(f1)中的参考结果更加接近。第 6 列中 CLEAR w/o GAN 的结果虽然细节上恢复得较好,但是图像存在轻微的模糊。整体比较发现,图 2-5 第 7 列中 CLEAR 重建的图像清晰度更高,黄色箭头标记的肝脏血管等多处微小组织特征也恢复得更好。与冠状面的结果类似,图 2-6 展示的矢状面结果中, CLEAR 重建的图像细节上和参考结果更加一致,特别是, CLEAR 能够很好地保持红色圆圈标记的肝脏病灶的辨识度,而且 CLEAR 重建的图像没有出现过度平滑的现象,具有更好的视觉感受。




图 2-6 不同方法在模拟人体低剂量 CT 数据上的矢状面结果。第 1 列为参考的常规剂量 CT 图像;第 2-7 列分别为低剂量条件下 FBP、TV、RED-CNN、DD-UNet、CLEAR w/o GAN 和 CLEAR 方法重建/处理的结果。黄色方框内 ROI 放大在相应图像下方。图像显示窗口为 $[-160, 240]$ HU。

表 2-2 统计了不同方法在模拟人体低剂量 CT 数据上的量化结果。从表 2-2 可以观察到一个有趣的现象,在基于深度学习的方法中,RED-CNN 获得了除 CLEAR w/o GAN 之外最好的 PSNR 和 MAE 分数,且 SSIM 仅比 CLEAR 方法低了 0.08%,这与前面视觉评估的结果并不一致,一些相关研究也发现了类似现象^[65, 147, 167]。PSNR 和 MAE 均是像素级别的度量,而 RED-CNN 是以最小化像素级别 MSE 损失为训练目标的,DD-UNet 和 CLEAR 分别引入了基于图像特征的损失和基于数据分布的损失约束,因此,RED-CNN 获得更好的 PSNR 和 MAE 分数并不奇怪。如果从 CLEAR 中移除基于数据分布的对抗损失,其各项指标均明显上升,表 2-2 中 CLEAR w/o GAN 的量化结果明显优于其他方法。此外,RED-CNN 还获得了优于 DD-UNet 且接近于 CLEAR 的 SSIM 分数,这有悖于视觉评估的结论。从图 2-4 至图 2-6 中展示的结果可以清晰观察到,RED-CNN 处理后的图像中存在明显的蜡状伪影和失真现象,特别是在图 2-4 和图 2-5 的(d4)和(f4)中。视觉评估中,DD-UNet 在细节恢复上虽然没有展现出明显的相对于 RED-CNN 的优势,但是 DD-UNet 可以有效避免产生蜡状伪影,这一点可以清楚地从图 2-4 (d4)和(d5)的对比中发现。相对于 RED-CNN,视觉评估中 CLEAR 的结果无论是在视觉感受上还是结构保真上均具有明显的优势,但是定量比较中 CLEAR 的 SSIM 仅优于 RED-CNN 结果 0.08%,而 PSNR 和 MAE 指标甚至略低于 RED-CNN。这一现象表明,尽管 SSIM、PSNR 和 MAE 作为评价图像质量的常用指标,但是其并不能充分反映图像质量的优劣^[65]。

表 2-2 不同方法在模拟人体低剂量 CT 数据上的定量结果。加粗:最优结果,下划线:次优结果。

方法	SSIM (%)	PSNR (dB)	MAE (HU)
FBP	82.67	29.83	55.92
TV	97.14	37.13	18.58
RED-CNN	97.63	<u>40.52</u>	<u>15.01</u>
DD-UNet	97.52	39.52	15.54
CLEAR w/o GAN	98.46	41.48	12.57
CLEAR	<u>97.71</u>	40.10	15.38

2.3.2 真实数据实验

临床实践中无法获得配对的不同剂量的人体数据用于研究。相比之下,模拟人体解剖结构和衰减特性的物理体模可以不计 X 射线的辐射伤害,进行多次扫描采集配对的不同剂量水平的数据用于研究或临床验证。

2.3.2.1 数据集

本节使用的 CIRS 三维腹部体模 (CIRS 3D Abdominal Phantom, Model 057A, CIRS Inc., Norfolk, VA) 如图 2-7 所示。通过 GE Discovery HD750 CT 系统采集数据,扫描时

管电压保持 120kV 不变,管电流从 10mA 逐渐增加至 600mA,共收集了 17 种不同剂量的配对体模数据,使用商用滤波反投影算法重建出相应的断层图像。由于原始投影数据不可获得,本研究使用与表 2-1 相同的成像几何将真实的不同剂量的腹部体模断层图像进行正向投影以获得不同剂量的投影数据。




图 2-7 CIRS 三维腹部体模。(a) 体模真实图像; (b) 体模断层图像示例。

2.3.2.2 参数设置

CIRS 腹部体模的结构和衰减特性与人体十分接近,因此腹部体模数据直接用于测试,即所有深度学习算法均仅使用 AAPM 数据训练,未在 CIRS 腹部体模数据重新训练或微调,因而本节没有参数调整。

2.3.2.3 重建结果

图 2-8 展示了不同方法在管电流设置为 100mA、70mA 和 50mA 时采集的腹部体模数据上的结果,其中将管电流为 600mA 时采集的图像作为参考图像。从图 2-8 第 2 列中的结果可以看出,RED-CNN 虽然能够有效抑制低剂量 CT (Low-dose CT, LDCT) 图像中的噪声,但观察(b3)、(d3)和(f3)中 ROI 的放大图可以发现,其处理过的图像过度平滑且存在明显的块状伪影。与 RED-CNN 相比,图 2-8 第 3 列中 DD-UNet 的结果虽然更加清晰,但是图像存在明显的棋盘伪影。第 4 列中,没有使用对抗学习机制的 CLEAR w/o GAN 方法的结果虽然有一些过度平滑,但是并没有出现明显的块状或蜡状伪影。第 5 列中 CLEAR 重建的图像保留了少许 LDCT 图像中的放射状伪影,但从(b6)、(d6)和(f6)中放大的 ROI 可以看出,与其他方法结果相比, CLEAR 算法结果的视觉效果更好。此外,图 2-8 中多处黄色箭头标记的模拟血管的对比度 $\text{CLEAR} > \text{CLEAR w/o GAN} > \text{DD-UNet} > \text{RED-CNN}$, 红色箭头指示的模拟肾脏病灶的对比度 $\text{CLEAR w/o GAN} > \text{CLEAR} > \text{RED-CNN} > \text{DD-UNet}$, 蓝色箭头标记的血管的对比度 CLEAR w/o GAN 方法更好,其余方法表现相当。

表 2-3 统计了不同方法在管电流设置为 100mA、70mA 和 50mA 时采集的腹部体模数据上的定量结果。CLEAR w/o GAN 在不同情况下均获得了最好的指标,这与图 2-8 中视觉评估的结果一致。此外,PSNR 和 MAE 的次优结果均由 CLEAR 方法获得,SSIM




图 2-8 不同方法在不同剂量的腹部体模数据上的结果。第 1 列为低剂量 CT 图像；第 2-5 列分别为低剂量条件下 RED-CNN、DD-UNet、CLEAR w/o GAN 和 CLEAR 方法重建/处理的结果；第 6 列为参考的常规剂量 CT 图像。黄色方框内 ROI 放大在相应图像下方。图像显示窗口为 $[-160, 240]$ HU。

的次优结果均由 RED-CNN 获得，这与视觉评估的结果有一定出入，因为从图 2-8 第 2 列中 ROI 的放大图可以看出，RED-CNN 处理过的图像中存在明显的块状伪影，这一现象再次表明了 PSNR、SSIM、MAE 等指标不能全面客观地反映图像的质量。基于当前研究可以发现，在仅使用传统像素级别图像强度损失（比如 MSE、RMSE 和 MAE 等）优化的方法中，使用 PSNR、SSIM 和 MAE 等指标来评估图像质量是公平的，但在引入其他类型损失（比如基于图像特征的感知损失或基于数据分布的对抗损失）后，不能仅通过 PSNR、SSIM 和 MAE 等指标来评判图像质量的优劣，因为这些指标并不能全面客观地反映图像的质量。在这种情况下需要结合可视化结果综合评定，因为医学图像中不同组织和病灶的对比度在放射科医生主观阅片时十分重要。

表 2-3 不同方法在不同剂量腹部体模数据上的定量结果。加粗：最优结果，下划线：次优结果。

管电压/电流	度量（单位）	LDCT	RED-CNN	DD-UNet	CLEAR w/o GAN	CLEAR
120kV, 100 mA	SSIM (%)	85.79	<u>96.12</u>	95.14	96.56	95.25
	PSNR (dB)	35.28	36.09	36.24	39.37	<u>37.85</u>
	MAE (HU)	18.54	16.63	15.07	11.17	<u>14.15</u>
120kV, 70 mA	SSIM (%)	82.25	<u>95.97</u>	94.98	96.49	94.91
	PSNR (dB)	34.93	36.04	36.26	39.3	<u>37.7</u>
	MAE (HU)	21.65	16.71	14.94	11.28	<u>14.45</u>
120kV, 50 mA	SSIM (%)	78.23	<u>95.79</u>	94.78	96.38	94.46
	PSNR (dB)	33.61	35.99	36.27	39.20	<u>37.49</u>
	MAE (HU)	25.2	16.83	14.92	11.47	<u>14.90</u>

2.3.3 应对噪声的鲁棒性

本研究中，所有基于深度学习的方法均仅使用单一噪声强度的低剂量数据进行训练。但是在临床实践中，不同患者同一部位或者同一患者不同部位的噪声水平是不尽相同的。因而，探究算法对不同噪声水平数据的鲁棒性十分有意义。为排除实际场景中不确定因素的干扰，本研究采用 2.3.1 节中的模拟人体数据来探究不同算法应对噪声的鲁棒性。具体地，在生成投影数据时，分别将式(2.1)中入射光子数 Z_{0i} 设置为 1.0×10^5 、 7.5×10^4 、 5.0×10^4 、 2.5×10^4 和 1.0×10^4 来获得具有 5 种不同强度泊松噪声的低剂量 CT 数据。请注意，本节中所有基于深度学习的方法均只使用噪声强度为 $Z_{0i} = 5.0 \times 10^4$ 的数据训练，训练好的模型直接用于测试其他噪声水平的数据。

图 2-9 展示了不同方法在模拟的不同剂量人体数据上的结果。整体上看，使用噪声强度为 $Z_{0i} = 5.0 \times 10^4$ 数据训练的 RED-CNN、DD-UNet、CLEAR w/o GAN 和 CLEAR 在应对 $Z_{0i} = 2.5 \times 10^4$ 至 $Z_{0i} = 1.0 \times 10^5$ 强度的噪声是都是比较鲁棒的。当噪声强度过大，即 $Z_{0i} = 1.0 \times 10^4$ 时，所有方法的性能均急剧下降，无法重建出可靠图像。从图 2-9 (e2)-(e6)可以看出，RED-CNN 处理后的图像存在严重的蜡状伪影，DD-UNet 和 CLEAR w/o GAN 重建的图像也受到了不同强度伪影的干扰，相比之下，CLEAR 方法没有导致明显的二次伪影，其重建的图像具有更好的视觉效果。从(a3)-(e3)中黄色圆圈标记的 ROI 可以看出，RED-CNN 在微小组织结构恢复上的性能有限，且处理后的图像容易出现块状或蜡状伪影。与 RED-CNN 的结果相比，DD-UNet 重建的图像没有明显的二次伪影，细节特征也保持得更好。(a5)-(d5)中 CLEAR w/o GAN 重建的图像细节恢复得较好，但结果有一些模糊。与其他方法相比，(a6)-(d6)中 CLEAR 重建的图像能够很好地保持血管等微小组织特征的一致性，而且具有更好的视觉效果，同时没有出现二次伪影。




图 2-9 不同方法在模拟的不同剂量的人体数据上的结果。第 1 列为参考的常规剂量 CT 图像；第 2-6 列分别为低剂量条件下 FBP、RED-CNN、DD-UNet、CLEAR w/o GAN 和 CLEAR 等方法重建/处理的结果。图像显示窗口为 $[-160, 240]$ HU。请注意，所有基于深度学习的方法均仅使用噪声强度 $Z_{0i} = 5.0 \times 10^4$ 的数据训练，未经任何微调直接用于测试其他噪声水平的数据。

表 2-4 统计了不同方法在不同剂量模拟人体数据上的定量结果。从 FBP 重建的结果可以看出，随着入射光子量的减少，低剂量 CT 图像质量逐渐下降。整体看来，RED-CNN、DD-UNet、CLEAR w/o GAN 和 CLEAR 等方法结果的量化指标均会随着噪声水平的降低而提高。在 Z_{0i} 为 2.5×10^4 及其以上时，SSIM、PSNR 和 MAE 等指标的最优分数均由 CLEAR w/o GAN 方法获得；在 $Z_{0i} = 1.0 \times 10^4$ 时，所有方法的表现均明显下降，相比之下，DD-UNet 获得了最好的 SSIM、PSNR 和 MAE。与其他方法相比，CLEAR 方法在量化评估时没有体现出优势，这与视觉评估的结果并不一致，在图 2-9 展示的可视化结果中，CLEAR 重建的图像与参考图像更加一致，关于这个现象上文已有讨论，这里不再赘述。

综合来看，使用固定噪声水平（ $Z_{0i} = 5.0 \times 10^4$ ）的数据训练的不同方法均能鲁棒地处理噪声水平在一定范围内（ $Z_{0i} = 2.5 \times 10^4 \sim 1.0 \times 10^5$ ）波动的低剂量数据。视觉评估中，本章提出的 CLEAR 方法能够重建出与参考结果更加接近的图像；量化评估中，CLEAR w/o GAN 相对于其他方法具有明显的优势。

表 2-4 不同方法在不同剂量的模拟数据上的定量结果。加粗：最优结果，下划线：次优结果。

噪声水平	度量 (单位)	FBP	RED-CNN	DD-UNet	CLEAR w/o GAN	CLEAR
$Z_{0i} = 1.0 \times 10^5$ (未训练)	SSIM (%)	91.63	97.48	97.17	97.72	<u>97.60</u>
	PSNR (dB)	31.15	<u>41.08</u>	40.42	41.54	41.02
	MAE (HU)	54.85	<u>16.63</u>	17.54	15.74	16.79
$Z_{0i} = 7.5 \times 10^4$ (未训练)	SSIM (%)	89.67	97.35	97.05	97.66	<u>97.43</u>
	PSNR (dB)	30.07	<u>40.89</u>	40.22	41.42	40.70
	MAE (HU)	62.18	<u>16.90</u>	17.9	15.92	17.37
$Z_{0i} = 5.0 \times 10^4$ (训练)	SSIM (%)	86.33	97.07	96.82	97.52	<u>97.09</u>
	PSNR (dB)	28.49	<u>40.45</u>	39.85	41.12	40.11
	MAE (HU)	74.69	<u>17.63</u>	18.58	16.37	18.46
$Z_{0i} = 2.5 \times 10^4$ (未训练)	SSIM (%)	79.06	95.80	<u>96.03</u>	96.50	95.77
	PSNR (dB)	25.67	<u>39.01</u>	38.78	39.72	38.46
	MAE (HU)	103.51	20.78	<u>20.71</u>	18.97	21.99
$Z_{0i} = 1.0 \times 10^4$ (未训练)	SSIM (%)	67.33	89.29	91.35	88.76	<u>90.86</u>
	PSNR (dB)	21.81	<u>35.11</u>	35.18	34.14	34.89
	MAE (HU)	161.56	34.18	31.00	34.72	<u>33.07</u>

2.3.4 剂量水平转换

在 2.3.1 节中，本研究通过式(2.1)来向投影数据中添加泊松噪声以生成模拟的低剂量数据，将模拟数据中的噪声水平和真实数据中的剂量水平等效是十分有意义的。因为，临床实践中，无法获得配对的不同剂量水平的图像用于有监督模型的训练，如果能够找到模拟噪声和真实剂量水平之间的转换关系，则可以缩小模拟低剂量数据和真实低剂量数据之间的差异，有助于稳健地将使用模拟数据训练的模型迁移到真实数据上。




图 2-10 不同剂量水平的腹部体模 CT 图像。显示窗口为[-160, 240] HU。

然而，目前尚未有广泛认可的转换模型将模拟的泊松噪声和真实剂量水平等效。本

节尝试使用本章 2.3.2 节中的 CIRS 三维腹部体模数据找到与 $Z_{0i} = 5.0 \times 10^4$ 的模拟低剂量数据噪声水平相当的真实低剂量数据。如上文所述, CIRS 三维腹部体模数据通过 GE Discovery HD750 CT 系统采集, 包含了配对的 17 种不同剂量 (10mAs~600mAs) 的 CT 图像。本研究将 600mAs 的图像作为参考图像进行正向投影并添加入射光子量 $Z_{0i} = 5.0 \times 10^4$ 的泊松噪声, 生成模拟的低剂量投影, 然后使用 FBP 算法重建, 获得模拟的低剂量 CT 图像。将模拟的低剂量 CT 图像和真实的不同剂量的 CT 图像比对以找出剂量水平相当的图像。

表 2-5 不同剂量水平的腹部体模 CT 图像的量化指标

度量 (单位)	模拟 LDCT $Z_{0i} = 5.0 \times 10^4$	80 mAs	70 mAs	60 mAs
SSIM (%)	82.56	83.64	82.25	80.49
PSNR (dB)	34.87	35.45	34.93	34.34
MAE (HU)	21.97	20.39	21.65	23.17

表 2-6 不同剂量水平的腹部体模 CT 图像的统计测量 (均值±标准差)

ROI 编号	模拟 LDCT $Z_{0i} = 5.0 \times 10^4$	60 mAs	70 mAs	80 mAs	600 mAs
ROI 1	136± 32	138±34	138± 31	138±26	136±9
ROI 2	83± 36	83±38	83± 36	83±33	83±12
ROI 3	51± 33	52±34	51± 32	52±30	52±11

图 2-10 展示了模拟的低剂量 CT 图像及与其具有相近噪声水平的真实低剂量 CT 图像。仅凭借视觉评估无法判断和图 2-10 (a)最为匹配的图像, 因此计算(a)-(d)中不同剂量图像和 600mAs 图像的 SSIM、PSNR 和 MAE 等指标, 结果统计在表 2-5 中。可以发现, 70mAs 的图像和模拟的低剂量 CT 图像在各项量化指标上均十分接近。为进一步比较, 选取了 3 个衰减值不同的 ROI (如图 2-10 所示), 并测量不同图像中对应 ROI 中的统计值, 结果如表 2-6 所示。对比发现, 在统计特性方面, 仍然是 70mAs 的图像和模拟的低剂量 CT 图像更加接近。

视觉评估和定量比较均表明, 在 GE Discovery HD750 CT 系统中, 模拟的 $Z_{0i} = 5.0 \times 10^4$ 的泊松噪声可以近似等效为 70mAs 的剂量水平。然而, 由于实际中的噪声分布受多种因素的影响, 本研究中探究的这种等效关系可能并不具有泛化性。而且, 从图 2-10 中可以发现, 模拟的低剂量 CT 图像中的伪影形式和真实的 70mAs 图像中的伪影形式有一定差异。这可能与物体本身衰减分布、成像系统特性、重建参数和算法选择等多种因素都有关系。如果仅需在固定成像系统中粗略地模拟具有一定剂量水平的噪声, 本节的方法可能会有所帮助。

2.3.5 消融研究

本节首先对投影-图像双空间联合优化策略的有效性进行验证, 为了公平比较, 将 CLEAR w/o GAN 与 Dual PD-Net 和 Dual ID-Net 进行对比, 其中 Dual PD-Net 使用与 CLEAR 相同的两个级联的 3D ResUNet 在投影空间处理, Dual ID-Net 使用与 CLEAR 相同的两个级联的 3D ResUNet 在图像空间处理, 这样保证了三个模型的参数量是相同的。




图 2-11 消融研究中不同方法在模拟人体低剂量 CT 数据上的结果。显示窗口为 $[-160, 240]$ HU。

表 2-7 消融研究中不同方法在模拟人体低剂量 CT 数据上的定量结果

度量 (单位)	Dual PD-Net	Dual ID-Net	CLEAR w/o GAN
SSIM (%)	97.33	97.41	97.52
PSNR (dB)	40.33	41.03	41.12
MAE (HU)	17.91	16.57	16.37

不同方法在模拟人体低剂量 CT 数据上的结果展示在图 2-11 中。从第 2 列中的图像可以看出, 仅在投影空间处理的 Dual PD-Net 的结果存在着明显的二次伪影, 箭头指示的多处细节有不同程度的失真。相比之下, 第 3 列中图像域方法 Dual ID-Net 处理后的图像没有出现明显的伪影, 但是在细节方面仍需进一步改进。第 4 列中 CLEAR w/o GAN 重建的图像和第 1 列中的参考结果更加接近, 特别是, CLEAR w/o GAN 能够很好地保

持黄色箭头指示的肝脏血管以及蓝色箭头指示的肝脏病灶的一致性。不同方法的定量比较结果统计在表 2-7 中, CLEAR w/o GAN 方法的各项指标均优于 Dual PD-Net 和 Dual ID-Net。视觉评估和定量分析结果均表明, 投影空间和图像空间联合处理的策略比仅在单一的投影空间或图像空间的处理策略更有潜力。

此外, 在 2.3.1 节和 2.3.2 节重建结果的对比中, 引入对抗学习机制后出现了视觉评估和量化分析结论不一致的现象, 因此, 本节详细探究了对抗学习机制对重建结果影响。在图 2-4~图 2-6、图 2-8、图 2-9 均展示了使用对抗学习机制的 CLEAR 方法和不使用对抗学习机制的 CLEAR w/o GAN 方法的结果, 对比图中放大 ROI 可以发现, 二者在细节恢复上的表现相当, 但 CLEAR w/o GAN 重建的图像存在过度平滑的现象, 而 CLEAR 的结果更加清晰, 具有更好的视觉效果。表 2-2 和表 2-3 统计了 CLEAR w/o GAN 和 CLEAR 在不同数据上的量化结果, 可以看出在引入了生成对抗网络之后, 重建结果的各项指标均明显降低, 但是在不同结果的视觉评估中, 未发现 CLEAR 相对于 CLEAR w/o GAN 有明显劣势, 相反, CLEAR 重建的图像具有更好的清晰度。相关研究^[65, 74, 92, 147, 167]也发现了类似现象, 对抗学习机制确实导致了量化指标的下降, 但是本研究和先前相关工作的结论一致, 认为引入对抗学习机制后的结果具有更好的图像质量。在医学图像重建中, 图像的视觉效果也十分重要, 因为医学图像最终由放射科医生通过视觉读取^[74, 92]。

下面将进一步探究对抗学习机制导致 MAE、PSNR 和 SSIM 指标下降的原因。本研究中, 为了保证重建的精度, 同时使输出的结果具有更好的视觉效果, 使用式(2.7)描述的复合损失函数将基于 Wasserstein 距离的对抗损失和基于欧式距离的重建损失组合在一起。由于二者优化目标并不完全相同, 对抗损失在缓解模糊效应的同时导致了重建损失增大, 因而定量评估时像素级别的图像强度误差指标(如 MAE、MSE 和 RMSE)的值有所上升。根据 PSNR 的计算公式:

$$PSNR(I_1, I_2) = 20 \cdot \log_{10} \left(\frac{V_{MAX}}{\sqrt{MSE(I_1, I_2)}} \right) \quad (2.9)$$

V_{MAX} 为图像的最大灰度值, 几乎不变, 当 $MSE(I_1, I_2)$ 增加时, $PSNR(I_1, I_2)$ 便会下降。

SSIM 计算公式为:

$$SSIM(I_1, I_2) = \frac{(2\mu_{I_1 I_2} + C_1)(2\sigma_{I_1 I_2} + C_2)}{(\mu_{I_1}^2 + \mu_{I_2}^2 + C_1)(\sigma_{I_1}^2 + \sigma_{I_2}^2 + C_2)} \quad (2.10)$$

其中 C_1 和 C_2 为常数, μ_I 和 σ_I 分别为图像的均值和标准差, $\sigma_{I_1 I_2}$ 是图像 I_1 和 I_2 的协方差。为确定上述值的变化关系, 选取了 8 个平滑区域的 ROI, 并测量了不同方法结果在相应 ROI 内的统计值, 结果如图 2-12 所示。可以看出, GAN 对 ROI 内均值几乎没有影响, 但使用了 GAN 的 CLEAR 方法重建的图像的 ROI 内的标准差和参考值更加接近, 且比 CLEAR w/o GAN 方法重建的图像的 ROI 内的标准差大。将 I_2 作为参考图像, 根据图 2-12 的测量可知, I_1 改变时, 式(2.10)中 $(2\mu_{I_1 I_2} + C_1)$ 和 $(\mu_{I_1}^2 + \mu_{I_2}^2 + C_1)$ 两项的值几乎不变, 而且此时 I_1 和 I_2 的协方差 $\sigma_{I_1 I_2} = \mu_{I_1 I_2} - \mu_{I_1} \mu_{I_2}$ 也几乎不变, 因此 $(2\sigma_{I_1 I_2} + C_2)$ 项的值几乎不变。当 $\sigma_{I_1}^2$ 的值变大时, $SSIM(I_1, I_2)$ 便会下降。需要说明的是, 针对对抗学习机制导致

量化指标下降的问题,目前并没有广泛认可的数学解释。上述分析虽然较好地说明了同一模型引入对抗学习机制后 MAE、PSNR 和 SSIM 等量化指标下降的原因,但并没有严格数学证明,不具有普遍意义。




图 2-12 生成对抗网络对重建图像统计性质的影响。(a)不同方法结果 ROI 内均值; (b)不同方法结果 ROI 内标准差。

2.4 本章小结

为了实现高质量的低剂量 CT 重建,本章考虑到 CT 成像中投影数据和图像数据密切相关的特性,提出投影-图像双空间联合优化的策略,并基于此设计了双域生成器网络。该网络将投影预滤波、解析重建和图像后处理集成到一个完整的成像通道中,有潜力直接从低剂量投影重建出高质量的 CT 图像。同时,该网络同时处理连续的三帧数据以利用相邻帧之间的相关性来提升重建精度。进一步,本章还引入了对抗学习机制来缓解最小化 MSE 损失导致的模糊效应,增强重建图像的视觉效果。消融研究表明,投影-图像双空间联合优化的策略比单一的投影空间或图像空间处理策略在图像细节保真和伪影抑制等方面更有潜力,使用的 WGAN-GP 也可以有效避免产生过度平滑的结果,重建出更加清晰的图像。在模拟人体数据和真实腹部体模数据上的结果均表明了 CLEAR 相对于同类方法在微小特征恢复、二次伪影抑制和视觉效果增强等方面的潜力。

为了重建出视觉上和真实常规剂量 CT 图像更加接近的图像,本章引入了生成对抗

网络 WGAN-GP 来缓解 MSE 损失导致的模糊效应。有趣的是,在实验中发现,相对于 CLEAR 方法,仅使用 MSE 损失的图像后处理网络 RED-CNN 在量化评估中表现出和 CLEAR 相当的性能,但是在视觉评估中,额外使用了基于数据分布的对抗损失的 CLEAR 算法重建的结果明显具有更准确的图像细节、更好的视觉感受以及更少的二次伪影,这就导致了视觉评估和定量比较的评价不一致。先前很多工作^[65, 74, 92, 147, 167]也发现了类似现象,且一致认为使用了对抗学习机制的方法的结果具有更好的图像质量且保持了更准确的诊断信息,本研究也认可这一结论。本章消融实验也进一步探究了同一模型引入对抗学习机制后量化指标下降的原因。从表 2-3 和表 2-4 可以发现,不使用基于数据分布的对抗损失的 CLEAR w/o GAN 方法在定量评估时具有明显优势,引入对抗损失后, CLEAR 方法的定量指标虽然有一定程度下降,但是从图 2-4~图 2-6、图 2-8 和图 2-9 的结果中并没有发现其在细节恢复和噪声抑制方面的性能下降,而且 CLEAR 重建的图像更加清晰,具有更好的视觉效果。上述现象也表明了设计一项能够全面客观地衡量图像质量的指标是十分有意义的。

此外,图像重建任务与单纯的图像生成任务不同,图像重建追求的是像素级别的准确性,而图像生成着重图像语义上可读性。在图像生成任务中, WGAN-GP 是否收敛可以根据判别器的损失来确定,但是图像重建任务中,为了保证重建的精度,生成器是采用对抗损失和重建损失联合优化的,如式(2.7)所示。因此不能再单纯依靠判别器的损失来确定网络是否收敛,而本章 2.3 节中的定量结果又显示对抗学习机制会使重建损失的值上升,因此,图像重建任务中,需要综合考虑验证集结果的视觉效果、重建损失和对抗损失来确定最终用于测试的模型参数。

最后,本章提出的 CLEAR 是数据驱动的方法,但是在临床实践中,无法获得配对的不同剂量的数据。本研究中,网络训练时使用的是模拟的低剂量 CT 数据,模拟数据在统计分布上可能与真实数据不一致,这种不匹配会降低算法在真实场景中的性能,本章 2.3.2 节中不同方法在真实腹部体模数据上的结果也验证了这一点。如何缩小模拟数据和真实数据之间的分布差异进而使在模拟数据上训练的模型能够鲁棒地迁移真实数据上也是需要进一步解决的问题。

第三章 基于双域网络正则的稀疏角度 CT 深度迭代重建

对于 3D 血管成像等需要在单个角度进行长时间曝光的应用中,稀疏角度扫描可以通过减少曝光次数有效降低累积的辐射剂量并缩短扫描时间^[9]。此外,在肿瘤运动成像等场景中,人体不自主的生理活动往往导致不同运动阶段的投影数据是严重稀疏的;为解决这个问题,4D-CBCT 成像被提出^[168]。4D-CBCT 将采集的投影数据根据不同的呼吸阶段分成不同的组,每组投影数据可以独立地重建对应呼吸相位的图像。但是,由于每个呼吸相位下的投影数据都是稀疏的,重建的每个呼吸阶段的图像通常存在着严重的条纹伪影,进而影响后续的治疗程序^[10]。因此,开发一种能够有效抑制条纹伪影的稀疏角度 CT 重建算法具有重大的临床意义。

近年来,深度学习迅速发展并已经成为医学影像领域新的前沿方向^[15, 18, 169],在医学图像重建方面也表现出了优异的性能^[13, 16]。其中,能够融合深度学习强大表征能力和迭代算法模型知识的深度迭代重建算法是求解医学成像中病态逆问题的一种很有潜力的方案^[104, 170],在 MRI^[171-173]、PET^[174-176]以及 CT^[104, 105, 108]中均取得了令人印象深刻的结果。然而,当前研究通常只在图像空间进行网络约束,未能充分发挥深度神经网络的性能,本研究第二章以及其他相关工作^[76, 79, 144, 146]表明,将投影空间处理融合到重建网络中有助于提升模型性能。

因此,本章在深度迭代重建框架中引入投影空间约束,提出了基于双域网络正则的深度残差迭代最小化网络(Deep Residual Error iterative Minimization Network, DREAM-Net)用于稀疏角度 CT 重建。DREAM-Net 由多个迭代块组成,每个迭代块包含三个级联的模块,即投影补全、残差感知和图像增强,每个模块负责特定的任务。首先,DREAM-Net 使用基于深度学习的图像增强模块替代传统迭代中基于压缩感知的正则项,将新颖的 ACID (Analytic Compressed Iterative Deep) 算法^[121, 122]展开到深度学习框架中。然后,引入残差感知模块,以传统的残差图像为输入,对精确的误差图像进行估计。最后,投影补全模块对缺失的测量数据进行恢复,以提高投影数据的一致性。与仅在图像空间进行网络约束的常规深度迭代重建方法相比,DREAM-Net 在投影空间和图像空间均进行网络约束,同时还对残差图像进行校正。而且,在 DREAM-Net 中,用于平衡不同项权重的超参数均隐藏到了深度神经网络中,不再需要显式地学习或者经验调整。最后,DREAM-Net 采用的基础网络模块是高效的轻量级 U-Net 结构,这有助于使用更少的迭代达到更优的性能,从而节省计算资源。本章相关研究成果已发表在《IEEE Journal of Biomedical and Health Informatics》期刊。

本章 3.1 节简要介绍了参考的 ACID 算法框架;3.2 节详细讲解了基于双域网络正则的稀疏角度 CT 深度迭代重建算法的推导过程、网络架构和关键组件;3.3 节对实验设置进行了详细说明并展示了不同算法在模拟数据集和真实数据集上的对比结果,然后通过消融实验探究了不同模块和模型大小的对算法重建性能影响以及不同迭代模块的作用,最后对不同算法的复杂度进行了对比分析;3.4 节总结本章工作并讨论了当前研究的局限性。

3.1 ACID 算法

对于 CT 成像，其正向投影过程可以描述为：

$$b = Ax + \varepsilon \quad (3.1)$$

其中， b 是测量的投影数据； ε 是投影噪声； A 为系统矩阵。在稀疏采样条件下，式(3.1)中描述的问题严重不适定，直接估计未知图像 x 是十分困难的。

通常，可以通过最小化以下目标函数获得 x 的一个解 x^* ：

$$x^* = \underset{x}{\operatorname{argmin}} \mathcal{D}(x, b) + \lambda \mathcal{R}(x) \quad (3.2)$$

其中， $\mathcal{D}(x, b)$ 是保真项； $\mathcal{R}(x)$ 是正则项； λ 是平衡保真项和正则项的超参数。很多成熟的算法，比如 ASD-POCS (Adaptive Steepest Descent, Projection Onto Convex Sets^[165]), ISTA (Iterative Shrinkage/Thresholding Algorithm^[158, 177]), ADMM (Alternating Direction Method of Multipliers^[178]) and PDHG (Primal-Dual Hybrid Gradient^[179])可以用来求解式(3.2)中描述的优化问题。

最近，为了解决深度学习驱动的图像重建中存在的不稳定问题，ACID 算法^[121, 122]被提出，随之被提出的还有一种新颖的迭代重建框架，其优化目标如下：

$$\underset{y, x}{\operatorname{argmin}} \frac{1}{2} \|\Phi(A_s x + y) - x\|_2^2 + \frac{\lambda}{2} \|A_s x + y - b\|_2^2 + \frac{\mu}{2} \|y\|_2^2 + \xi \|\mathcal{H}x\|_1 \quad (3.3)$$

其中， $\Phi(\cdot)$ 是一个训练好的深度神经网络，可以将投影数据映射为图像矩阵； A_s 是具体的稀疏采样矩阵； y 是投影误差； b 是测量数据； $\mathcal{H}$ 表示稀疏变换； λ 、 μ 和 ξ 是不同项的权重系数。ACID 可以通过交替更新如下步骤实现精确而稳定的重建^[122]：

$$y^t = \frac{\lambda(A_s x^{t-1} - b)}{1 + \lambda + \mu} \quad (3.4)$$

$$x^t = \mathcal{H}^* S_\theta \left(\mathcal{H} \left(x^{t-1} + \frac{1 + \mu}{\lambda} \Phi(y^t) \right) \right) \quad (3.5)$$

y^t 和 x^t 分别是第 t 次迭代中的投影误差和估计的图像； $\mathcal{H}^*$ 是 $\mathcal{H}$ 的伴随矩阵； $S_\theta(\cdot)$ 是软阈值函数，其中 $\theta = \xi/\lambda$ 。

鉴于 ACID 在对抗扰动方面表现出了优异性能，本研究将其用于稀疏角度 CT 重建。同时，受到已有的深度迭代重建算法^[104, 105, 108, 171]的启发，本研究将 ACID 算法展开到深度学习框架中，并采用渐进改进的策略设计 DREAM-Net，以协同迭代重建和深度学习的优势。

3.2 基于双域网络正则的稀疏角度 CT 深度迭代重建算法

本研究提出的 DREAM-Net 通过迭代更新以下步骤来求解公(3.3)中的优化问题：

$$p^t = \varphi_t(A_f x^{t-1}, \Theta_{\varphi_t}) \oplus b \quad (3.6)$$

$$r^t = \psi_t(A_f^T(A_f x^{t-1} - p^t), \Theta_{\psi_t}) \quad (3.7)$$

$$x^t = \phi_t(x^{t-1} + r^t, \Theta_{\phi_t}) \quad (3.8)$$

其中， p^t 是估计的全角度投影数据； r^t 是校正后的残差图像； x^t 是增强后的图像；

$\varphi_t(\cdot, \Theta_{\varphi_t})$ 、 $\psi_t(\cdot, \Theta_{\psi_t})$ 和 $\phi_t(\cdot, \Theta_{\phi_t})$ 是不同的深度神经网络， Θ_{φ_t} 、 Θ_{ψ_t} 和 Θ_{ϕ_t} 是相应的可训练参数； A_f 是具体的全采样矩阵； $\oplus$ 是一个根据给定索引进行重写的算子； b 是测量数据。具体地， $p_o = p \oplus b$ 可以定义为：

$$p_o(i) = \begin{cases} b \left(\frac{i-1}{M/N} + 1 \right), & \text{if } (i-1) \bmod (M/N) = 0 \\ p(i), & \text{else} \end{cases} \quad (3.9)$$

其中， i 表示第 i 个角度的投影数据， $i = 1, 2, \dots, M$ ， M 是全扫描中采集的投影数目， N 是稀疏扫描中采集的投影数目（为方便表述，假设 M/N 始终为正整数）。




图 3-1 基于双域网络正则的稀疏角度 CT 深度迭代重建算法原理图。(a) DREAM-Net 的整体结构，DREAM-Net 由多个迭代块构成，每个迭代块包含三个级联的模块：投影补全（PI: Projection Inpainting）、残差感知（RA: Residual Awareness）和图像增强（IR: Image Refinement）；(b) 投影补全模块中深度神经网络 $\varphi_t(\cdot)$ 的具体结构；(c) 残差感知模块和图像增强模块中深度神经网络 $\psi_t(\cdot)$ 和 $\phi_t(\cdot)$ 的具体结构。请注意 $\psi_t(\cdot)$ 和 $\phi_t(\cdot)$ 是两个完全独立的网络，只是具有相同的结构，但其输入、输出和训练目标均不相同，参数也并不共享。

本章提出的基于双域网络正则的稀疏角度 CT 深度迭代重建算法原理如图 3-1 所示。与式(3.6)-(3.8)描述的三个更新步骤相对应，DREAM-Net 的每个迭代块由三个级联的模块组成，即投影补全（PI: Projection Inpainting）、残差感知（RA: Residual Awareness）和图像增强（IR: Image Refinement）。投影补全作为一种非标准的数据保真项，以有监督的方式提高投影一致性。残差感知旨在对上一时刻图像的残留误差进行精确估计。图像增强通过一个基于深度神经网络的正则化器进一步微调当前时刻的图像。迭代地更新

上述三个步骤，提出的 DREAM-Net 有潜力能够实现高质量的稀疏角度 CT 重建。下面将通过渐进改进的方式详细讲解 DREAM-Net 的设计原理。

3.2.1 图像增强

尽管 AICD 算法在对抗扰动方面展现出了优异的性能，但其沿用了传统的迭代重建框架，涉及的超参数仍需经验调整，整个重建过程也相对耗时。针对这个问题，本研究将 ACID 算法展开为深度迭代重建框架，使用基于深度神经网络的非标准正则项来替代基于压缩感知的约束项。先前的研究^[105, 171, 180]已经表明深度神经网络比人工设计的正则项更具竞争力。具体地，一个具有解码器-编码器结构的深度神经网络模块 $\phi_t(\cdot)$ 用来替代式(3.5)中基于压缩感知的约束 $\mathcal{H}^*S_\theta(\mathcal{H}(\cdot))$ 。同时，使用可学习的标量 λ^t 和 μ^t 来平衡不同项的权重。式(3.5)中相应的更新公式转化为：

$$x^t = \phi^t \left(x^{t-1} + \frac{1 + \mu^t}{\lambda^t} \Phi(y^t), \Theta_{\phi_t} \right) \quad (3.10)$$

在式(3.10)中，ACID 被展开为深度迭代重建算法。此时，展开模型是 DREAM-Net 的一个降级版本，它包含式(3.10)中定义的图像增强模块和式(3.4)中定义的投影误差计算操作。请注意，(3.10)中用以平衡不同项权重的标量 $(1 + \mu^t)/\lambda^t$ 是冗余的，在残差感知模块中将被隐藏到深度神经网络中。

3.2.2 残差感知

在式(3.5)中，ACID 使用一个深度神经网络 $\Phi(\cdot)$ 将式(3.4)计算的投影误差 y^t 映射到图像空间。然而，在 ACID 的推导中，仅假设 $\Phi(\cdot)$ 的相对误差是有界的。换言之，重建的误差图像 $\Phi(y^t)$ 可能是不准确的。因此，另一个深度神经网络模块 $\psi_t(\cdot)$ 用来估计准确的残差图像。将投影误差计算操作考虑在内后，残差感知模块转换为：

$$r^t = \psi_t \left(A_s^T \frac{\lambda^t (A_s x^{t-1} - b)}{1 + \lambda^t + \mu^t}, \Theta_{\psi_t} \right) \quad (3.11)$$

其中， $\psi_t(A_s^T(\cdot), \Theta_{\psi_t})$ 作为对 $\Phi(\cdot)$ 的一个更优替代。另外，由于式(3.11)中的 $\lambda^t/(1 + \lambda^t + \mu^t)$ 和式(3.10)中的 $(1 + \mu^t)/\lambda^t$ 在每个具体时刻的迭代中是固定的标量，可以直接通过 $\psi_t(\cdot)$ 学习到，因此可以省略，即式(3.11)转换为：

$$r^t = \psi_t(A_s^T(A_s x^{t-1} - b), \Theta_{\psi_t}) \quad (3.12)$$

请注意，式(3.12)是式(3.7)不包含投影补全模块的一个退化版本。使用 r^t 替换 $\frac{1 + \mu^t}{\lambda^t} \Phi(y^t)$ 项，即可通过式(3.10)得到最终的图像增强模块的更新公式(3.8)。

3.2.3 投影补全

先前工作^[76, 146, 181, 182]表明，在不完备采样条件下，投影预处理在提升重建性能方面具有极大的潜力。因此，本研究将投影补全集成到深度迭代重建框架中，作为一个非标准的数据保真项。如式(3.6)所示，在对前一时刻的图像 x^{t-1} 进行全采样正投影后，一个深度神经网络模块 $\varphi_t(\cdot)$ 用于提高投影的一致性。同时，采用一个重写算子 $\oplus$ 将深度神经网络恢复的投影 $\varphi_t(A_f x^{t-1}, \Theta_{\varphi_t})$ 中对应的部分用可采集到的稀疏投影 b 替换。因为测量

数据 b 是绝对准确的，替换后既可以保证投影数据中可采集到的部分是准确的，还能够一定程度上恢复投影数据中缺失部分的信息。理想状态下，式(3.6)得到的 p^t 是对全角度投影数据的一个精确估计。在引入投影补全模块并使用全采样投影和反投影算子 A_f 和 A_f^T 替换掉相应的稀疏投影和反投影算子 A_s 和 A_s^T 后，式(3.12)中描述的残差感知模块便转化为式(3.7)中的形式。

3.2.4 网络结构

考虑到计算负载，轻量且高效的基础网络模型是展开迭代重建算法的最佳选择。UNet^[183]及其变体在各种医学应用中表现出了有前景的性能，如去噪、配准、重建、检测、分割、超分辨率以及医学图像合成。因此，由 UNet 改进而来的深度神经网络用于 DREAM-Net 中的三个模块，如图 3-1 (b)和(c)所示。具体来说，将原始的 UNet 简化为轻量级版本，并引入残差块^[160]，以避免梯度消失使网络训练更加稳定。图 3-1 (b)中的 PD-Net (Projection Domain Network) 是投影补全模块中 $\varphi_t(\cdot)$ 网络的具体结构，图 3-1 (c)中的 ID-Net (Image Domain Network) 是残差感知模块和图像增强模块中 $\psi(\cdot)$ 和 $\phi_t(\cdot)$ 网络的具体结构。但是请注意， $\psi(\cdot)$ 和 $\phi_t(\cdot)$ 网络仅具有相同的结构但并不共享参数，因为这两个网络具有不同的训练目标。投影补全模块中的 $\varphi_t(\cdot)$ 网络以前一次迭代结果的全采样投影 $A_f x^{t-1}$ 为输入，训练目标是全角度投影数据。残差感知模块中的 $\psi(\cdot)$ 网络以误差图像 $A_f^T(A_f x^{t-1} - p^t)$ 作为输入，尝试预测出更精确的残差图像。图像增强模块中的 $\phi_t(\cdot)$ 网络进一步微调中间图像 $(x^{t-1} + r^t)$ 并输出当前时刻的图像 x^t 。为了避免在重建图像中产生二次伪影，PD-Net 被设计成比 ID-Net 更深层的模型。为了加速网络的收敛，PD-Net 和 ID-Net 都采用了全局残差学习策略^[184]，即学习输入和相应训练标签之间的误差图像，而非直接估计标签图像。

3.2.5 损失函数

先前研究表明，合适的损失函数能够提升深度神经网络的表现^[65, 155]。因此，本研究为提出的 DREAM-Net 设计了一个复合的损失函数。首先，一个基于平均绝对误差 MAE 的损失项用于约束投影补全模块以避免产生过度平滑的投影图像，因为 l_1 范数有助于产生尖锐的边缘^[158]；然后，一项 MAE 损失和一项基于结构相似性的 SSIM 损失用来约束图像增强模块以缩小重建的最终图像和参考图像之间的距离并提高二者之间的结构相似性。最终，复合的损失函数为：

$$\mathcal{L}_{com} = \sigma \cdot \mathcal{L}_{MAE}(p^n, p_{gt}) + \mathcal{L}_{MAE}(x^n, x_{gt}) + \beta \cdot \mathcal{L}_{SSIM}(x^n, x_{gt}) \quad (3.13)$$

其中， p^n 和 x^n 分别是第 n 次迭代中预测的投影和图像； p_{gt} 和 x_{gt} 是相应的全角度投影数据和高质量 CT 图像； σ 和 β 是两个平衡不同损失项的权重系数。

3.3 实验和结果

在本节中，首先利用模拟人体数据和真实小鼠数据来评估所提出的 DREAM-Net。除主观评估外，还进行了定量评价。定量指标包括平均绝对误差 MAE、结构相似性 SSIM

和峰值信噪比 PSNR。对比方法包括 FBP^[32]、FBPConvNet^[61]、CLEAR^[182]和 FISTA-Net^[104]等四种不同类型的算法。FBP 是常用的解析重建算法，用于观察稀疏采样导致的条纹伪影的带来的负面影响。FBPConvNet 是经典在图像域中抑制条纹伪影的后处理算法，使用的网络结构是 UNet。CLEAR 是本研究第二章中提出的投影-图像双域联合处理的低剂量 CT 重建算法，本章将其修改用于稀疏角度 CT 重建。FISTA-Net 是一种先进的用于稀疏角度 CT 的深度迭代重建算法。为了公平比较，FBPConvNet、CLEAR 和 FISTA-Net 均使用与 DREAM-Net 相同的数据进行训练，所有竞争方法的超参数均根据其原始论文进行调整。此外，本节还通过消融实验验证了 DREAM-Net 不同模块的有效性以及模型大小的影响，并探究了不同迭代块的作用。最后，对不同算法的复杂度进行了对比分析。实验在台式电脑（Ubuntu 20.04、i7-10700K 3.8GHz CPU、24GB Geforce RTX 3090 GPU、64GB RAM）上使用 Python 和 Pytorch 库实现。

3.3.1 模拟数据实验

3.3.1.1 数据集

模拟实验数据来源与 2.3.1 节相同。AAPM 数据按照 8:1:1 的比例随机划分为训练集（4776 层切片）、验证集（600 层切片）和测试集（560 层切片）。此外，测试时还使用了来自美国国家癌症研究所的 5 名匿名患者数据。采用表 2-1 描述的成像几何获得模拟的全投影数据，生成模拟投影时加入入射光子量为 1×10^6 的泊松噪声。不同稀疏角度的投影数据从全角度投影数据中抽取而来。

3.3.1.2 参数设置

如 3.2.2 节所述，在 DREAM-Net 中，用以平衡不同项权重的超参数均隐含到深度神经网络模块中，不需要显式地进行调整或学习。式(3.13)损失函数中的 σ 和 β 分别设置为 80 和 100，以保证不同损失项的值在相当的数量级。受限于可用的计算资源，DREAM-Net 中迭代块的数量设置为 3，批量大小设置为 2，PD-Net 和 ID-Net 卷积核初始数目设置为 32。采用默认的 Adam 优化器对提出的 DREAM-Net 训练 100 轮，学习率从 10^{-4} 逐步衰减至 10^{-6} 。本研究中，初始化图像 x_0 由 FBP 算法直接对稀疏投影重建获得，亦可使用其他算法（比如迭代重建、图像域网络等）预先处理以获得更好的初值。使用开源的 torch-radon 库^[162]提供的支持 GPU 加速的投影和反投影算子进行域变换。

3.3.1.3 重建结果

为充分评估不同方法的性能，本节对不同方法在稀疏投影数目 N 为 96、72 和 48（对应的全角度投影数目 M 设置为 576）等三种不同配置下的结果进行比较分析，其中轴状面结果如图 3-2 所示。从图 3-2 第 2 列中的结果可以看出，在稀疏采样配置下，直接使用 FBP 算法重建的图像中存在严重的条纹伪影。在图像空间进行处理，FBPConvNet 可以在一定程度上抑制伪影并恢复图像细节，但由于缺乏对数据一致性的约束，FBPConvNet 无法提供高保真的细节恢复。比如，图 3-2 (b3)中蓝色箭头指示的肝脏中的血管在参考图像(b1)中并不存在，图 3-2 (d3)中红色圆圈标记的骨骼存在失真，

图 3-2 (f3)中黄色箭头指示的肺部组织存在缺失。在引入投影空间恢复之后, CLEAR 的结果相对于 FBPCovNet 在结构保真度方面有明显改善, 如图 3-2 (b4)、(d4)和(f4)中黄色箭头所示。将深度学习和迭代重建相结合, FISTA-Net 和 DREAM-Net 在微小特征恢复上更有潜力; 同其他算法相比, 图 3-2 (b5)和(b6)中黄色箭头指示的肝脏中血管以及(e5)和(e6)中黄色椭圆标记的肌肉组织与参考图像更加接近。不过, 从图 3-2 (b5)和(d5)中 ROI 的放大图观察到, FISTA-Net 重建的结果中存在轻微的块状伪影。




图 3-2 不同方法在稀疏投影数目 N 为 96、72 和 48 三种不同配置下的轴状面结果。第 1 列为使用全角度投影通过 FBP 算法重建的参考图像; 第 2-6 列分别为 FBP、FBPCovNet、CLEAR、FISTA-Net 和 DREAM-Net 算法在不同稀疏扫描配置下重建/处理的结果。黄色方框标记的 ROI 放大在相应图像的下方。腹部图像显示窗口为 $[-300, 300]$ HU; 肺部图像显示窗口为 $[-1150, 350]$ HU。

图 3-3 展示了不同方法在三种稀疏采样配置下的冠状面结果。在稀疏投影数目 $N=96$ 时, 不同方法的结果都相对较好, 图 3-3 (b3)-(b6)中展示的血管树和参考结果均比较接近。不过, 在 FBPCovNet 处理的结果中, 肝脏血管有轻微失真, 如图 3-3 (b3)中红色箭头所示。另外, 从(b5)和(b6)中黄色箭头标记的区域可以观察到, 与其他方法相比,

FISTA-Net 和 DREAM-Net 重建的血管末端和参考图像更加一致。在稀疏投影数目 $N=72$ 时, FBPCnvNet 恢复的图像虽然没有条纹伪影残留, 但是存在一定程度的失真, 如图 3-3 (d3) 中红色箭头所示。在引入数据保真之后, CLEAR、FISTA-Net 和 DREAM-Net 在细节恢复方面相对于 FBPCnvNet 均有不同程度的改进, 如图 3-3 (d3)-(d6) 中箭头所示。此外, 相比之下, 图 3-3 (d3)-(d6) 中黄色箭头处, FISTA-Net 和 DREAM-Net 的结果优于 CLEAR, 蓝色箭头处, CLEAR 和 DREAM-Net 的结果优于 FISTA-Net。在稀疏投影数目 $N=48$ 时, 由于投影信息缺失过多, 所有方法表现均不佳, 但是从图 3-3 (f3)-(f6) 中箭头和圆圈标记的区域可以看出, 同其他方法相比, DREAM-Net 重建的图像的细节和参考图像更加一致。




图 3-3 不同方法在稀疏投影数目 N 为 96、72 和 48 三种不同配置下的冠状面结果。第 1 列为使用全角度投影通过 FBP 算法重建的参考图像; 第 2-6 列分别为 FBP、FBPCnvNet、CLEAR、FISTA-Net 和 DREAM-Net 算法在不同稀疏扫描配置下重建/处理的结果。黄色方框标记的 ROI 放大在相应图像的下方。图像显示窗口为 $[-300, 300]$ HU。

图 3-4 是不同方法在三种稀疏采样配置下的矢状面结果。从第 3 列 ROI 的放大图可以观察到, FBPCnvNet 恢复的图像细节上存在不同程度的失真(如红色箭头所示), 在图 3-4 (b3)中, 一些伪影特征甚至被 FBPCnvNet 作为有用信息保留了下来。与 FBPCnvNet 相比, 图 3-4 第 4 列中 CLEAR 算法的结果在伪影抑制和细节恢复方面均有所改进, 但图像中的微小组织特征仍存在比较严重的畸变, 比如黄色箭头标记的血管以及蓝色箭头标记的肝脏病灶。相比之下, FISTA-Net 和 DREAM-Net 的结果更好, 特别是(b5)和(b6)中展示的这两种方法重建的肝脏病灶(蓝色箭头所示)和参考结果更加接近。进一步, 与 FIATA-Net 相比, DREAM-Net 的结果在细节上表现更好, 比如(b6)和(f6)中黄色箭头指示的血管, 以及(d6)中黄色圆圈标记的肾脏组织。




图 3-4 不同方法在稀疏投影数目 N 为 96、72 和 48 三种不同配置下的矢状面结果。第 1 列为使用全角度投影通过 FBP 算法重建的参考图像; 第 2-6 列分别为 FBP、FBPCnvNet、CLEAR、FISTA-Net 和 DREAM-Net 算法在不同稀疏扫描配置下重建/处理的结果。黄色方框标记的 ROI 放大在相应图像的下方。图像显示窗口为 $[-300, 300]$ HU。

表 3-1 统计了不同方法在三种稀疏采样配置下的定量结果。FBP 直接重建的图像受到条纹伪影的影响质量退化严重，不同稀疏采样配置下的结构相似性 SSIM、峰值信噪比 PSNR 和平均绝对误差 MAE 均比较低。FBPConvNet 可以很大程度地提高 SSIM、PSNR 和 MAE 分数，但是从图 3-2 至图 3-4 中的可视化结果发现，FBPConvNet 并不能提供可信的图像。通过在投影空间和图像空间联合优化，本研究第二章中提出的 CLEAR 方法可以进一步提高图像的质量，表 3-1 中没有引入对抗学习机制的 CLEAR 算法（CLEAR w/o GAN）相比于仅在图像空间恢复的 FBPConvNet 有较大提升，这表明了 CLEAR 算法在稀疏角度 CT 重建任务上的潜力。引入对抗学习机制后，CLEAR 算法结果的量化分数有所下降，这一现象在本研究第二章 2.3 节中已经讨论，本节不再赘述。图 3-2 至图 3-4 中的结果表明，相比于其他方法，CLEAR 重建的图像没有出现过度平滑的现象，且在细节恢复和伪影移除方面优于 FBPConvNet。融合了深度学习和迭代重建的优势，FISTA-Net 和 DREAM-Net 的定量结果比其他方法更好。得益于投影补全、残差感知和图像增强三个模块的协同效果，DREAM-Net 在三种稀疏采样配置下的各项指标均优于 FISTA-Net。

表 3-1 三种稀疏采样配置下不同方法在模拟数据集上的定量结果

投影 数目	度量（单位）	FBP	FBPConvNet	CLEAR w/o GAN	CLEAR	FISTA-Net	DREAM-Net
N=96, M=576	SSIM (%)	67.72	96.22	97.96	97.37	98.38	98.49
	PSNR (dB)	28.32	38.38	40.16	39.34	41.77	42.07
	MAE (HU)	61.37	16.79	14.15	16.23	12.46	12.07
N=72, M=576	SSIM (%)	59.72	94.03	97.23	96.50	98.03	98.24
	PSNR (dB)	26.48	36.49	38.72	37.99	40.77	40.83
	MAE (HU)	74.62	19.75	16.29	18.35	13.52	13.06
N=48, M=576	SSIM (%)	49.99	91.18	95.40	93.93	96.63	96.98
	PSNR (dB)	24.18	34.14	35.75	35.38	37.58	38.01
	MAE (HU)	95.61	24.50	20.38	22.99	17.04	16.03

3.3.2 真实数据实验

3.3.2.1 数据集

真实小鼠数据通过图 3-5 所示的 Hiscan VM Micro-CT 系统^[185, 186]采集，该系统配备一个微焦点 X 射线管（L9421-02, Hamamatsu Photonics）和一块平板探测器（Dexela CMOS 1512, PerkinElmer）。X 射线管管电压范围为 20~90 kVp，管电流范围为 0~200 μ A，最大输出功率为 8 W，射线源微焦点尺寸为 5 μ m。探测器阵列为 1944 $\times$ 1536，动态范围为 0~16383。Hiscan VM Micro-CT 系统是锥束成像几何，考虑到计算负载，本研究参考先前工作^[119, 146]将三维锥束投影重排为二维扇束投影。扇束 CT 成像几何设置如下：光源-探测器距离和光源-旋转中心距离分别为 172.14 mm 和 86.07 mm；探测器矩阵尺寸为

963×1 ; 探测器单元尺寸为 $0.1 \times 1.0 \text{ mm}^2$; 图像矩阵尺寸为 512×512 ; 图像像素尺寸为 $75 \times 75 \text{ }\mu\text{m}^2$; 全扫描角度范围为 $(0^\circ, 360^\circ]$, 采集投影数目为 600。从全投影数据中抽取对应角度的数据作为稀疏角度投影。采集的 5 只小鼠数据按照 3:1:1 的比例随机分为训练集 (3 只, 180 层切片)、验证集 (1 只, 60 层切片) 和测试集 (1 只, 60 层切片)。为了缓解训练样本不足的问题, 通过三次间隔为 90° 的旋转将训练集增加到 720 层切片。



图 3-5 Hiscan VM Micro-CT 系统

3.3.2.2 参数设置

在小鼠数据实验中, 参数设置和模拟实验相同。具体地, 损失函数中的 σ 和 β 为 80 和 100; DREAM-Net 中迭代块的数量为 3, PD-Net 和 ID-Net 初始通道数为 32; 采用默认 Adam 优化器训练 100 轮, 批大小设置为 2, 学习率初始为 10^{-4} 且每轮衰减 1%。FBP 算法直接重建的图像作为 x_0 。由于真实小鼠数据训练样本较少, 因此先使用 AAPM 数据进行预训练, 然后再使用真实小鼠数据微调; 此外, 为了防止过拟合, 训练时采用 mixup 技术^[187]进行在线数据扩充。

3.3.2.3 重建结果

稀疏投影数目 N 为 100、75 和 50 (全角度投影数目 M 设置为 600) 的三种不同采样配置用来评估不同方法在真实场景中的性能, 结果如图 3-6 所示。可以看出, 不同方法在真实小鼠数据上的性能均有所下降, 主要原因是训练样本较少, 尽管通过数据扩充后有 720 组训练数据, 但原始训练样本仅有 180 组, 这对数据驱动的方法是很大的挑战。FBPConvNet 作为一种图像后处理类算法, 具有良好的泛化性, 从图 3-6 第 3 列中的结果可以看出, 尽管 FBPConvNet 处理后的图像无法保持精确的图像细节, 但是几乎没有引入其他伪影, 不过在稀疏投影数目 $N=50$ 时, FBPConvNet 无法有效抑制伪影, 如图 3-6 (e3) 红色箭头所示, 放置小鼠的容器壁存在明显形变。相比之下, CLEAR 作为一个三维模型, 对训练数据的需求量比较大, 在数据缺乏时性能下降更加明显, 从图 3-6 第 4 列中 ROI 的放大图可以观察到, CLEAR 重建的结果存在着明显的二次伪影。由于融入了模型知识, FISTA-Net 在稀疏投影数目为 100 和 75 时表现较好, 但在稀疏投影数目 $N=50$ 的情况下, FISTA-Net 重建的结果受到二次伪影的影响, 图 3-6 (f5) 红色箭头指示的平滑软组织区域出现了坑洼不平的伪影。从图 3-6 第 6 列中的结果可以观察到,

DREAM-Net 重建的结果也丢失了一些信息，但是通过对比图 3-6 中多处黄色箭头标记可以看出，相比于其他方法，提出的 DREAM-Net 重建的图像中细节特征恢复得更好。而且，DREAM-Net 没有因为缺乏训练数据导致明显的二次伪影。因此，整体上看，在训练样本较少的真实场景中，DREAM-Net 也表现得更有潜力。




图 3-6 稀疏投影数目 N 分别为 100、75 和 50 时，不同方法在真实小鼠数据集上结果。第 1 列为使用全角度投影通过 FBP 算法重建的参考图像；第 2-6 列分别为 FBP、FBPCConvNet、CLEAR、FISTA-Net 和 DREAM-Net 算法在不同稀疏扫描配置下重建/处理的结果。黄色方框标记的 ROI 放大在相应图像的下方。图像显示窗口为 $[100, 500]$ HU。

表 3-2 统计了三种稀疏采样配置下不同方法在真实小鼠数据集上的定量结果。可以看出，尽管优势较小，但在三种不同稀疏配置下，相比于其他方法，本章提出的 DREAM-Net 算法重建的小鼠 CT 图像的平均绝对误差 MAE 更小，结构相似性 SSIM 和峰值信噪比 PSNR 更高，这也与视觉评估的结果一致。

表 3-2 三种稀疏采样配置下不同方法在真实小鼠数据集上的定量结果

投影 数目	度量（单位）	FBP	FBPConvNet	CLEAR	FISTA-Net	DREAM-Net
N=100, M=600	MAE (HU)	26.53	9.71	9.49	9.36	9.28
	SSIM (%)	75.01	95.01	95.41	95.50	95.63
	PSNR (dB)	28.33	36.79	37.00	37.23	37.31
N=75, M=600	MAE (HU)	32.32	9.96	9.86	9.74	9.66
	SSIM (%)	68.28	94.69	94.95	95.01	95.17
	PSNR (dB)	26.62	36.51	36.59	36.83	36.89
N=50, M=600	MAE (HU)	42.02	10.82	10.60	10.42	10.30
	SSIM (%)	59.09	93.63	93.99	94.09	94.32
	PSNR (dB)	24.36	35.57	35.65	36.13	36.15

3.3.3 消融实验

3.3.3.1 不同模块的影响

投影补全、残差感知和图像增强是 DREAM-Net 中三个关键的模块，本节通过消融实验来探究不同模块的影响。首先需要说明的是，尽管 DREAM-Net 由 ACID 算法衍生而来，但是消融研究并没有将其纳入对比。本研究的目的是开发一种更有潜力的深度迭代重建算法，但 ACID 的目标并不是设计一种性能更好的网络模型，而是缓解深度神经网络 $\Phi(\cdot)$ 的不稳定性。ACID 并不关注 $\Phi(\cdot)$ 本身的架构和表现如何，旨在使其能够对抗扰动。也就是说，当 DREAM-Net 在处理添加了扰动的数据而性能下降时，可以进一步采用 ACID 框架来稳定其表现。本研究使用的数据并不考虑扰动，因此将 ACID 算法纳入消融实验没有意义。在本章 3.2 节中，采用渐进改进的策略逐步引入了三个深度神经网络在图像空间、残差空间和投影空间进行约束，最终构建了 DREAM-Net。本节遵循 DREAM-Net 的构建过程，逐步探索不同空间约束带来的增益效果。

集成不同模块的三种模型在验证集上的结果如图 3-7 所示。观察图 3-7 (a2)-(d2)黄色箭头指示区域可以发现，仅包含图像增强模块的模型重建的肝脏血管辨识度较低，在增加残差感知模块后，其辨识度有所提升，进一步集成投影补全模块后，黄色箭头标记的肝脏血管可以清晰辨识。此外，对比图 3-7 (a4)-(d4)中黄色圆圈标记的区域发现，(d4)中的图像细节和参考图像更加接近，表明协同投影补全、残差感知和图像增强三个模块更有潜力实现高质量的重建。

不同空间网络约束对重建结果影响的定量比较统计在表 3-3 中。可以发现，仅在图像空间进行约束的模型重建的图像的平均绝对误差 MAE 最大，结构相似性 SSIM 和峰值信噪比 PSNR 最低。在增加了残差空间的约束之后，各项指标均有轻微程度改进。同时在图像空间、残差空间和投影空间进行约束的模型能够取得更好的分数，MAE、SSIM 和 PSNR 分别达到了 15.07 HU、97.84%和 41.93 dB。




图 3-7 不同模型在验证集上的结果。黄色方框标记的 ROI 放大在相应图像的下方。IR：图像增强；RA：残差感知；PI：投影补全。图像显示窗口为[-300, 300] HU。

表 3-3 不同空间网络约束对重建结果影响的定量比较

模型	图像空间	残差空间	投影空间	MAE (HU)	SSIM (%)	PSNR (dB)
IR	✓	×	×	15.80	97.62	41.50
IR+RA	✓	✓	×	15.59	97.68	41.61
IR+RA+PI	✓	✓	✓	15.07	97.84	41.93

3.3.3.2 模型大小的影响

DREAM-Net 模型大小主要由两个因素决定，一个是迭代块的数量，另一个是基础网络 PD-Net 和 ID-Net 的规模，在结构确定的情况下，PD-Net 和 ID-Net 模型的大小主要由卷积核的数目决定。本节中，首先将 PD-Net 和 ID-Net 的卷积核初始数目设置为 32 来探究迭代块数量的影响，然后在迭代块数量固定为 3 的情况下，探究 PD-Net 和 ID-Net 的卷积核数目的影响。在 1/8 稀疏采样配置下 (M=576, N=72) 进行实验，使用模拟数据以排除真实场景中不确定因素的干扰，在验证集上计算的平均绝对误差 MAE 和结构相似性 SSIM 用来评估不同模型的性能。不同参数配置下 DREAM-Net 模型大小统计在表 3-4 中，可见迭代块数量或卷积核数目的增加均会导致 DREAM-Net 模型尺寸和计算量的增加。不同参数配置下 DREAM-Net 的性能的量化结果总结在图 3-8 中。从

图 3-8 (a)可以看出, 在 PD-Net 和 ID-Net 卷积核初始数目为 32 的情况下, 当迭代块的数量大于 4 之后 DREAM-Net 的性能不再有明显的上升趋势; 从图 3-8 (b)可以看出, 在迭代块的数量固定为 3 的情况下, 当 PD-Net 和 ID-Net 卷积核初始数目大于 32 后 DREAM-Net 的性能不再有明显的上升趋势。本研究中, 受限于可用的计算资源, 在权衡模型性能和计算负载之后, 最终确定 PD-Net 和 ID-Net 卷积核初始数目为 32, 迭代块的数量为 3。

表 3-4 迭代块数量和卷积核数目对 DREAM-Net 模型大小的影响

迭代块数量	2		3		4		5		6		7							
浮点运算次数（G）	254.98		382.58		510.26		638.02		765.85		893.76							
参数量（M）	5.31		7.97		10.63		13.29		15.95		18.61							
卷积核初始数目	8		12		16		20		24		28		32		36		40	
浮点运算次数（G）	24.16		54.12		95.98		149.76		215.46		293.07		382.58		484.02		597.37	
参数量（M）	0.50		1.12		2.00		3.12		4.49		6.11		7.97		10.09		12.46	




图 3-8 迭代块数量和卷积核数目对 DREAM-Net 性能的影响。

3.3.3.3 不同迭代的结果

本节对 DREAM-Net 中三个迭代块的作用进行了探究。图 3-9 展示了 1/8 稀疏采样配置下 ($M=576$, $N=72$) DREAM-Net 在验证集上不同迭代的结果。从图 3-9 中放大的

ROI 可以观察到, 黄色箭头标记的被条纹伪影湮没的血管随着迭代加深逐步恢复。从表 3-5 中不同迭代的定量结果可以看出, 相比于初始化图像 x_0 , x_1 的图像质量大幅度提升, x_2 和 x_3 的图像质量在前一次迭代的基础上均有小幅度的改进。综合视觉评估和定量比较的结果可以发现, DREAM-Net 的第 1 次迭代可以有效移除稀疏采样导致的条纹伪影并恢复图像的整体结构, 大幅提升图像质量, 第 2 次和第 3 次迭代对前一次迭代的结果微调并逐步复原被条纹伪影湮没的微小组织结构, 比如血管。




图 3-9 不同迭代的结果。显示窗口为[-300, 300] HU。

表 3-5 不同迭代结果的定量比较

图像	x_0	x_1	x_2	x_3
MAE (HU)	81.65	18.72	15.72	15.07
SSIM (%)	61.88	96.72	97.67	97.84
PSNR (dB)	27.63	39.7	41.52	41.93

3.3.4 算法复杂性分析

算法的复杂性分析对算法的设计或选用具有重要的指导意义, 是算法实际部署时十分关注的指标。本节中, 分别采用浮点运算次数 (Floating Point Operations)、参数量

(Parameters) 和吞吐量 (Throughput) 来衡量算法的运算量、模型大小以及运行效率, 对涉及的不同算法的复杂性进行对比分析。表 3-6 统计了 1/8 稀疏采样配置下 ($M=576$, $N=72$) 不同算法处理模拟数据的情况。不同算法按运算量升序排列依次是: FBPCConvNet、DREAM-Net、FISTA-Net 和 CLEAR。CLEAR 使用的是简化后的轻量级三维模型, 参数量比 FBPCConvNet 使用的二维模型都少, 但由于其同时在投影域和图像域进行网络处理且进行在线重建, 故而运算量较大, 运行效率也较低。FBPCConvNet 虽然使用的模型最大, 但其仅在图像域恢复, 因而运算量较小, 且运行效率最高。FISTA-Net 使用的模型十分简单, 参数仅有 0.15 M, 但其整个重建过程包括 7 次迭代, 重复的投影和反投影操作导致了较大的运算量; 不过, 得益于其简单的架构 (仅在图像空间进行约束) 以及轻量级的基础模型, FISTA-Net 的运行效率也比较高。相对于 FISTA-Net, DREAM-Net 每个迭代块更加高效, 因而仅使用 3 个迭代块便可以实现优于 FISTA-Net 的性能, 更少的迭代次数也导致了 DREAM-Net 具有更少的运算量; 但是, 由于 DREAM-Net 结构较为复杂 (同时在投影空间、图像空间和残差空间进行约束) 且使用的基础模型参数更多, 其运行效率略低于 FISTA-Net。不过, 在临床实践中, DREAM-Net 每秒 15 帧图像的处理速度也是十分高效的, 牺牲一些算法效率而实现更优的重建性能是可以接受的。综合来看, DREAM-Net 在重建精度和算法复杂性之间具有更好的平衡。

表 3-6 不同方法的算法复杂性比较 (G: Giga, M: Million)。加粗: 最优结果, 下划线: 次优结果

度量 (单位)	FBPCConvNet	CLEAR	FISTA-Net	DREAM-Net
浮点运算次数 (G)	232.67	1396.05	815.98	<u>382.58</u>
参数量 (M)	31.43	17.53	0.15	<u>7.97</u>
吞吐量 (帧/秒)	39	11	<u>23</u>	15

3.4 本章小结

对于 3D 血管成像等每个投影角度均需长时间曝光的应用, 稀疏角度 CT 扫描在降低辐射剂量和缩短采集时间方面具有极大的潜力, 此外在 4D CBCT 等一些特殊场景下, 周期性的呼吸和心跳不可避免地导致不同运动相位下的投影数据是稀疏的。为了抑制稀疏采样导致的条纹伪影, 本章将深度学习强大的表征能力和迭代算法模型相结合, 提出了基于双域网络正则的深度迭代重建网络 DREAM-Net。DREAM-Net 由多个展开的迭代块组成, 每个迭代块包含三个级联的子模块, 分别是投影补全、残差感知和图像增强, 每个模块负责一项特定任务。投影补全和图像增强分别在投影空间和图像空间施加非标准的网络正则化, 以提高数据一致性和提升图像质量, 残差感知尝试从传统误差图像中估计出更加准确的残差特征。消融研究表明: (1) 协同上述三个模块的作用可以实现更优的重建性能; (2) DREAM-Net 的浅层迭代主要作用是移除条纹伪影并恢复整体结构, 深层迭代的主要作用是复原微小组织特征。在模拟人体数据和真实小鼠数据上的视觉评估和定量结果均表明了 DREAM-Net 相对于同类方法的优势。

为了不失一般性, 本章提出深度迭代重建算法没有限定应用场景, 理论上可以推广

到 CT 的其他应用中, 比如降噪和有限角度重建。受限于可用的计算资源, 本研究中仅使用了二维扇束几何来验证提出的算法, 而在临床实践中, 通常使用三维的螺旋或锥束成像几何, 巨大的计算负载是亟需解决的问题^[121]。一种解决方案是参考先前研究^[119, 146]将三维的螺旋或锥束投影数据重排成二维的扇束投影数据, 将三维重建问题解耦为二维重建问题, 本研究 3.3.2 节采用的正是这一方案。另一种解决方案是使用支持 GPU 加速的且兼容反向传播算法的投影和反投影算子进行域变换。开源的 ODL 库 (Operator Discretization Library, <https://github.com/odlgroup/odl>) 让在深度学习框架中使用三维成像几何成为可能。目前, 展开迭代重建算法在三维成像中的初步应用也已有研究报道^[188]。

此外, ACID 指出了深度神经网络在稀疏正则化表示 (如图像梯度 l_0 范数) 方面的局限性, 且不建议使用展开版本, 一个主要原因是展开 ACID 将使其失去对抗扰动的能力。然而, 所提出的 DREAM-Net 并不是为了稳定深度层析重建而开发的, 而是为了实现高质量的稀疏角度 CT 重建。因此, 展开迭代重建框架在本研究中是可行的。

本研究的另一个局限在于, 提出的 DREAM-Net 是一种有监督的方法, 通过训练使网络的输出与标签图像 (高质量 CT 图像) 之间的距离最小化。然而, 在某些场景中, 比如 4D CBCT, 无法得到作为标签数据的高质量 CT 图像。直接使用模拟数据训练的模型来重建真实数据效果不佳, 如何缩小模拟数据与真实数据之间分布的差异, 进而保证使用模拟数据训练的模型能够鲁棒地迁移到真实采集的数据上, 是需要进一步解决的问题。

最后, 从本章 3.3 节中模拟人体数据和真实小鼠数据上的实验结果可以看出, 尽管提出的 DREAM-Net 的表现相比于竞争方法更有潜力, 但单纯就结果而言, DREAM-Net 重建的图像仍然存在一定程度的信息丢失, 而且这种现象在投影数目较少时更加严重, 因此本章方法仍需进一步改进, 在 4D CBCT^[124, 189]和 DECT^[73, 74]等真实应用场景中, 还可以引入相应的先验图像来提升算法的性能, 以重建出误差更小的图像。

第四章 基于互补扫描的稀疏角度 DECT 双域优化重建

尽管 CT 广泛应用于多种疾病的筛查和诊断,但是普通 CT 存在一个固有局限,即无法对 CT 图像中 HU 值接近的物质进行区分。相比之下,双能 CT (Dual-Energy CT, DECT) 在两个不同的 X 射线能谱下采集衰减数据,具有区分不同物质的能力。特别是,DECT 能够在已知元素组成的混合物中对两种或三种材料的质量密度进行量化^[19]。这一优势使 DECT 在医学和工业实践中都越来越受欢迎。

DECT 的一个典型实现是西门子医疗使用的快速 kV 切换技术,该技术在两个预定 kV 之间频繁地快速交替切换 X 射线管电压。然而,这种技术的使用在实践中可能受到限制,因为实现快速 kV 切换需要复杂的硬件,这通常需要巨大成本^[189]。此外,频繁的电压切换的另一个缺点是管电流调制困难,这可能会降低剂量效率^[84]。一种可能的解决方案是降低采集过程中的电压切换频率,这有望降低技术成本及对专有硬件的依赖,从而使更多的患者从 DECT 技术中获益。然而,这种替代方案采集的双能数据是稀疏的,直接重建的 DECT 图像中存在严重的条纹伪影。

此外,X 射线辐射风险在 DECT 成像中同样也是备受关注的问题。不过,与普通 CT 不同,由于 DECT 图像是在不同的 X 射线能谱下对同一目标采集的,所以低能 CT 图像和高能 CT 图像虽然 CT 值不同但是解剖结构几乎是相同的,即低能 CT 图像和高能 CT 图像是密切相关的,如图 4-1 所示。而且,由于 Radon 变换的线性性质,DECT 不同能量通道数据之间的相关性不仅在图像空间存在,在投影空间也同样存在。这种冗余性可以用来放宽成像条件,进而降低累积的 X 射线照射剂量。




图 4-1 DECT 不同能量通道数据之间的相关性。(a) 低能 CT 图像;(b) 高能 CT 图像;(c) 低能 CT 图像与高能 CT 图像的差;(d)(e)(f)分别为提取的(a)(b)(c)的轮廓。低能 CT 图像和高能 CT 图像虽然 CT 值不同但是解剖结构几乎相同。

针对上述问题,本章结合 DECT 成像的特性,提出了基于慢速 kV 切换的互补稀疏扫描方案来降低 DECT 成像对高成本专有设备的依赖,并减少 DECT 成像过程中累积的 X 射线辐射剂量。然而,在稀疏扫描条件下,使用解析算法直接重建的 CT 图像中存

在严重的条纹伪影。为解决这一问题，本章进一步将第二章中的投影空间和图像空间联合处理的思想扩展到 DECT 中，提出稀疏角度 DECT 双域优化重建算法，协同投影空间信息恢复和图像空间伪影移除以实现高质量的 DECT 重建。投影空间子网络和图像空间子网络均采用针对 DECT 成像专门设计的双流 ResUNet 网络，其共享编码器（Shared Encoder）能够提取和利用双能数据之间的相关性，其低能解码器（Low-Energy Decoder）和高能解码器（High-Energy Decoder）可以有针对性地同步处理低能和高能通道数据，实现差别学习。本章相关研究成果已发表在《IEEE Transactions on Computational Imaging》期刊。

本章 4.1 节详细介绍了基于互补扫描的稀疏角度 DECT 双域优化重建的算法框架、优化目标和关键组件；4.2 节对使用的数据集以及采用的数据预处理措施进行说明；4.3 节首先通过消融实验探究了不同空间信息对最终重建结果的影响，然后对比分析了不同方法的重建结果和材料分解结果；4.4 节总结并对当前工作存在的一些问题进行讨论。

4.1 基于互补扫描的稀疏角度 DECT 双域优化重建算法

本章在 DECT 稀疏角度互补扫描的基础上，进一步使用开发的双域深度神经网络 CD-Net（Comprehensive-Domain Network）提取并利用高低能数据之间的相关性同时在投影空间和图像空间进行恢复以实现高质量重建。具体如下：

4.1.1 互补稀疏采样




图 4-2 基于互补扫描的 DECT 稀疏采样方案，橙色和蓝色圆弧分别代表高能和低能采样轨迹。

相比于普通 CT，DECT 成像中低能和高能通道中的数据是密切相关的，基于此，本章建议通过基于互补扫描的 DECT 稀疏采样方案来降低高低能电压切换的频率，减少 X 射线辐射剂量并尽可能多地采集被扫描目标的信息。该方案示意图如图 4-2 所示，高能和低能采样点在圆形轨迹上均匀交替分布。

假设一次全角度扫描共采集 M 个投影, 一次稀疏扫描采集 N 个投影(为方便描述, 令 M/N 始终为正偶数), 则双能稀疏投影和对应的全角度投影之间的关系为:

$$P_S^L(i) = P_F^L\left((i-1) \cdot \frac{M}{N} + 1\right), i = 1, 2, 3, \dots, N. \quad (4.1)$$

$$P_S^H(i) = P_F^H\left(\left(i - \frac{1}{2}\right) \cdot \frac{M}{N} + 1\right), i = 1, 2, 3, \dots, N. \quad (4.2)$$

其中, P_S^L 和 P_S^H 分别为低能稀疏投影和高能稀疏投影; P_F^L 和 P_F^H 分别为相应的低能全角度投影和高能全角度投影; i 表示第 i 个角度的投影。

4.1.2 双域优化重建

通过在投影域和图像域引入相应的伪影组件, 可以将稀疏角度 CT 重建问题转化为对投影空间和图像空间相应的伪影成分的估计问题:

$$I_{Ref} = \mathcal{R}^{-1}(P_{SI} - P_A) = I_S - I_A \quad (4.3)$$

其中, I_{Ref} 是高质量 CT 图像; P_{SI} 为插值后的投影; I_S 是使用解析算法重建的稀疏角度 CT 图像; P_A 和 I_A 分别为投影空间和图像空间伪影图像; $\mathcal{R}^{-1}$ 为逆 Radon 变换。

理论上, 只要能够精准估计出投影空间伪影成分 P_A 或者图像空间伪影成分 I_A , 就可以通过式(4.3)获得期望的高质量 CT 图像 I_{Ref} 。然而, 受限于当前技术水平, 无法保证估计的投影空间伪影成分 P_A 或图像空间伪影成分 I_A 是完全精确的。针对这个问题, 本章提出以投影空间和图像空间联合处理的策略进行稀疏角度 DECT 重建, 可以描述为:

$$\begin{pmatrix} \widehat{I_{Ref}^L} \\ \widehat{I_{Ref}^H} \end{pmatrix} = \mathcal{R}^{-1} \left(\begin{pmatrix} P_{SI}^L \\ P_{SI}^H \end{pmatrix} - \Phi_{PD}^* \begin{pmatrix} P_{SI}^L \\ P_{SI}^H \end{pmatrix} \right) - \Phi_{ID}^* \left(\mathcal{R}^{-1} \left(\begin{pmatrix} P_{SI}^L \\ P_{SI}^H \end{pmatrix} - \Phi_{PD}^* \begin{pmatrix} P_{SI}^L \\ P_{SI}^H \end{pmatrix} \right) \right) \quad (4.4)$$

其中, $\widehat{I_{Ref}^L}$ 和 $\widehat{I_{Ref}^H}$ 分别为估计的高质量低能 CT 图像和高能 CT 图像; P_{SI}^L 和 P_{SI}^H 分别为插值后的低能和高能投影; $\Phi_{PD}^*(\cdot)$ 为训练好的投影域网络; $\Phi_{ID}^*(\cdot)$ 为训练好的图像域网络。

根据 DECT 成像中数据流动方向, 式(4.4)可以分解为三个步骤, 即投影域优化, 在线重建和图像域优化。投影域优化的目标是训练一个投影域网络 $\Phi_{PD}(\cdot)$ 以尽可能精确地估计出投影空间伪影成分, 可以描述为:

$$\Phi_{PD}^* = \underset{\Phi_{PD}}{\operatorname{argmin}} \left\| \Phi_{PD} \begin{pmatrix} P_{SI}^L \\ P_{SI}^H \end{pmatrix} - \begin{pmatrix} P_A^L \\ P_A^H \end{pmatrix} \right\| \quad (4.5)$$

其中 P_A^H 和 P_A^L 分别为插值后的高低能投影中的伪影成分。经投影域网络 $\Phi_{PD}(\cdot)$ 处理后, 已经很大程度地校正了插值后的投影和全角度投影不一致的部分, 但是由于当前技术水平限制, 仍然会存在不可忽略的投影误差。针对这一问题, 首先通过重建算子 $\mathcal{R}^{-1}$ 将处理后的投影在线重建到图像空间, 然后在图像空间进一步微调。图像域优化的目标是训练一个图像域网络 $\Phi_{ID}(\cdot)$ 进一步对投影域处理后残留的伪影成分进行估计, 可以描述为:

$$\Phi_{ID}^* = \underset{\Phi_{ID}}{\operatorname{argmin}} \left\| \Phi_{ID} \left(\mathcal{R}^{-1} \left(\begin{pmatrix} P_{SI}^L \\ P_{SI}^H \end{pmatrix} - \Phi_{PD}^* \begin{pmatrix} P_{SI}^L \\ P_{SI}^H \end{pmatrix} \right) \right) - \begin{pmatrix} I_A^L \\ I_A^H \end{pmatrix} \right\| \quad (4.6)$$

其中 I_A^L 和 I_A^H 分别为投影域处理后低能 CT 图像和高能 CT 图像中残留的伪影成分。

上述三个步骤通过提出的 CD-Net (Comprehensive Domain Network) 集成到一个算法框架中, 如图 4-3 所示。通过 4.1 节中基于互补扫描的 DECT 稀疏采样方案获取的双能稀疏投影经过二次线性插值之后, 输入到 CD-Net 中。首先通过投影域网络 (Projection Domain Network, PD-Net) 对插值后的投影误差进行校正; 随后通过可微解析重建算子 (Differentiable Analytical Reconstruction Operator, DARO^[190]) 将处理后的投影数据映射到图像空间; 进一步使用图像域网络 (Image Domain Network, ID-Net) 移除残留在 DECT 图像中的伪影成分。在训练过程中, 分别通过投影损失 $\mathcal{L}_{\text{Proj}}$ 和图像损失 $\mathcal{L}_{\text{CT}}$ 来约束 PD-Net 和 ID-Net。通过在投影空间和图像空间联合优化, 提出的 CD-Net 有潜力从互补的双能稀疏投影直接重建出高质量的 DECT 图像。




图 4-3 稀疏角度 DECT 双域联合优化重建流程图。CD-Net (Comprehensive Domain Network) 主要由投影域网络 (Projection Domain Network, PD-Net), 可微解析重建算子 (Differentiable Analytical Reconstruction Operator, DARO) 和图像域网络 (Image Domain Network, ID-Net) 三个功能模块构成。 $\mathcal{L}_{\text{Proj}}$ 和 $\mathcal{L}_{\text{CT}}$ 分别为投影空间和图像空间损失。

4.1.3 复合损失函数

为了实现式(4.5)和式(4.6)描述的优化目标, 本章基于平均绝对误差 (Mean Absolute Error, MAE) 和结构相似性 (Structural SIMilarity, SSIM) 构建了一个复合损失函数以约束 PD-Net 和 ID-Net。除了常规地对投影和图像进行约束之外, 还对高低能投影和图像的差进行了约束, 因为高低能能量通道之间的差异是 DECT 进行物质分辨和量化的关键。总的损失函数为:

$$\mathcal{L}_{\text{Total}} = \lambda \cdot \mathcal{L}_{\text{Proj}} + \mathcal{L}_{\text{CT}} \quad (4.7)$$

其中:

$$\begin{aligned} \mathcal{L}_{\text{Proj}} = & \mathcal{L}_{\text{Proj}}^{\text{MAE}} \left(\begin{pmatrix} \widehat{P}_F^L \\ \widehat{P}_F^H \end{pmatrix}, \begin{pmatrix} P_F^L \\ P_F^H \end{pmatrix} \right) + \alpha \cdot \mathcal{L}_{\text{Proj}}^{\text{SSIM}} \left(\begin{pmatrix} \widehat{P}_F^L \\ \widehat{P}_F^H \end{pmatrix}, \begin{pmatrix} P_F^L \\ P_F^H \end{pmatrix} \right) + \\ & \beta \cdot \mathcal{L}_{\text{Proj}}^{\text{MAE}}_{\text{Diff}} \left((\widehat{P}_F^L - \widehat{P}_F^H), (P_F^L - P_F^H) \right) \end{aligned} \quad (4.8)$$

$$\mathcal{L}_{CT} = \mathcal{L}_{CT}^{\text{MAE}} \left(\begin{pmatrix} \widehat{I_{Ref}^L} \\ \widehat{I_{Ref}^H} \end{pmatrix}, \begin{pmatrix} I_{Ref}^L \\ I_{Ref}^H \end{pmatrix} \right) + \alpha \cdot \mathcal{L}_{CT}^{\text{SSIM}} \left(\begin{pmatrix} \widehat{I_{Ref}^L} \\ \widehat{I_{Ref}^H} \end{pmatrix}, \begin{pmatrix} I_{Ref}^L \\ I_{Ref}^H \end{pmatrix} \right) + \beta \cdot \mathcal{L}_{CT}^{\text{MAE}}_{\text{Diff}} \left(\begin{pmatrix} \widehat{I_{Ref}^L} - \widehat{I_{Ref}^H} \\ I_{Ref}^L - I_{Ref}^H \end{pmatrix} \right) \quad (4.9)$$

λ , α 和 β 为平衡不同损失项权重的超参数。

4.1.4 双流网络模型




图 4-4 双流 ResUNet 模型。针对 DECT 成像设计的双流 ResUNet 由一个共享编码器(Shared Encoder), 一个低能解码器 (Low-Energy Decoder) 以及一个高能解码器 (High-Energy Decoder) 构成, 每个组件负责一项特定的任务。

为了利用 DECT 不同能量通道数据之间的相关性来改进成像质量, 特设计了如图

4-4 所示的双流 ResUNet 模型。该模型由一个共享编码器（Shared Encoder），一个低能解码器（Low-Energy Decoder）以及一个高能解码器（High-Energy Decoder）构成。各个组件负责不同的特定任务，其中共享编码器提取融合 DECT 不同能量通道数据信息并编码为共享特征，低能解码器和高能解码器以共享特征作为输入并进行差别学习，针对性地捕获有利于不同能量通道数据恢复的特征信息。

该模型以 UNet^[183]为基础，因为 UNet 及其变体在各种医学应用中均表现出了优异的性能，如去噪、配准、重建、检测、分割、超分辨率以及医学图像合成。本研究中，针对 DECT 成像，将其输入输出均扩展为双通道，且将解码部分扩展为双流结构，并采用了更有效的残差模块（Residual Block^[160], ResBlock）替代级联的卷积层。解码时采用双流结构而非双通道结构能够分配更多的参数进行差别学习。残差模块的引入有助于缓解梯度消失的问题，使模型训练更加稳定。UNet 中的跳跃连接可以同步映射局部和全局特征，增强网络的特征提取能力。

双流 ResUNet 是 4.1.2 节中 PD-Net 和 ID-Net 的具体结构，但请注意 PD-Net 和 ID-Net 是两个完全独立的模型，只是结构相同，其训练目标和输入输出完全不同，两个模型的参数也并不共享。具体地，PD-Net 以插值后的双能投影为输入，致力于估计出精确的投影误差，ID-Net 以重建的中间 DECT 图像为输入，专注于在图像空间移除投影域处理后残留的伪影成分。

4.2 数据预处理

在得到伦理审查委员会批准后，本研究在中国南京东部战区总医院回顾性收集了 25 名进行过碘对比增强 DECT 检查患者的胸腹部图像。患者在注射碘造影剂后，使用双源 SOMATOM Definition Flash 扫描仪（Siemens Healthcare, Forchheim, Germany）进行扫描。低能电位和高能电位分别设置为 100kV 和 140kV，其中 140 kV 的能谱使用锡过滤器进行预硬化，以提高频谱分离和剂量效率。使用 CT 供应商提供的商用滤波反投影算法进行图像重建。所有数据均进行了匿名处理以保护患者隐私。由于收集的 DECT 图像噪声较大，特采用了一个降噪网络对所有的 DECT 图像进行预处理，以增强不同能量通道 CT 图像之间的相关性。

4.2.1 预处理网络

后处理类的图像降噪方法具有较好的泛化性，为了使在 AAPM 数据上训练的模型能够很好地应用于本研究中的 DECT 数据，特开发了如图 4-5 所示的 GMUNet（Gradient-enhanced Multi-UNet）降噪模型，引入梯度信息来加强网络对图像高频特征的关注，并使用多个 UNet 模块进行渐进降噪。

图 4-5 (a)展示了 GMUNet 的整体结构，主要由 UNet 模块（UNet Block）、梯度提取操作（Gradient Extraction）和若干卷积层组成。UNet 模块详细结构在图 4-5 (b)中说明。有很多滤波器可以用于提取图像梯度信息，比如 Sobel 算子、Scharr 算子、Prewitt 算子和 Roberts 算子等，参考先前的工作^[13, 191]，本研究中采用 Sobel 算子来提取梯度信

息。




图 4-5 (a) 降噪 GMUNet 模型, 主要由 UNet 模块 (UNet Block)、梯度提取操作 (Gradient Extraction) 和若干卷积层组成; (b) UNet 模块的详细结构。

Sobel 算子由一个水平方向滤波器 S_H 和一个垂直方向滤波器 S_V 组成, S_H 和 S_V 具体形式如下:

$$S_H = \begin{bmatrix} -1 & 0 & +1 \\ -2 & 0 & +2 \\ -1 & 0 & +1 \end{bmatrix}, S_V = \begin{bmatrix} -1 & -2 & -1 \\ 0 & 0 & 0 \\ +1 & +2 & +1 \end{bmatrix} \quad (4.10)$$

给定图像 x , 其水平方向梯度 G_H 和垂直方向梯度 G_V 可以通过下式计算:

$$G_H(x) = S_H * x, G_V(x) = S_V * x, \quad (4.11)$$

其中 $*$ 表示卷积运算。图像 x 最终梯度为:

$$G(x) = \sqrt{G_H(x)^2 + G_V(x)^2} \quad (4.12)$$

式(4.12)中平方运算和平方根运算均为矩阵上的逐元素操作。

低剂量 CT 图像输入 GMUNet 后, 首先进行梯度提取, 得到的图像梯度和原始图像串联输入两层卷积层进行简单的特征提取, 随后编码的特征输入到三个串联的 UNet 模块进行渐进特征提取, 最后经过一个卷积核为 1×1 的卷积层输出降噪后的图像。为了对图像梯度信息充分利用, 前两个 UNet 模块输出的特征, 进行梯度提取后再和原特征串联一起输入到下一个 UNet 模块。

4.2.2 训练与测试

使用同第二章 2.3 节相同的 AAPM 数据对提出的 GMUNet 进行训练, 该数据集提供了 10 名患者在常规剂量下扫描的 CT 图像以及模拟的 1/4 常规剂量的低剂量 CT 图像, 图像层厚有 1mm 和 3mm 两种设置, 本研究中仅使用 1mm 层厚的图像数据。随机将 10 名患者数据划分为训练集 (8 名患者) 和验证集 (2 名患者)。

GMUNet 的优化目标是 최소화 预测的常规剂量 CT 图像和对应的真实常规剂量 CT 图像之间的平均均方误差 MSE, 优化器采用默认的 Adam, 学习率初始设置为 0.01 且每轮衰减 1%, 批大小设置为 16, 训练 100 轮后停止。训练完成后, AAPM 数据验证集

上表现最好的参数直接用于处理本研究中采集的 DECT 数据。

图 4-6 展示了降噪前后的 DECT 图像以及移除的噪声成分。从图 4-6 中放大的 ROI 可以看出, 提出的 GMUNet 在抑制噪声的同时可以很好地保持原始 DECT 图像解剖结构, 没有造成微小组织特征形变失真, 而且可以使高衰减区域和低衰减区域的边界更加清晰, 特别是在图 4-6 (b1)和(b2)中。移除的噪声成分(c)和(f)中也没有发现明显的结构化信息, 表明在降噪过程中没有导致图像内容丢失。请注意使用 AAPM 数据训练的 GMUNet 直接用于本研究中收集的 DECT 图像, 没有进一步在 DECT 数据上微调, 故而预处理步骤在有效抑制 DECT 图像噪声增强不同能量通道数据之间的相关性的同时并没有造成对 DECT 数据的额外需求。




图 4-6 DECT 图像降噪前后对比。(a) 原始低能 CT 图像; (b) 降噪后低能 CT 图像; (c) 低能 CT 图像中噪声成分; (d) 原始高能 CT 图像; (e) 降噪后高能 CT 图像; (f) 高能 CT 图像中噪声成分。黄色和红色方框标记的 ROI 放大在右侧。DECT 图像显示窗口为 $[-160, 240]$ HU; 噪声图像显示窗口为 $[-50, 50]$ HU。

4.3 实验和结果

本节首先对数据仿真流程以及实验设置进行说明, 然后通过消融实验探究不同空间信息对 DECT 成像质量的影响, 接着在三种不同稀疏采样配置下与相关算法结果进行对比分析, 最后通过两个材料分解应用, 虚拟无对比成像 (Virtual Non-Contrast Imaging, VNC) 和碘造影剂量化 (Iodine Contrast Agent Quantification), 来探究使用本章提出方法重建的 DECT 图像的临床效用。实验在台式电脑 (Ubuntu 20.04、i7-10700K 3.8GHz CPU、24GB Geforce RTX 3090 GPU、64GB RAM) 上使用 Python 和 TensorFlow 库完成。

4.3.1 数据说明

如本章 4.2 节中所述, 本研究在中国南京东部战区总医院回顾性收集了 25 名接受了 DECT 检查患者的胸腹部 CT 图像数据, 这些数据预先进行了降噪处理以增强不同能量通道数据之间的相关性。25 名患者数据随机划分为训练集 (19 名患者共 9297 组 DECT

图像)、验证集(3名患者共991组DECT图像)和测试集(3名患者共1203组DECT图像)。由于原始投影数据不可获得,本研究采用了表4-1所示的扇束成像几何生成仿真的全角度高低能投影数据,生成投影数据时按照第二章中式(2.1)添加入射光子数为 1×10^6 的泊松噪声。相应的稀疏角度投影数据按照本章4.1.1节中式(4.1)和式(4.2)从全角度高低能投影数据抽取而来。最终,每一组数据均包含高质量DECT图像、稀疏角度DECT图像、全角度双能投影和稀疏角度双能投影。

表4-1 仿真成像几何

参数	值	参数	值
光源-探测器距离	108.56 cm	光源-旋转中心距离	59.50 cm
探测器矩阵尺寸	736×1	探测器单元尺寸	1.2858×1.0 mm ²
图像矩阵尺寸	512×512	图像像素尺寸	0.8×0.8 mm ²
投影数目	720	全扫描角度范围	(0°, 360°]

4.3.2 实验设置

CD-Net以端到端的方式训练,通过式(4.7)中的复合损失函数联合优化,其中 λ , α 和 β 分别设置为0.1、0.025和0.1。调试 λ , α 和 β 时,首先令 $\alpha = \beta = 0$ 以确定 λ 的值,然后令 $\lambda = 0.1$, $\beta = 0$ 来确定 α 的值,最后令 $\lambda = 0.1$, $\alpha = 0.025$ 确定 β 的值。受限于可用的计算资源,批量大小设置为2。采用默认的Adam优化器,初始学习率设置为 10^{-4} 且每轮衰减1%,训练100轮后停止,在验证集上表现最好的参数用于最终测试。对比方法的参数设置参考相应的原始论文,为了公平比较,所有基于深度学习的方法均使用与CD-Net相同的数据进行训练,并在验证集上调至最优。

4.3.3 消融研究

本章提出的DECT重建算法同时在投影空间和图像空间进行约束,并引入了能量域相关性来提高成像质量,为探究这三种不同特性对最终结果的影响,首先进行了消融实验。具体地,PD-Net、ID-Net、SE-CD-Net(Single-Energy CD-Net)和CD-Net等四种方法被纳入比较,各方法的特性总结在表4-2中。请注意,消融研究中的PD-Net和ID-Net分别为在投影域进行预处理和在图像域进行后处理的独立模型,并不是CD-Net中的组件。即,PD-Net的输入是插值后的双能投影,训练目标是高质量双能投影,ID-Net的输入是直接重建的稀疏角度DECT图像,训练目标是高质量DECT图像。为探究能量域相关性的影响,特设计了一个CD-Net的退化模型,即SE-CD-Net。SE-CD-Net将CD-Net中的双流ResUNet更改为普通的ResUNet,即输入输出通道数为1且仅有一个编码器和一个解码器的ResUNet。由于ResUNet的通道数为1,所以SE-CD-Net需要分别处理低能和高能数据。消融研究中,采用1/12的稀疏采样配置,具体而言,本章4.1.1节式(4.1)和式(4.2)中的全角度投影数目设置为720,稀疏角度投影数目设置为60。

表 4-2 不同方法特性

特性	PD-Net	ID-Net	SE-CD-Net	CD-Net
投影域约束	✓	×	✓	✓
图像域约束	×	✓	✓	✓
能量域相关性	✓	✓	×	✓




图 4-7 消融研究中不同方法在 1/12 稀疏采样配置下的结果 (N=60, M=720)。第 1 列为参考的高质量 DECT 图像, 第 2-6 列分别为 1/12 稀疏采样配置下 FBP、PD-Net、ID-Net、SE-CD-Net 和 CD-Net 重建/处理的 DECT 图像。黄色方框标记的 ROI 的放大图展示在相应 CT 图像的下方。显示窗口为[-160, 240] HU。

图 4-7 展示了消融研究中不同方法在 1/12 稀疏采样配置下的结果。为排版简洁, 同一病例仅展示 LECT (Low-Energy CT) 或 HECT (High-Energy CT) 的结果; 为方便比较, 选取了部分临床上感兴趣的区域放大在相应图像的下方。图 4-7 第 2 列中 FBP 重建的图像存在严重的条纹伪影, 说明稀疏采样严重影像了 CT 图像的质量, 放大的 ROI

显示条纹伪影几乎完全淹没了 CT 图像中组织和器官的结构信息。图 4-7 第 3 列中, PD-Net 虽然可以较好地恢复解剖信息,但重建后 DECT 图像中存在着明显的二次伪影,特别是在图 4-7 (b3)放大的 ROI 中。ID-Net 和 SE-CD-Net 虽然都能够很好地移除伪影,但是处理后的 HECT 图像不同程度地丢失了细节信息。其中,没有利用能量域相关性的 SE-CD-Net 处理的结果失真更加严重,如图 4-7 中红色箭头所示。总体上看, CD-Net 重建的 DECT 图像和参考的 DECT 图像更为接近。此外,同 ID-Net 相比, PD-Net 处理后的结果具有更好的结构保真性,表明投影域处理有助于结构信息的恢复;但同时 PD-Net 处理后的图像仍残留着轻微的伪影,而 ID-Net 处理后的图像中没有,表明图像域处理可以很好地抑制条纹伪影。尽管 SE-CD-Net 采用了在投影域和图像域联合处理的策略,但由于没有考虑能量域相关性,重建的图像严重失真,特别是图 4-7 (b5)和(d5)中的血管以及图 4-7 (f5)中的肾脏结构信息几乎完全丢失,说明在 DECT 成像中,能量域相关性对于改进图像质量十分有帮助。相比之下, CD-Net 无论是在结构保真还是伪影移除方面均优于其他方法,表明在 DECT 中利用能量域相关性同时在投影域和图像域处理能够获得各种特性的协同增益效果。

表 4-3 消融研究中不同方法的定量结果

度量 (单位)	FBP	PD-Net	ID-Net	SE-CD-Net	CD-Net
MAE (HU)	110.00	14.73	15.10	15.18	11.07
SSIM (%)	45.53	97.27	96.86	95.57	98.53
PSNR (dB)	23.69	39.77	39.64	38.96	42.42

除了视觉评估,还对消融研究中不同方法的性能进行了量化比较,定量指标采用的是平均绝对误差 (MAE)、结构相似性 (SSIM) 和峰值信噪比 (PSNR),结果统计在表 4-3 中。与直接使用 FBP 算法重建相比, PD-Net、ID-Net 和 SE-CD-Net 等方法在三个指标上均取得了大幅度的改进。此外, CD-Net 取得了比 PD-Net、ID-Net 和 SE-CD-Net 更优的性能, MAE、PSNR 和 SSIM 分别达到了 11.07 HU、42.42 dB 和 98.53%。定量比较也表明,将三种特性集成到一个框架中的 CD-Net 更有潜力实现高质量的稀疏角度 DECT 重建。

4.3.4 图像重建结果

本节在三种不同稀疏采样配置 (1/12、1/10 和 1/8) 下,将提出的 CD-Net 与 FBP、DD-Net^[63] (DenseNet and Deconvolution based Network) 和 WATITF^[192] (Weight Adaptive Total-variation and Image-spectral Tensor Factorization) 等不同类别方法的结果进行比较分析,以评估其性能。其中, FBP 算法是经典的解析重建方法, DD-Net 是一种基于深度学习的用于稀疏角度 CT 伪影移除的图像后处理算法, WATITF 是一种融合了自适应权重 TV 和图像空间张量分解的能谱 CT 迭代重建算法。为公平比较,所有方法均参考原始论文进行调试以达到最优性能。为排版简洁,同一病例仅展示 LECT 或者 HECT 的结果。




图 4-8 不同方法在 1/12 稀疏采样配置下的轴状面结果($N=60$, $M=720$)。第 1 列为参考的高质量 DECT 图像；第 2-5 列分别为 1/12 稀疏采样配置下 FBP、DD-Net、WATITF 和 CD-Net 重建/处理的 DECT 图像。黄色方框标记的 ROI 放大在相应图像下方。肺部图像显示窗口为 $[-1150, 350]$ HU；腹部图像显示窗口为 $[-160, 240]$ HU。

图 4-8 展示了不同方法在 1/12 稀疏采样配置下的轴状面结果，黄色方框标记的兴趣区域放大在相应图像下方。由于投影数目过于稀疏，图 4-8 第 2 列所示的直接使用 FBP 算法重建的图像被条纹伪影严重损坏，图 4-8 (b2)中肺部微小组织特征以及图 4-8 (d2)和(f2)中肾脏结构几乎无法分辨。作为一种图像域的伪影移除算法，DD-Net 可以粗略恢复不同组织和器官的结构，但是由于没有考虑到数据一致性，在采样极其稀疏的情况下，DD-Net 处理后的图像严重失真，可以从图 4-8 (b3)、(d3)和(f3)中放大的 ROI 观

察到。相比之下, WATITF 方法可以很好地还原图像细节, 这得益于 WATITF 方法对投影一致性的约束以及在构建张量时考虑了不同能量通道之间的相关性, 但是 WATITF 重建的 DECT 图像存在着一定程度的二次伪影, 导致了原有组织特征的形变。特别是在图 4-8 (f4)中, 肾脏平滑区域存在明显的块状伪影。从图 4-8 第 5 列 ROI 的放大图可以看出, 提出的 CD-Net 不仅可以有效移除条纹伪影, 还能够恢复微小组织特征 (如红色箭头标识), 且 CD-Net 重建的 DECT 图像中没有明显的二次伪影。




图 4-9 不同方法在 1/10 稀疏采样配置下的冠状面结果($N=72$, $M=720$)。第 1 列为参考的高质量 DECT 图像; 第 2-5 列分别为 1/10 稀疏采样配置下 FBP、DD-Net、WATITF 和 CD-Net 重建/处理的 DECT 图像。黄色方框标记的 ROI 放大在相应图像下方。图像显示窗口为 $[-160, 240]$ HU。

图 4-9 展示了不同方法在 1/10 稀疏采样配置下的冠状面结果, 黄色方框标记的兴趣区域放大在相应图像下方。从图 4-9 第 2 列结果可以看出, 在 1/10 稀疏采样配置下直接使用 FBP 算法重建的 DECT 图像仅可粗略辨别出不同组织器官的大致结构, 但细节

信息完全被伪影淹没。DD-Net 可以很好地移除稀疏采样导致的条纹伪影，但是无法准确地恢复微小组织特征，特别是图 4-9 (d3)所示的血管结构严重失真。相比之下，图 4-9 (d4)展示的 WATITF 方法重建的 DECT 图像中，血管整体结构恢复较好，不过血管末端特征也存在失真现象（如红色箭头所示）；此外，虽然图 4-9 (b4)和(f4)展示的肾脏中的组织结构保留完好，但存在着轻微的块状伪影，特别是，图 4-9 (f4)中块状伪影导致了一些假阳性结构（如红色箭头所示）。整体而言，图 4-9 (d5)中 CD-Net 恢复的血管树和参考图像中展示的血管树更加一致，图 4-9 (b5)和(f5)中黄色箭头标示的肾脏中病灶的边界也更加清晰，且没有导致其他假阳性特征。




图 4-10 不同方法在 1/8 稀疏采样配置下的矢状面结果(N=90, M=720)。第 1 列为参考的高质量 DECT 图像；第 2-5 列分别为 1/8 稀疏采样配置下 FBP、DD-Net、WATITF 和 CD-Net 重建/处理的 DECT 图像。黄色方框标记的 ROI 放大在相应图像下方。图像显示窗口为[-160, 240] HU。

图 4-10 展示了不同方法在 1/8 稀疏采样配置下的矢状面结果，黄色方框标记的感兴趣

趣区域放大在相应图像下方。FBP 算法无法应对投影数据不完备的情况，重建的 DECT 图像中存在严重的条纹伪影，如图 4-10 第 2 列结果所示。DD-Net 在移除伪影的同时，还能够粗略恢复 DECT 图像中的结构信息；不过对于一些对比度低且边界不清晰的组织特征，DD-Net 的复原能力较弱，比如图 4-10 (d3)中的肝脏血管。相对于图 4-8 和图 4-9 中 1/10 和 1/12 稀疏采样的情况，图 4-10 第 4 列中 WATITF 重建的 DECT 图像仅存在着轻微的块状伪影，不同组织和器官的结构信息基本复原，不过块状伪影仍然导致了一些低对比特征的失真，比如图 4-10 (d4)中红色箭头标示的肝脏血管。对比发现，图 4-10 第 5 列 CD-Net 重建的 DECT 图像和参考图像更加一致，特别是，黄色箭头指示的肝脏血管和肾脏病灶等临床上关注的组织特征均精确恢复。

表 4-3 不同方法在不同稀疏采样配置下的定量结果

投影数目	度量（单位）	FBP	DD-Net	WATITF	CD-Net
N=60, M=720	MAE (HU)	110.01	20.74	15.42	11.07
	SSIM (%)	45.53	91.76	97.40	98.53
	PSNR (dB)	23.69	36.54	39.55	42.42
N=72, M=720	MAE (HU)	98.36	17.89	13.40	10.28
	SSIM (%)	49.34	94.36	98.12	98.76
	PSNR (dB)	24.72	37.69	40.85	43.20
N=90, M=720	MAE (HU)	86.14	16.31	11.51	9.39
	SSIM (%)	54.15	95.24	98.67	98.99
	PSNR (dB)	25.87	38.62	42.27	44.08

在量化评估方面，同样采用平均绝对误差（MAE）、结构相似性（SSIM）和峰值信噪比（PSNR）三个指标，不同方法在不同稀疏采样配置下的定量结果总结在表 4-3 中。由于 FBP 算法不适用于不完备采样条件下的 CT 重建，MAE、SSIM 和 PSNR 等各项指标均不理想。DD-Net 可以很好地抑制条纹伪影并一定程度地恢复图像信息，在三项指标上均取得了较大提升。在视觉评估中发现 WATITF 重建的 DECT 图像虽然存在着轻微的块状伪影，但组织和器官的结构信息均得到了较好的恢复；在表 4-3 中，WATITF 也取得了较为理想的定量结果，特别是结构相似性分数和 CD-Net 十分接近。相比之下，CD-Net 在不同稀疏采样配置下均取得了更好的 MAE、SSIM 和 PSNR，这也表明 CD-Net 重建的 DECT 图像和参考的 DECT 图像更加一致。

4.3.5 材料分解结果

相对于普通 CT，DECT 的优势是能够进行材料分辨和量化。因此，本节通过两个 DECT 的临床应用，即碘造影剂量化（Iodine Contrast Agent Quantification）和虚拟无对比成像（Virtual Non-Contrast Imaging, VNC），来验证本章提出方法重建的 DECT 图像

的临床应用价值。简单来说, VNC 图像是人工移除造影剂信息后的 CT 图像, VNC 成像通常用于模拟不使用造影剂的 CT 扫描, 以减少临床对比增强 DECT 成像程序中对不使用造影剂的 CT 扫描的需求。另外, 碘造影剂量化对各种病变的主观评价很有帮助。

本研究使用一种临床实践中广泛使用的图像域材料分解算法^[193]来获得 VNC 图像和碘造影剂图像。该算法中, 基材料图像以 DECT 图像加权和的方式表示, 即

$$\begin{pmatrix} B_1(i) \\ B_2(i) \end{pmatrix} = \begin{pmatrix} w_{1L} & w_{1H} \\ w_{2L} & w_{2H} \end{pmatrix} \begin{pmatrix} I^L(i) \\ I^H(i) \end{pmatrix}, i = 1, 2, \dots, K. \quad (4.13)$$

其中 B_1 和 B_2 为两种材料图像, I^L 和 I^H 为 DECT 图像, i 表示第 i 个像素, K 为图像像素总数。想要获得材料图像, 需要进行校正测量以获得加权系数矩阵 $\begin{pmatrix} w_{1L} & w_{1H} \\ w_{2L} & w_{2H} \end{pmatrix}$ 中各元素的值。具体地, 在 DECT 图像中选择包含水和碘对比剂的 ROI 进行测量, 对于仅含水的 ROI 有 $B_1 = 1$ 且 $B_2 = 0$, 对于含碘对比剂 ROI 有 $B_1 = 1$ 且 $B_2 = 1$, 然后通过求解以下线性方程, 获得加权系数矩阵:

$$\begin{cases} \begin{pmatrix} 1 \\ 0 \end{pmatrix} = \begin{pmatrix} w_{1L} & w_{1H} \\ w_{2L} & w_{2H} \end{pmatrix} \begin{pmatrix} V_{Water}^L \\ V_{Water}^H \end{pmatrix} \\ \begin{pmatrix} 1 \\ 1 \end{pmatrix} = \begin{pmatrix} w_{1L} & w_{1H} \\ w_{2L} & w_{2H} \end{pmatrix} \begin{pmatrix} V_{Iodine}^L \\ V_{Iodine}^H \end{pmatrix} \end{cases} \quad (4.14)$$

其中 V_{Water}^L 和 V_{Water}^H 分别为校准测量时 LECT 和 HECT 图像中水的 ROI 内的平均值; V_{Iodine}^L 和 V_{Iodine}^H 分别为校准测量时 LECT 和 HECT 图像中碘造影剂 ROI 内的平均值。获得上述测量值后, 通过式(4.14)即可获得加权系数矩阵 $\begin{pmatrix} w_{1L} & w_{1H} \\ w_{2L} & w_{2H} \end{pmatrix}$, 然后通过式(4.13)即可利用 DECT 图像获得两种基材料图像。

图 4-11 展示了 1/8 稀疏采样配置下使用不同方法重建的 DECT 图像生成的碘造影剂图像。从图 4-11 第 2 列的结果可以看出, 使用参考的 DECT 图像生成的碘造影剂图像中的噪声较大, 各种组织和器官之间的边界并不清晰。尽管在本章 4.2 节中已经对收集的 DECT 数据进行了降噪预处理, 但是为了更直接地探究从不同 DECT 图像获得的基材料图像的质量, 本节使用的材料分解算法并未添加约束项对材料图像中的噪声进行抑制, 因此使用参考的 DECT 图像生成的材料图像仍然受到了放大的噪声的影响。由于 DD-Net 方法处理后的 DECT 图像质量较差, 图 4-11 第 3 列中相应的碘造影剂图像也存在明显的失真。相比之下, 第 4 列 WATITF 方法的碘造影剂图像中的结构信息保持完好, 特别是图 4-11 (b4) 中红色箭头标记的微小特征仍可辨识; 不过, WATITF 的结果受到严重的块状伪影的影响。与其他方法的结果相比, 图 4-11 第 5 列中使用 CD-Net 重建的 DECT 图像生成的碘造影剂图像噪声水平低, 各种组织、器官和骨骼的边界更加清晰, 具有更好的视觉感受。从放大的 ROI 可以发现, CD-Net 的碘造影剂图像中结构信息也保留得比较完整, 特别是, 图 4-11 (d5) 中蓝色箭头标记的碘造影剂增强的血管以及图 4-11 (f5) 中黄色箭头标记的肾脏病灶均能清晰分辨。不过, CD-Net 重建的 DECT 图像仍和参考 DECT 图像有一定的误差, 这些误差也在碘造影剂图像中体现出来, 如图 4-11 (b5) 中红色箭头所示。




图 4-11 1/8 稀疏采样配置下不同方法重建的 DECT 图像生成的碘造影剂图像。第 1 列为对应的 LECT 图像；第 2 列为使用参考的 DECT 图像生成的碘造影剂图像；第 3-5 列分别为 1/8 稀疏采样配置下使用 DD-Net、WATITF 和 CD-Net 处理/重建的 DECT 图像生成的碘造影剂图像。黄色方框标记的 ROI 放大在相应图像下方。LECT 图像显示窗口为 $[-160, 240]$ HU；碘造影剂图像显示窗口为 $[0, 1.0]$ 。

图 4-12 展示了 1/8 稀疏采样配置下使用不同方法重建的 DECT 图像生成的 VNC 图像。同样可以观察到，使用 CD-Net 重建的 DECT 图像生成的 VNC 图像视觉效果更好，图 4-12 第 2 行中红色箭头标识的血管、图 4-12 第 4 行中蓝色箭头指示的肾脏组织以及图 4-12 第 6 行中黄色箭头标记的骨骼均更加清晰。

为了进一步评估生成的碘造影剂图像和 VNC 图像的准确性，在图 4-11 和图 4-12 选取了 6 个临床上感兴趣的 ROI 进行统计测量，结果记录在表 4-4 中。对比发现，WATITF 和 CD-Net 的结果与参考值更为接近，量化准确性相当，不过从图 4-11 和图 4-12 可以看出，WATITF 的碘造影剂图像和 VNC 图像存在明显的块状伪影。




图 4-12 1/8 稀疏采样配置下不同方法重建的 DECT 图像生成的 VNC 图像。第 1 列为对应的 LECT 图像；第 2 列为使用参考的 DECT 图像生成的 VNC 图像；第 3-5 列分别为 1/8 稀疏采样配置下使用 DD-Net、WATITF 和 CD-Net 处理/重建的 DECT 图像生成的 VNC 图像。黄色方框标记的 ROI 放大在相应图像下方。LECT 图像和 VNC 图像的显示窗口均为[-160, 240] HU。

表 4-4 图 4-11 和图 4-12 标记的 ROI 内的统计值（均值±标准差）

图像类型	ROI 编号	参考值	DD-Net	WATITF	CD-Net
碘图 (单位: %)	ROI 1	1.004±0.205	0.910±0.126	1.019±0.075	0.999±0.058
	ROI 2	0.957±0.148	0.939±0.051	0.958±0.056	0.959±0.078
	ROI 3	1.040±0.137	1.056±0.085	1.054±0.059	1.045±0.066
VNC 图像 (单位: HU)	ROI 1	43±37	39±37	44±20	43±15
	ROI 2	71±36	65±14	68±16	67±13
	ROI 3	-18±36	2±37	-18±15	-16±16

4.4 本章小结

本章针对 DECT 成像的特点,提出了基于互补扫描的稀疏角度 DECT 双域优化重建算法。基于互补扫描的稀疏采集方案有望放宽对高成本 DECT 专用硬件的依赖,同时能够降低数据采集过程中累积的 X 射线辐射。为了解决稀疏采样导致的图像质量退化问题,提出利用 DECT 不同能量通道之间的相关性,同时在投影空间和图像空间进行恢复。为实现上述目标,设计了基于双流 ResUNet 模型的 CD-Net。双流 ResUNet 利用一个共享编码器提取 DECT 数据不同能量通道之间的相关性以及不同尺度的图像信息并编码为共享特征,然后使用低能和高能两个解码器进行差别学习,对共享特征解码以恢复出相应的高质量低能 CT 和高能 CT 图像。使用模拟腹部 DECT 数据集对本章提出方法进行了验证。消融研究表明,在互补的稀疏采样配置下,不同能量通道之间的相关性对于恢复 DECT 图像细节十分有帮助,投影空间处理可以提高微小特征的恢复效果,而图像空间处理可以有效移除伪影。同相关方法对比发现,提出的 CD-Net 更有潜力在互补的稀疏扫描配置下重建出高质量 DECT 图像。两个临床上的 DECT 应用,碘造影剂量化和 VNC 成像,表明使用 CD-Net 重建的 DECT 图像获得的材料图像噪声水平更低,各种组织和器官的边界更加清晰,统计测量的结果也表明 CD-Net 重建的 DECT 图像在定量方面和参考的 DECT 图像相差很小。

本研究中,生成模拟的双能投影数据时,仅对腹部 DECT 图像进行正投影,没有将多光谱的信息考虑进去。这是因为融合多光谱信息需要获得不同材料的密度图像,这对于组成成分复杂的人体组织是十分困难的,使用现有材料分解算法获得的材料图像质量未必理想,高噪声的材料图像反而会破坏 DECT 不同能量通道数据之间的相关性。况且,无论是否考虑多光谱信息,DECT 成像中不同能量通道数据之间的相关性都是存在的,因此考虑多光谱信息与否不会影响本研究利用 DECT 能量域相关性来提高稀疏角度 DECT 重建的质量。

本章提出了一种基于慢速 kV 切换的 DECT 互补稀疏扫描方案,通过降低电压切换的频率,该方案可以大大降低技术实现难度,进而降低对昂贵专用硬件的依赖。不过,此项工作尚未在真实 DECT 数据上验证,因为目前大规模的 DECT 原始投影数据不可获得,无法对投影空间网络进行训练。此外,临床上诊断 DECT 通常使用的为螺旋成像几何,可用的计算资源难以支持三维重建巨大的运算量。后续将通过与供应商的紧密合作采集真实的 DECT 数据进行验证,并参考先前工作^[76, 78],采用投影空间和图像空间分步处理的方式来规避三维成像运算量大无法在线重建的问题。此外,还可以通过投影数据重排将三维重建问题解耦为二维重建问题^[119, 146],进而减少成像过程中的计算资源消耗。

第五章 基于双域先验增强的有限角度 DECT 深度迭代重建

随着 DECT 技术在放射诊断社区被广泛接受, 将 DECT 技术应用于其他临床应用的兴趣亦越来越高, 比如放射治疗和介入手术。在这些情形中, 为了避免扫描设备与病人或其他硬件发生碰撞, 通常使用有限角度扫描来采集数据^[11, 73, 74]。此时, 第四章中提出的基于互补扫描的 DECT 稀疏采样方案不再适用, 因为该方法虽然以稀疏扫描的方式降低了采样频率但仍需要完整的圆周旋转来采集投影数据。

针对上述问题, 本章考虑到 DECT 成像中不同能量通道数据之间的相关性, 提议使用基于双 1/4 圆周扫描的 DECT 采集方案进行衰减测量, 即在 $(0^\circ, 90^\circ]$ 范围内采集低能投影数据, 在 $(90^\circ, 180^\circ]$ 范围内采集高能投影数据, 采集过程中仅需进行一次能级转换。该采集方案在满足放射治疗和介入手术等特殊数据采集场景的同时可以降低累积的 X 射线辐射。但是, 有限角度扫描采集的投影数据不完备, 直接使用解析算法重建的 DECT 图像存在严重的楔形伪影, 无法为后续放射治疗或者介入程序提供精准的影像信息。

考虑到第四章提出的完全数据驱动的 CD-Net 的局限性, 本章基于第三章数据-模型联合驱动的思想, 并结合 DECT 成像特点, 提出双域自先验信息增强的深度迭代重建 (Self-Prior Information Enhanced Deep Iterative Reconstruction, SPIE-DIR) 算法。与第三章提出的 DREAM-Net 类似, SPIE-DIR 在每次迭代中使用投影补全、残差校正和图像增强三个模块同时在投影空间、残差空间和图像空间进行约束, 以协同实现高质量重建。不同的是, SPIE-DIR 针对 DECT 成像进行了改进, 与 DREAM-Net 相比具有以下几方面优势。首先, DREAM-Net 为普通 CT 开发, 单线程处理数据, 而 SPIE-DIR 可以实现高效的 DECT 双通道并行重建; 其次, SPIE-DIR 利用基于 DECT 能量域相关性的先验信息同时在投影空间和图像空间增强, 能够实现更有潜力的性能; 第三, SPIE-DIR 采用密集链接的方式融合不同迭代时刻的信息, 可以有效避免梯度消失并稳定模型性能; 最后, SPIE-DIR 还引入了 Wasserstein 距离约束, 使用 WGAN-GP 来增强生成的 DECT 图像的视觉效果。本章相关研究成果已发表在《IEEE Transactions on Instrumentation and Measurement》期刊。

本章 5.1 节从传统的图像先验约束迭代重建算法推导出基于双域先验增强的有限角度 DECT 深度迭代重建算法, 并详细讲解了其功能模块和采用的网络结构; 5.2 节首先对比分析不同方法在模拟人体腹部 DECT 数据和真实小鼠 DECT 数据上的结果, 然后通过消融实验探究不同模块、先验信息和生成对抗网络对算法性能的影响, 最后对比分析不同算法的复杂性; 5.3 节总结本章内容并对仍需进一步解决的几个问题进行讨论。

5.1 基于双域先验增强的有限角度 DECT 深度迭代重建算法

本节首先讲解提议的基于双 1/4 圆周扫描的 DECT 采集方案, 然后介绍传统的图像先验信息约束的 CT 重建方法的一般求解过程, 在此基础上提出基于双域先验增强的有限角度 DECT 深度迭代重建算法, 并对涉及的功能组件和网络模块进行详细说明。

5.1.1 基于双 1/4 圆周扫描的采集方案

面向放射治疗和介入手术等特殊的临床应用场景,本章提出基于双 1/4 圆周扫描的 DECT 采集方案,如图 5-1 所示,即在 $(0^\circ, 90^\circ]$ 范围内采集低能投影数据,在 $(90^\circ, 180^\circ]$ 范围内采集高能投影数据,采集过程中仅需进行一次能级转换。请注意,这里能级转换可以通过多种方式实现,比如 kV 切换、垂直安装的双源系统、起始角度间隔 90° 的两次顺序扫描。该方案在满足放射治疗和介入手术等特殊数据采集场景需求的同时还可以降低累积的 X 射线辐射。




图 5-1 基于双 1/4 圆周扫描的 DECT 采集方案,蓝色和橙色圆弧分别代表低能和高能采样轨迹。

5.1.2 传统先验信息约束的图像重建

考虑到 DECT 成像不同能量通道数据之间的相关性,可以通过下式融合高低能有限角投影数据获得一张先验图像 x_p ,即:

$$x_p = \text{FBP}([y_0^l; y_0^h]) \quad (5.1)$$

其中 y_0^l 和 y_0^h 是使用基于双 1/4 圆周扫描的 DECT 采集方案获取的低能和高能有限角投影数据;FBP 是解析重建算法。可以发现,与图 5-2 (a)和(b)中的低能和高能有限角 CT 图像相比,图 5-2 (c)所示的先验图像中仅存在轻微伪影而且保留了丰富的图像细节,因而可以用于改进有限角度 DECT 成像质量。



图 5-2 各种 CT 图像。(a)和(b)为使用基于双 1/4 圆周扫描的 DECT 采集方案获取的低能和高能有限角 CT 图像;(c)先验图像;(d)和(e)为参考的高质量低能和高能 CT 图像。

一般地,先验图像约束的 DECT 迭代重建算法目标函数如下:

$$x^e = \underset{x^e}{\operatorname{argmin}} \frac{1}{2} \|A_{la}^e x^e - y_0^e\|_2^2 + \mu^e \cdot \mathcal{R}_x(x^e) + \gamma^e \cdot \mathcal{R}_p(x^e, x_p), e = \{l, h\}. \quad (5.2)$$

其中, e 表示不同的能级, $e = l$ 是低能级, $e = h$ 是高能级; A_{la}^e 是 e 能级对应的有限角度投影矩阵; x^e 为重建的 e 能级的 CT 图像; $\mathcal{R}_x(\cdot)$ 和 $\mathcal{R}_p(\cdot)$ 分别是人工设计的针对 DECT 图像和先验图像的正则项; μ^e 和 γ^e 为平衡不同项权重的超参数。通常, 可以使用梯度下降法来求解式(5.2)描述的重建问题, 即迭代更新以下步骤:

$$x_t^e = x_{t-1}^e - \lambda^e \cdot (A_{la}^e)^T (A_{la}^e x_{t-1}^e - y_0^e) - \mu^e \cdot \nabla \mathcal{R}_x(x_{t-1}^e) - \gamma^e \cdot \nabla \mathcal{R}_p(x_{t-1}^e, x_p), \quad (5.3)$$

$$e = \{l, h\}.$$

5.1.3 双域先验增强的深度迭代重建

先前的研究^[105, 108, 109, 116, 123]表明, 基于深度学习的约束比手工设计的正则项更加强, 可以用来提高算法性能。因此, 本研究首先用深度神经网络模块替换式(5.3)中基于压缩感知的正则项, 将传统的迭代重建算法展开为深度迭代重建:

$$x_t^e = x_{t-1}^e - \lambda^e \cdot (A_{la}^e)^T (A_{la}^e x_{t-1}^e - y_0^e) - \mu_t^e \cdot \mathcal{G}_t^e(x_{t-1}^e) - \gamma_t^e \cdot \mathcal{F}_t^e(x_{t-1}^e, x_p), \quad (5.4)$$

$$e = \{l, h\}.$$

其中 λ^e 、 μ_t^e 和 γ_t^e 为可训练的标量; $\mathcal{G}_t^e$ 和 $\mathcal{F}_t^e$ 为对应的深度神经网络模块。考虑到深度神经网络具有强大的对复杂映射的表征能力, $\mathcal{G}_t^e$ 和 $\mathcal{F}_t^e$ 可以用一个深度神经网络模块 $\mathcal{H}_t^e$ 替代^[194]。即式(5.4)转化为:

$$x_t^e = x_{t-1}^e - \lambda^e \cdot (A_{la}^e)^T (A_{la}^e x_{t-1}^e - y_0^e) - \eta_t^e \cdot \mathcal{H}_t^e(x_{t-1}^e, x_p), \quad e = \{l, h\}. \quad (5.5)$$

式(5.5)便是采用展开迭代重建策略求解式(5.2)中定义的问题的一般方案。

但是, 有两个问题需要进一步解决。首先, 在有限角度 CT 重建中, 现有的投影数据严重不完整, 导致传统的数据保真项性能不理想。其次, 在式(5.5)中使用反向投影矩阵 $(A_{la}^e)^T$ 产生的误差图像是模糊的, 且存在严重的楔形伪影, 可能会影响重建精度。为了解决上述两个问题, 分别引入投影补全和误差校正两个模块, 针对有限角度 DECT 提出了双域自先验信息增强的深度迭代重建 (Self-Prior Information Enhanced Deep Iterative Reconstruction, SPIE-DIR) 算法。该方法包含投影补全、误差校正和图像增强三个模块, 每个模块对应一项具体的任务, 具体如下。

5.1.3.1 投影补全

投影补全能够以监督学习的方式来提高数据一致性^[86, 110, 195], 因此, 本研究采用一个进行投影补全的网络模块来改进式(5.5)。首先, 使用全采样投影矩阵 A 对前一次迭代的图像 x_{t-1}^e 进行正向投影。然后, 网络模块 $\mathcal{P}_t^e(\cdot)$ 被用来缩小重投影 Ax_{t-1}^e 和参考的全投影之间的距离。此外, 因为采集的有限角度投影数据 y_0^e 是完全精确的, 故采用一个复写算子 $\oplus$ 将网络恢复的投影 $\mathcal{P}_t^e(Ax_{t-1}^e)$ 中对应角度的数据用 y_0^e 替换。这样不仅可以保证采集到的部分投影数据是完全准确的, 而且可以在一定程度上恢复缺失部分的投影信息。最后, 因为 Radon 变换的线性性质, 在图像空间有效的先验图像 x_p 同样可以用来提升投影补全模块的性能。先验投影 y_p 可以通过对先验图像 x_p 进行正向投影获得, 即:

$$y_p = Ax_p \quad (5.6)$$

从图 5-3 可以发现, 通过式(5.6)获取的先验投影基本上补全了图 5-3 (a)和(b)中双能有限

角度投影中缺失的部分。引入先验投影增强后，投影补全模块可以描述为：

$$y_t^e = \mathcal{P}_t^e \left((Ax_{t-1}^e, y_p), \Theta_{\mathcal{P}_t^e} \right) \oplus y_0^e, e = \{l, h\}. \quad (5.7)$$




图 5-3 各种投影图像。(a)和(b)分别为使用基于双 1/4 圆周扫描的 DECT 采集方案获取的低能和高能有限角投影，灰色区域为缺失部分；(c)先验投影；(d)和(e)为参考的全角度低能和高能投影。

5.1.3.2 误差校正

研究^[121-123]表明，对误差图像施加一个约束有助于增强迭代重建算法的性能。因此，另一个深度神经网络模块 $\mathcal{Q}_t^e(\cdot)$ 用来估计更准确的误差图像。在考虑投影补全模块后，误差校正模块定义为：

$$r_t^e = \mathcal{Q}_t^e \left(A^T (Ax_{t-1}^e - y_t^e), \Theta_{\mathcal{Q}_t^e} \right), e = \{l, h\} \quad (5.8)$$

5.1.3.3 图像增强

最后，当前迭代的图像 x_t^e 可以通过下式获得：

$$x_t^e = x_{t-1}^e - \mathcal{H}_t^e \left((x_{t-1}^e, x_p), \Theta_{\mathcal{H}_t^e} \right) - r_t^e, e = \{l, h\} \quad (5.9)$$

因为深度神经网络 $\mathcal{H}_t^e$ 和 $\mathcal{Q}_t^e$ 具备学习标量系数的能力，所以式(5.5)中用以平衡不同项的超参数 λ^e 和 η_t^e 在式(5.9)中被省略了。此外，受到 DenseNet^[196]的启发，图像增强模块将前面所有迭代的结果链接到当前迭代，进而避免梯度消失并稳定模型性能^[12, 63, 197]。即，式(5.9)转化为：

$$x_t^e = x_{t-1}^e - \mathcal{H}_t^e \left((x_0^e, \dots, x_{t-1}^e, x_p), \Theta_{\mathcal{H}_t^e} \right) - r_t^e, e = \{l, h\}. \quad (5.10)$$

通过迭代更新式(5.7)、(5.8)和(5.10)中定义的投影补全、误差校正和图像增强三个步骤，提出的基于双域先验增强的 DECT 深度迭代重建算法有潜力从双 1/4 圆周有限角度扫描中重建出高质量的 DECT 图像。

5.1.3.4 网络结构

为了实现端到端的训练，上述三个模块被集成到一个生成器网络中，如图 5-4 (a)所示。可以看出，生成器网络由一个初始化网络以及 n 个迭代模块组成，每个迭代模块包含投影补全、误差校正和图像增强三个子模块。其中，初始化网络和投影补全网络 $\mathcal{P}_t^e(\cdot)$ 均采用图 5-4 (c)所示的结构。但请注意，初始化网络和投影补全网络是两个完全独立的网络，参数并不共享，输入、输出和训练目标也不相同，只是具有相同的结构。具体而言，初始化网络的输入是 FBP 直接重建的有限角 DECT 图像 x_{fbp}^l 和 x_{fbp}^h ，目标是为后续迭代模块提供一个较好的初始值，图 5-4 (c)中初始化网络的输入输出通道 I 和 O 均为 2，模型初始通道数 C 为 32；而投影补全网络 $\mathcal{P}_t^e(\cdot)$ 的输入是上一时刻图像的投影

Ax_{t-1}^e 以及先验投影 y_p ，输出是恢复的投影数据，图 5-4 (c) 中投影补全网络 $\mathcal{P}_t^e(\cdot)$ 的输入通道 I 为 2，输出通道 O 为 1。误差校正采用了一个轻量级 U 型网络 $\mathcal{Q}_t^e(\cdot)$ ，其结构如图 5-4 (e) 所示，其输入输出通道 I 和 O 均为 1。图像增强模块中 $\mathcal{H}_t^e(\cdot)$ 网络结构如图 5-4 (d) 所示，图像增强模块的目标是利用前面所有时刻的图像信息以及先验信息恢复出当前时刻图像 x_t^e ，因此对于第 t 次迭代中的 $\mathcal{H}_t^e(\cdot)$ ，其输入通道 I 为 $t+1$ ，输出通道 O 为 1。受限于可用的计算资源，三个模块中网络的初始通道数 C 均设置为 16。判别器网络及其具体结构如图 5-4 (b) 所示，判别器由 8 个卷积层、1 个全局平均池化层和 1 个全连接层组成。为了增强判别器的特征提取能力，其输入为在线提取的图像块。采用全局平均池化层而不是全连接层来压缩特征维度以防止过拟合^[164]。为了进行 Wasserstein 距离的计算，最后一层采用输出维度为 1 的全连接层。




图 5-4 基于双域先验增强的有限角度 DECT 深度迭代重建算法原理图。(a) 生成器网络架构；(b) 判别器网络及其具体结构；(c) 初始化网络和投影补全网络 $\mathcal{P}_t^e$ 的具体结构；(d) 图像增强模块中 $\mathcal{H}_t^e$ 网络的具体结构；(e) 误差校正网络 $\mathcal{Q}_t^e$ 的具体结构。请注意初始化网络和投影补全网络 $\mathcal{P}_t^e$ 是两个完全独立的网络，参数并不共享，输入、输出和训练目标也不相同，只是具有相同的结构。

5.1.3.5 损失函数

为了在保证重建精度的同时避免产生模糊的结果，一个复合损失函数应用于本章中的任务。该复合损失函数由两个部分组成，分别是基于欧式距离的重建损失项和基于

Wasserstein 距离的对抗损失项。具体地，对于生成器网络 g ，其优化目标为：

$$\min_g (\mathcal{L}_g^{rec} + \lambda_{adv} \cdot \mathcal{L}_g^{adv}) \quad (5.11)$$

其中

$$\begin{aligned} \mathcal{L}_g^{rec} = & \mathcal{L}_{MAE} \left(\begin{pmatrix} x_{label}^l \\ x_{label}^h \end{pmatrix}, \begin{pmatrix} x_n^l \\ x_n^h \end{pmatrix} \right) + \lambda_x \cdot \mathcal{L}_{SSIM} \left(\begin{pmatrix} x_{label}^l \\ x_{label}^h \end{pmatrix}, \begin{pmatrix} x_n^l \\ x_n^h \end{pmatrix} \right) \\ & + \lambda_y \cdot \mathcal{L}_{MAE} \left(\begin{pmatrix} y_{label}^l \\ y_{label}^h \end{pmatrix}, \begin{pmatrix} y_n^l \\ y_n^h \end{pmatrix} \right) \end{aligned} \quad (5.12)$$

x_{label}^l 、 x_{label}^h 和 x_n^l 、 x_n^h 分别为高质量 DECT 图像和预测的 DECT 图像； y_{label}^l 、 y_{label}^h 和 y_n^l 、 y_n^h 分别为全角度投影数据和预测的投影数据； λ_{adv} 、 λ_x 和 λ_y 是平衡不同损失项的超参数。

至于生成对抗网络的具体模态，本研究中采用 WGAN-GP。众所周知，GAN 存在训练不稳定的问题，尽管它们是强大的生成模型。WGAN-GP 先后引入了 Wasserstein 距离^[198]和梯度惩罚^[159]，能够在几乎不调整超参数的情况下稳定训练各种 GAN 的架构。GAN 虽然还有许多其他变体^[199]，但 WGAN-GP 易于训练，除了鉴别器外不需要其他组件。此外，之前的工作^[13, 65, 182]已经证明了 WGAN-GP 在常规 CT 应用中的潜力。因此，本研究采用 WGAN-GP。在 WGAN-GP 模式下，生成器 g 和判别器 d 的损失函数分别为：

$$\mathcal{L}_g^{adv} = -\mathbb{E}_{g \left(\begin{pmatrix} y_0^l \\ y_0^h \end{pmatrix} \right)} \left[d \left(g \left(\begin{pmatrix} y_0^l \\ y_0^h \end{pmatrix} \right) \right) \right] \quad (5.13)$$

$$\begin{aligned} \mathcal{L}_d^{adv} = & \mathbb{E}_{\left(\begin{pmatrix} x_n^l \\ x_n^h \end{pmatrix} \right)} \left[d \left(\begin{pmatrix} x_n^l \\ x_n^h \end{pmatrix} \right) \right] - \mathbb{E}_{\left(\begin{pmatrix} x_{label}^l \\ x_{label}^h \end{pmatrix} \right)} \left[d \left(\begin{pmatrix} x_{label}^l \\ x_{label}^h \end{pmatrix} \right) \right] \\ & + \lambda_{gp} \cdot \mathbb{E}_{\hat{x}} [(\|\nabla_{\hat{x}} d(\hat{x})\|_2 - 1)^2] \end{aligned} \quad (5.14)$$

λ_{gp} 为梯度惩罚项的超参数， $\nabla_{\hat{x}} d(\hat{x})$ 为生成器 d 对 $\hat{x}$ 的梯度，其中：

$$\hat{x} = \epsilon \cdot \begin{pmatrix} x_{label}^l \\ x_{label}^h \end{pmatrix} + (1 - \epsilon) \cdot \begin{pmatrix} x_n^l \\ x_n^h \end{pmatrix}, \quad \epsilon \sim U[0, 1]. \quad (5.15)$$

5.2 实验和结果

本节中，模拟人体数据和真实小鼠数据被用来评估提出的 DECT 深度迭代重建方法。FBP^[32]、DD-Net^[63]、LEARN⁺⁺^[200]和 CD-Net^[201]四种不同类型的方法被纳入比较。FBP 是经典的解析重建方法；DD-Net 是用于 CT 图像条纹伪影移除的后处理网络；LEARN^[108]是一种展开迭代重建算法，在稀疏角度 CT 重建中表现出了优异的性能，LEARN⁺⁺是 LEARN 的改进版本，是为有限角度 CT 开发的，LEARN⁺⁺用更高效的基于 UNet 的架构取代了 LEARN 中的三个级联的卷积层，以获得更好的性能；CD-Net 是本研究第四章中提出的利用能量域相关性同时进行投影修补和图像恢复的 DECT 专用的重建方法。为了公平比较，所有竞争方法都在验证集上进行了调优，以达到最佳性能。除视觉评估外，还采用平均绝对误差（MAE）、结构相似性（SSIM）和峰值信噪比（PSNR）三个常用指标对不同方法进行定量评估。实验在台式电脑（Ubuntu 20.04, i7-10700K 3.8GHz CPU,

32GB RAM, Geforce RTX 3090 24GB GPU) 上使用 Python 和 TensorFlow 库实现。

5.2.1 模拟数据实验

5.2.1.1 数据集

模拟实验数据来源与 4.3.1 节相同。为了加速训练, 从中抽取出 22 名患者的腹部 DECT 图像用于验证本章提出的算法, 按照 16:3:3 的比例随机划分为训练集 (2000 组 DECT 数据)、验证集 (230 组 DECT 数据) 和测试集 (322 组 DECT 数据)。采用表 4-1 相同成像几何获得模拟的双能全投影数据, 其中, 在 $(0^\circ, 90^\circ]$ 范围内低能投影数据和 $(90^\circ, 180^\circ]$ 范围内高能投影数据提取出来作为双能有限角度投影数据。

5.2.1.2 参数设置

在模型训练之前, 本研究采用的复合损失函数中有四个超参数需要预先确定。首先, 参考先前的工作^[13], 式(5.11)中生成器的对抗损失的权重 λ_{adv} 设置为 0.02; 然后, 采用网格搜索法确定式(5.12)中不同损失的权重系数 λ_x 和 λ_y 为 300 和 1; 最后, 式(5.14)中梯度惩罚项的系数采用默认设置 $\lambda_{gp} = 10$ 。在权衡了重建性能和计算负载之后, 迭代模块的个数设置为 3。提出的 SPIE-DIR 算法的训练分为两个阶段, 在第一个阶段, 生成器先只使用重建损失 $\mathcal{L}_g^{rec}$ 训练 100 轮以稳定性能, 采用默认的 Adam 优化器, 初始学习率设置为 10^{-4} 且每轮衰减 1%。第二个阶段, 生成器和判别器通过复合的损失函数交替训练 50 轮。在这个阶段中, 生成器仍使用默认的 Adam 算法优化, 学习率从 10^{-4} 逐渐降低到 10^{-6} ; 判别器优化时学习率固定为 10^{-6} , Adam 优化器的两个衰减因子 β_1 和 β_2 分别设置为 0.5 和 0.9。受限于可用的计算资源, 训练时批量大小设置为 1。为了避免测试时使用到过拟合的参数, 在验证集上表现最好的参数作为最终参数。对比方法的参数设置参考其原始论文, 为公平对比, 所有基于深度学习的算法均使用与 SPIE-DIR 相同的数据训练, 并在验证集上调整至最优性能。

5.2.1.3 重建结果

图 5-5 展示了不同方法在模拟腹部 DECT 数据上的结果。从图 5-5 第 2 列 FBP 直接重建的结果可以看出, 有限角度扫描导致的楔形伪影使 DECT 图像质量严重退化, 不仅改变了 DECT 图像原有的 CT 值, 还破坏了其结构信息。作为一种图像后处理网络, DD-Net 虽然能够移除楔形伪影恢复 DECT 图像轮廓, 但是不能准确校正 CT 值并复原缺失的图像细节。将数据保真和图像正则集成到一个深度迭代重建框架中后, LEARN⁺⁺ 算法可以重建出优于 DD-Net 的结果。从图 5-5 第 4 列 ROI 的放大图可以观察到, LEARN⁺⁺ 算法能够粗略恢复出不同组织和器官的结构, 不过在细节方面还需要进一步改善。相比之下, CD-Net 和 SPIE-DIR 方法不仅能够很好地消除投影缺失引起的楔形伪影, 还能够高保真地恢复人体内部不同组织和器官的结构和细节, 这也证明了在 DECT 成像中利用不同能量通道数据之间相关性进行图像恢复的有效性。不过, 由于最小化欧式距离鼓励平均所有可能的解^[150-152], CD-Net 重建的 DECT 图像有一定程度的模糊。除了在欧式空间进行约束, SPIE-DIR 还引入 WGAN-GP 来缩小重建的 DECT 图像和参考的

高质量 DECT 图像之间的 Wasserstein 距离，避免产生过度平滑的结果并增强生成的 DECT 图像的视觉感受。从图 5-5 第 6 列 ROI 中肾脏和血管组织的放大图可以看出，与其他方法相比，SPIE-DIR 重建的 DECT 图像具有更好的视觉效果。




图 5-5 不同方法在模拟腹部 DECT 数据集上的结果。第 1 列为参考的高质量 DECT 图像；第 2-6 列分别为有限角度扫描条件下 FBP、DD-Net、LEARN⁺⁺、CD-Net 和 SPIE-DIR 重建/处理的 DECT 图像。黄色方框标记的 ROI 放大在相应图像下方。图像显示窗口为[-200, 300] HU。

表 5-1 不同方法在模拟腹部 DECT 数据上的定量结果

度量（单位）	FBP	DD-Net	LEARN ⁺⁺	CD-Net	SPIE-DIR
MAE (HU)	280.97	41.10	24.79	13.26	10.83
SSIM (%)	54.86	87.11	93.46	98.31	98.60
PSNR (dB)	15.45	28.99	31.09	41.38	43.09

除了视觉评估，本节还采用了 MAE、SSIM 和 PSNR 三个指标来量化不同方法的性能，结果如表 5-1 所示。FBP 直接重建的 DECT 图像的 MAE 高达 280.97 HU，说明楔

形伪影严重破坏了 DECT 原有的 CT 值。DD-Net 和 LEARN⁺⁺不同程度地降低了 HU 值的绝对误差,但是仍不能准确地校正 DECT 图像的 CT 值。CD-Net 和 SPIE-DIR 算法重建的 DECT 图像的 CT 值误差相对较小,这得益于对不同能量通道数据之间相关性的利用。此外,与 LEARN⁺⁺相比,同为深度迭代算法的 SPIE-DIR 重建的 DECT 图像 HU 值绝对误差更小。在结构相似性方面,由于采样角度缺失,FBP 算法取得了最差的分值。DD-Net 和 LEARN⁺⁺虽然很大程度地提高了 SSIM 分数,但是从图 5-5 中可以发现,这两种方法处理的 DECT 图像在细节上仍然存在比较严重的失真。得益于能量域相关性的提取和利用,CD-Net 和 SPIE-DIR 均获得了较高的 SSIM 分数,不过相比之下,SPIE-DIR 重建的 DECT 图像的结构保真度更高,这也与视觉评估的结论一致。此外,提出的 SPIE-DIR 算法在竞争方法中还取得了更好的 PSNR,达到了 43.09 dB。

5.2.1.4 材料分解结果

上节对不同方法的重建精度进行了对比,本节采用两个 DECT 的临床应用,碘造影剂量化和 VNC 成像,对不同方法获得的 DECT 图像的临床效用进行评估。材料分解方法与第四章 4.3.4 节相同。




图 5-6 不同方法的在模拟腹部 DECT 数据上的材料分解结果。第 1 列为参考的高质量低能 CT 图像;第 2 列为使用高质量 DECT 图像获得的碘造影剂图像和 VNC 图像;第 3-5 列为分别为使用 LEARN⁺⁺、CD-Net 和 SPIE-DIR 算法的重建的 DECT 图像获得的碘造影剂图像和 VNC 图像。碘造影剂图像显示窗口为[-0.1, 1.0];低能 CT 图像和 VNC 图像显示窗口为[-200, 300] HU。

图 5-6 为使用不同方法重建的 DECT 图像获得的碘造影剂图像和 VNC 图像。由于通过 FBP 和 DD-Net 方法获得 DECT 图像退化严重,为排版简洁,图 5-6 中没有展示这两种方法的材料分解结果。从图 5-6 第 3 列的结果可以看出,由于 LEARN⁺⁺重建的 DECT 图像质量不理想,使用其生成的碘造影剂图像和 VNC 图像中存在严重的伪影。此外,通过对比图 5-6 第 2 列和第 4、5 列的结果可以发现,与参考的碘造影剂图像和 VNC 图像的相比,使用 CD-Net 和 SPIE-DIR 重建的 DECT 图像获得的碘造影剂图像和 VNC 图像中不同组织和器官的边缘更加清晰。特别是,在图 5-6 第 4、5 列 CD-Net 和 SPIE-DIR 方法的材料分解结果中,黄色圆圈标记的肾脏病灶和黄色箭头指示的血管钙化点均能有效辨识。

表 5-2 使用不同方法重建的 DECT 图像获得的碘造影剂图像和 VNC 图像中 ROI 的均值和标准差,ROI 的位置标示在图 5-6 中。

图像类别	ROI	Reference	FBP	DD-Net	LEARN ⁺⁺	CD-Net	SPIE-DIR
碘造影剂 图像 (%)	ROI 1	1.00±0.23	1.17±1.15	1.37±0.84	1.48±0.21	0.93±0.2	1.04±0.24
	ROI 2	1.06±0.22	1.13±0.61	0.90±0.43	1.09±0.31	1.13±0.13	1.09±0.18
	ROI 3	0.55±0.20	0.01±0.60	0.67±0.41	0.63±0.27	0.60±0.12	0.57±0.18
VNC 图像 (HU)	ROI 1	31±47	397±207	-32±76	-40±48	25±29	32±47
	ROI 2	-4±38	123±202	-65±138	-16±87	-8±22	-6±36
	ROI 3	32±46	495±142	-15±79	-7±63	26±29	30±45

为了进一步评估使用不同方法重建的 DECT 图像进行材料分解的准确性,分别在碘造影剂图像和 VNC 图像中选取了 3 个均匀的 ROI (对应 ROI 位置标注在图 5-6 中),并测量其均值和标准差,结果统计在表 5-2 中。对比发现,使用 FBP、DD-Net 和 LEARN⁺⁺等方法重建的 DECT 图像获得的值和参考值相差较大,CD-Net 和 SPIE-DIR 方法的结果与参考值较为接近。其中,在碘造影剂图像的 3 个 ROI 中,CD-Net 的误差在 7%以内,SPIE-DIR 的误差在 4%以内;在 VNC 图像的 3 个 ROI 中,CD-Net 的误差在 6 HU 以内,SPIE-DIR 的误差在 2 HU 以内。此外,可以发现,无论在碘造影剂图像中还是在 VNC 图像中,CD-Net 的标准差比 SPIE-DIR 和参考的标准差更小,这表明相应的碘造影剂图像和 VNC 图像的噪声水平更低。SPIE-DIR 的噪声水平和参考图像的噪声水平相当,这是因为 WGAN-GP 将高质量 DECT 图像的统计特性迁移到了生成的 DECT 图像中,以避免处理后的图像过度平滑。

5.2.2 真实数据实验

5.2.2.1 数据集

真实小鼠 DECT 数据使用与本研究 3.3.2 节相同的 Hiscan VM Micro-CT 系统^[185, 186]采集,采用两次连续的扫描获取双能数据,管电压分别设置为 50 kV 和 70 kV。考虑到

计算负载,参考先前工作^[119, 146]将三维锥束投影重排为二维扇束投影,扇束成像几何如表 5-3 所示。低能扫描($0^\circ, 90^\circ$]范围内的投影数据与高能扫描($90^\circ, 180^\circ$]范围内的投影数据作为互补的有限角度双能数据。采集的 5 只小鼠数据随机分为训练集(3 只, 180 层切片)、验证集(1 只, 60 层切片)和测试集(1 只, 60 层切片)。为了缓解训练样本不足的问题,通过三次间隔为 90° 的旋转将训练集增加到 720 层切片。

表 5-3 真实小鼠 DECT 数据成像几何

参数	值	参数	值
光源-探测器距离	172.14 mm	光源-旋转中心距离	86.07 mm
探测器矩阵尺寸	963×1	探测器单元尺寸	0.1×1.0 mm ²
图像矩阵尺寸	512×512	图像像素尺寸	75×75 μm^2
投影数目	600	全扫描角度范围	($0^\circ, 360^\circ$]

5.2.2.2 参数设置

损失函数中的权重系数的设置与模拟实验相同。生成器首先用重建损失训练了 50 轮,以稳定其性能,此阶段采用默认的 Adam 算法,学习率从 10^{-4} 逐渐降低到 10^{-5} 。然后,再使用复合损失函数将生成器和判别器交替训练 50 轮,此阶段生成器和判别器均采用使用默认的 Adam 优化器更新,学习率固定为 10^{-5} 。由于真实小鼠数据训练样本较少,因此先使用 5.2.1 节中的模拟数据进行预训练,然后再使用真实小鼠数据微调;而且,训练时采用 mixup 技术^[187]进行在线数据扩充以防止过拟合。在验证集上表现最好的参数用于最终测试。为公平比较,所有基于深度学习的算法均使用与 SPIE-DIR 相同的数据重新训练并调至最优性能。

5.2.2.3 重建结果

不同方法在真实小鼠 DECT 数据上的结果展示在图 5-7 中。从图 5-7 第 2 列的结果可以看出,有限角度扫描条件下,FBP 直接重建的 DECT 图像被楔形伪影严重损坏,放大的 ROI 中的真实结构完全无法辨识。图 5-7 第 2 列和第 3 列中的结果显示,DD-Net 和 LEARN⁺⁺方法可以有效移除有限角度扫描导致的楔形伪影,也可以在一定程度上恢复缺失的 DECT 图像内容,但是无法复原受楔形伪影影响严重的区域(如蓝色箭头所示),ROI 放大图中不同组织区域中的细节特征也存在着明显的失真。从图 5-7 第 5 列和第 6 列中的结果可以观察到,CD-Net 和 SPIE-DIR 方法可以有效复原蓝色箭头指示的 DD-Net 和 LEARN⁺⁺算法无法恢复的区域,这表明利用不同能量通道数据之间的相关性对缺失的扫描信息进行弥补是有效的。通过对比图 5-7 中 ROI 的放大图(b5)、(b6)和(d5)、(d6)可以发现,CD-Net 重建的高能 CT 图像存在过度平滑的问题,而 SPIE-DIR 重建的高能 CT 图像中小鼠的骨骼(b6)和肺部组织(d6)都相对清晰;在低能 CT 图像中,CD-Net 重建结果的软组织部分出现了一些假性的低衰减区域,如图 5-7 (h5)中红色箭头所示,相比

之下, SPIE-DIR 重建的结果和使用全角度投影重建的低能 CT 图像更加一致, 这得益于 SPIE-DIR 算法协同了深度学习和迭代重建的优势。




图 5-7 不同方法在真实小鼠 DECT 数据上的结果。第 1 列为参考的高质量 DECT 图像; 第 2-6 列分别为有限角度扫描条件下 FBP、DD-Net、LEARN⁺⁺、CD-Net 和 SPIE-DIR 重建/处理的 DECT 图像。黄色方框标记的 ROI 放大在相应图像下方。图像显示窗口为[100, 500] HU。

不同方法在真实小鼠 DECT 数据上的定量结果统计在表 5-4 中。与视觉评估的结果

一致，直接使用 FBP 算法重建误差最大，DD-Net 和 LEARN⁺⁺可以不同程度地提升有限角度 DECT 重建的精度，三个指标相对于 FBP 算法均有改进，但由于忽略了 DECT 成像的特性，DD-Net 和 LEARN⁺⁺的恢复效果并不理想。利用不同能量通道之间的冗余信息来恢复缺失的投影和图像内容，CD-Net 可以将重建的绝对误差降低到 12.78 HU，对应的小鼠 DECT 图像的结构相似性和峰值信噪比也分别提高到了 96.25%和 36.32dB。通过投影补全、误差校正和图像增强三个组件来协同深度学习和迭代重建的优势，并引入双域先验信息增强，SPIE-DIR 相比于 CD-Net 可以进一步将重建的绝对误差降低 2.62 HU，并将重建的小鼠 DECT 图像的结构相似性和峰值信噪比进一步提高至 96.89%和 37.74 dB。

表 5-4 不同方法在真实小鼠 DECT 数据上的定量结果

度量（单位）	FBP	DD-Net	LEARN ⁺⁺	CD-Net	SPIE-DIR
MAE (HU)	53.55	17.13	16.03	12.78	10.15
SSIM (%)	70.91	88.75	90.07	96.25	96.89
PSNR (dB)	23.87	32.04	32.71	36.32	37.74

5.2.2.4 材料分解结果

由于真实实验中的小鼠在进行 DECT 扫描前未注射碘造影剂，因此，另一种 DECT 应用——自动骨移除，用来比较使用不同方法重建的 DECT 图像进行材料分解的效果，材料分解方法与第四章 4.3.4 节相同。




图 5-8 不同方法的在真实小鼠 DECT 数据上的材料分解结果。第 1 列为参考的高质量高能 CT 图像；第 2 列为使用高质量 DECT 图像获得的骨组织图像和虚拟无骨图像；第 3-5 列为分别为使用 LEARN⁺⁺、CD-Net 和 SPIE-DIR 算法的重建的 DECT 图像获得的骨组织图像和虚拟无骨图像。骨组织图像显示窗口为[0, 0.4]；高能 CT 图像和虚拟无骨图像显示窗口为[100, 500] HU。

使用不同方法重建的小鼠 DECT 图像获得的骨组织图像和虚拟无骨图像展示在图 5-8 中, FBP 和 DD-Net 的结果伪影严重, 为排版简洁, 未在图 5-8 中展示。图 5-8 第 3 列中展示的 LEARN⁺⁺的材料分解结果存在着明显的伪影, 这是因为重建的小鼠 DECT 图像误差较大, 通过材料分解之后, 这些误差反映在骨组织图像和虚拟无骨图像中。CD-Net 和 SPIE-DIR 的材料分解结果中, 骨组织图像结构均比较完整, 不过 CD-Net 的结果中骨组织的值偏低; 在小鼠的虚拟无骨图像中, 可以明显看到 CD-Net 的结果中残留了较为明显的骨成分(如红色箭头所示), 而 SPIE-DIR 的结果与参考的虚拟无骨图像更为接近, 这说明在真实小鼠数据上, SPIE-DIR 重建的 DECT 图像精度更高。此外, 从图 5-8 (d1)-(f1)中的结果可以看到, 参考的虚拟无骨图像中仍残留了少量骨组织的信息, 这是因为真实小鼠 DECT 数据是通过两次时序上连续的扫描采集的, 两次扫描过程中, 小鼠的位置发生了轻微偏移。




图 5-9 使用不同方法重建的 DECT 图像获得的小鼠骨组织图像中的剖线图, 剖线的位置标示在图 5-8 中, 黑色方框标记的部分放大在相应图像的右侧。

由于小鼠骨组织图像中难以获得均匀的 ROI, 因此在三个视角的骨组织图像中各划定一条剖线, 来比较不同方法的骨组织图像的精度, 图 5-8 中标记的 3 条剖线的结果分别展示在图 5-9 的(a)-(c)中, FBP 算法的结果波动幅度较大未在图 5-9 中展示。对比发现, DD-Net 和 LEARN⁺⁺的结果误差较大, 与参考剖线的吻合度较低, CD-Net 和 SPIE-DIR 的结果与参考剖线的吻合度较高。进一步通过图 5-8 右侧剖线图的放大部分可以发现, 与 CD-Net 相比, SPIE-DIR 的结果与参考剖线的匹配度更高一些, 这表明使用 SPIE-DIR 算法重建的 DECT 图像能够获得更加准确的骨组织图像。此外, 还对不同方法的虚拟无骨图像的精度进行了比较, 分别从三个视角的虚拟无骨图像中选取了 3 个均匀的 ROI, 并测量其均值和标准差, 结果统计在表 5-5 中。表 5-5 显示, 受楔形伪影的影响 FBP 方法的结果误差较大; DD-Net 和 LEARN⁺⁺虽然能够一定程度地恢复 DECT 图像的信息, 但是仍不能有效地校正其 HU 值; CD-Net 在虚拟无骨图像中 3 个 ROI 的误差分别为 19 HU、19 HU 和 15 HU; SPIE-DIR 算法可以进一步将 3 个 ROI 内的均值误差降低到 4 HU、3 HU 和 5 HU。

表 5-5 使用不同方法重建的 DECT 图像获得的小鼠虚拟无骨图像中 ROI 的均值和标准差, ROI 的位置标示在图 5-8 中。

ROI 编号	ROI 1	ROI 2	ROI 3
Reference	298±40	295±39	284±43
FBP	519±163	652±138	727±121
DD-Net	244±63	295±36	343±36
LEARN ⁺⁺	255±35	271±32	331±37
CD-Net	317±18	314±19	299±19
SPIE-DIR	294±37	298±38	289±34

5.2.3 消融研究

本章提出的 SPIE-DIR 算法同时使用深度神经网络在投影空间、图像空间和残差空间进行约束, 并引入了自先验信息和对抗学习机制来提升算法性能。本节通过消融实验来探究上述不同因素带来的影响。为排除真实环境中潜在的不确定因素的干扰, 消融研究在模拟人体腹部 DECT 数据上进行。

首先, 对不同空间网络约束的有效性进行验证。在本章 5.1.3 节中, 提出的 SPIE-DIR 算法逐步引入了投影补全、误差校正和图像增强三个模块分别在投影空间、残差空间和图像空间进行约束。如表 5-6 所示, 消融研究中尝试了不同空间约束的所有组合, 作为基准模型, 图像空间约束始终被保留。在探究不同空间网络约束的影响时, 先验信息的增益效果被保留, 但不采用对抗学习机制进行训练, 因为先前研究表明对抗学习机制会影响模型的最终性能。不同方法的结果展示在图 5-10 中, 由于难以直接从重建的 DECT

图像中观察到不同方法的差别，计算了不同方法结果的绝对误差图像并放置在对对应图像下方。如红色箭头所示，图 5-10 (b2)中的绝对误差图像残留的结构更加明显，说明只在图像空间进行约束的模型比其他模型的性能差。引入残差空间约束或投影空间约束都可以在一定程度上提升重建精度，图 5-10 (b3)和(b4)展示的绝对误差图像中残留的结构信息相较于(b2)也更少。与其他结果相比，图 5-10 (b5)中残留的结构信息最少。表 5-6 列出了不同空间网络约束对重建结果影响的定量结果。可以发现，残差空间约束和投影空间约束可不同程度地改善所有的指标；同时在三个空间约束的模型在所有指标都取得了最高分数，与仅在图像空间进行约束的基础模型相比，MAE、PSNR 和 SSIM 分别提高了 1.83 HU、1.77 dB 和 0.81%。视觉评估和定量比较结果都表明同时在投影空间、残差空间和图像空间进行约束有希望获得更优的性能。




图 5-10 不同空间网络约束对重建结果的影响。(a1)为参考的低能 CT 图像；(a2)-(a5)为不同方法重建的图像；(b1)-(b5)为相应的绝对误差图像。DECT 图像显示窗口为[-200, 300] HU；绝对误差图像的显示窗口为[0, 80] HU。IR：图像增强，RC：误差校正，PI：投影补全。

表 5-6 不同空间网络约束对重建结果影响的定量比较

方法	图像空间	残差空间	投影空间	MAE (HU)	SSIM (%)	PSNR (dB)
IR	✓	×	×	12.32	97.89	41.53
IR+RC	✓	✓	×	11.99	98.32	42.19
IR+PI	✓	×	✓	10.82	98.57	42.90
IR+RC+PI	✓	✓	✓	10.49	98.70	43.30

另外，消融研究还对先验信息（Prior）和对抗学习机制（WGAN-GP）的影响进行了研究。不同方法的结果展示在图 5-11 中。通过对比(b2)-(b4)中的绝对误差图像可以发现，先验信息可以有效降低重建误差；此外，比较(a3)和(a4)中放大的 ROI 可以发现 WGAN-GP 能够缓解最小化欧式距离导致的模糊效应，有助于生成视觉上增强的 DECT 图像。先验信息和对抗学习机制影响的定量结果统计在表 5-7 中。对比第 1 行和第 2 行

的结果可以发现, 先验信息的利用能够将平均绝对误差降低 1.93 HU, 并将结构相似性和峰值信噪比分别提升 0.9%和 2.30dB。从表 5-7 还可以发现一个有趣的现象, WGAN-GP 的引入虽然提升了重建的 DECT 图像的视觉感受, 但是略微降低了所有指标的分数, 先前的一些研究^[65, 92, 182]也揭露过类似现象, 本研究 2.3.5 节也探讨了这一现象产生的原因。由于医学图像最终由放射科医生视觉审阅, 因此略微牺牲定量指标而提高视觉感受是值得的。




图 5-11 先验信息 (Prior) 和对抗学习机制 (WGAN-GP) 对重建结果的影响。(a1)为参考的低能 CT 图像;(a2)-(a5)为不同方法重建的图像;(b1)-(b4)为相应的绝对误差图像。DECT 图像显示窗口为 $[-200, 300]$ HU; 绝对误差图像的显示窗口为 $[0, 80]$ HU。

表 5-7 先验信息 (Prior) 和对抗学习机制 (WGAN-GP) 影响的定量比较

Prior	WGAN-GP	MAE (HU)	SSIM (%)	PSNR (dB)
×	×	12.42	97.80	41.00
✓	×	10.49	98.70	43.30
✓	✓	10.83	98.60	43.09

5.2.4 算法复杂性分析

算法的复杂性是算法部署时十分关注的指标, 本节采用浮点运算次数 (Floating Point Operations)、参数量 (Parameters) 和吞吐量 (Throughout) 三个常用度量来比较不同方法的复杂性。在模拟腹部 DECT 数据上获得的不同方法的结果总结在表 5-8 中。对比发现, DD-Net 浮点运算次数和参数量最少, 吞吐量最大, 处理速度达到了每秒 17 帧图像。但是, 在 5.2.1 节和 5.2.2 节模拟数据和真实数据实验中, DD-Net 处理后的图像失真严重, 无法为后续任务提供精确的图像引导。LEARN⁺⁺的运算量和参数量在对比方法中最多, 吞吐量最小, 但是由于没有利用能量域相关性, LEARN⁺⁺在有限角度扫描条件下仍然不能重建出令人满意的 DECT 图像。SPIE-DIR 算法的浮点运算次数是

CD-Net 的 128%，参数量是 CD-Net 的 110%，但是吞吐量只有 CD-Net 的 55% 左右，不过 SPIE-DIR 在模拟实验和真实实验中视觉评估和定量比较都优于 CD-Net，牺牲一些算法效率而取得更好的性能是值得的。而且，在临床实践中，SPIE-DIR 每秒 6 帧图像的处理速度仍然是比较高效的。SPIE-DIR 吞吐量低是因为它是一种展开的迭代重建算法，而迭代框架中的重复的投影和反投影操作非常耗时，所有展开的迭代重建算法都存在这个问题，比如 LEARN⁺⁺。

表 5-8 不同方法的算法复杂性比较 (G: Giga, M: Million)

度量 (单位)	DD-Net	LEARN ⁺⁺	CD-Net	SPIE-DIR
浮点运算次数 (G)	228.99	1519.71	362.01	466.89
参数量 (M)	2.99	16.26	7.42	8.22
吞吐量 (帧/秒)	17	5	11	6

5.3 本章小结

为了使放射治疗和介入手术等临床场景也能够从 DECT 技术中获益，本章提出了双 1/4 圆周的 DECT 扫描方案，在有限角度范围内采集双能数据。为了求解不完备采样导致的严重病态的逆问题，提出了能够协同深度学习和迭代重建优势的深度迭代重建算法，该算法由投影补全、残差校正和图像增强三个模块组成，分别在投影空间、残差空间和图像空间进行约束；此外，针对 DECT 成像的特性，引入了投影先验和图像先验来增强相应模块的性能；最后，采用对抗学习机制来缓解最小化欧式距离导致的模糊效应，以重建出视觉上增强的 DECT 图像。消融实验表明同时在投影空间、残差空间和图像空间进行约束能够达到协同增益的效果。此外，先验信息提升重建精度的有效性和对抗学习机制提升重建图像视觉效果的作用也在消融研究中得到了验证。在模拟人体腹部 DECT 数据和真实小鼠 DECT 数据上的结果均表明，提出的基于双域先验增强的 DECT 重建算法更有潜力在有限角度扫描应用场景中重建出高质量的 DECT 图像。

本章基于传统的先验图像约束的迭代重建算法构建了一个深度迭代重建网络，并额外引入了投影先验来增强模型性能。与传统迭代重建方法不同，不易在数学上给出展开的迭代重建算法的收敛性证明，类似方法均存在这一问题，不过实验中的 loss 曲线和可视化结果均能指示深度神经网络的收敛，如何解释深度学习是一个长足的问题。

此外，提出的基于双域先验增强的有限角度 DECT 深度迭代重建算法是一种数据-模型共同驱动的方法，基于模型的构建方式能够使不同网络组件专注于特定的子任务，进而提升算法性能，不过该算法一定程度上保留了数据驱动方法的局限性。在本章中，采用了模拟腹部 DECT 数据和真实小鼠 DECT 数据对算法进行了验证，但是由于两个数据集的特性不同，无法直接将使用模拟腹部 DECT 数据训练的模型应用在真实小鼠数据上。对于深度神经网络来说，摆脱对数据的依赖而专注于图像恢复任务本身是十分有挑战性的。而且，数据集的规模也会影响到算法的性能。在本章 5.2 节中，可以看出不

同方法在真实小鼠数据的性能均有所下降，训练数据不足是主要原因。但是在临床上，制作大规模配对的 DECT 数据集是非常困难的，如何基于有限数据实现满意的算法性能仍需进一步探究。

本章提出了一种基于互补的双 1/4 圆周扫描的 DECT 采集方案，用以在有限角度范围内采集 DECT 数据，同时降低累积的 X 射线辐射剂量并缩短扫描时间，一个值得关注的问题是此方案的可行性。提议的有限角度 DECT 扫描方案采集过程中仅需进行一次能级转换，可以通过多种方式实现，比如 kV 切换、双源系统、起始角度间隔 90° 的两次顺序扫描。其中起始角度间隔 90° 的两次顺序扫描可以在不做任何硬件升级的情况下进行，是最适合在放射治疗和介入手术等特殊应用场景中使用的方式。

第六章 总结与展望

6.1 研究工作总结

X 射线计算机断层成像 (Computed Tomography, CT) 能够以非侵入的方式可视化物体内部的三维结构, 且具有扫描速度快、图像分辨率高等优点, 在临床上有很多重要应用, 比如疾病的筛查、诊断、疗效评估以及术中影像引导。为尽可能降低 X 射线带来的辐射伤害, 根据具体场景可通过低剂量扫描、稀疏角度扫描或者有限角度扫描等方式采集数据, 而且, 在一些特殊场景中还不可避免地导致投影数据的稀疏或缺失, 从而导致直接重建的图像中存在严重的噪声或伪影, 无法用于后续的诊断和治疗程序。

此外, 相对于普通 CT, 双能 CT (Dual-Energy CT, DECT) 具有物质分辨的能力, 在临床上有其独特的优势和应用。然而, 当前 DECT 成像严重依赖于专用的硬件设备和成像系统, 比如德国西门子的双源系统、美国通用电气的快速 kV 切换系统和荷兰飞利浦的双层探测器系统, 更新 DECT 设备需要巨大的技术成本, 阻碍了更多患者从 DECT 成像中受益。而且, 随着 DECT 在诊断放射领域获得广泛认可, 使用 DECT 技术来改进介入手术和放射治疗等应用的兴趣日益高涨, 然而现有的相关设备均未集成双能成像功能。

针对上述问题, 本研究借助计算机领域的前沿技术——深度学习, 并结合具体的临床场景, 开发相应的 CT 重建算法, 以实现非理想采样条件下的高质量成像, 为后续诊断和治疗提供精确的影像信息。具体如下:

(1) 临床上, 通常采用降低管电流的方式来实现低剂量扫描, 针对随之而来的投影数据信噪比低的问题, 本研究考虑到 CT 数据在投影空间和图像空间紧密相关的特性, 提出了基于双域生成器网络的低剂量 CT 对抗学习重建算法。实验结果表明, 双域联合处理策略能够超越数据空间的限制, 实现比单一空间处理更优的性能。对抗学习机制能够鼓励生成器的输出在统计分布上和参考图像更加一致的结果, 有效避免模糊效应。采用的 3D 模型也更有助于利用相邻切片之间的关联性来增强算法的细节恢复能力。在不同噪声水平数据上的表明也表明了提出方法能够鲁棒地应对不同强度的噪声。

(2) 在 3D 血管成像等需要在单角度下长时间曝光的场景中, 可以采用稀疏扫描的方式来降低辐射剂量并加快扫描进程, 针对相应的投影数据稀疏的问题, 本研究考虑到投影补全在提高数据一致性方面的潜力, 提出了基于双域网络正则化的稀疏角度 CT 深度迭代重建算法。实验结果表明, 展开的迭代结构能够以渐进改进的方式逐步提高图像的质量, 投影补全、残差感知和图像增强三个模块同时在投影空间、残差空间和图像空间进行约束, 更有潜力实现高质量的稀疏角度 CT 重建。

(3) 西门子采用的快速 kV 切换系统需要复杂的高成本硬件, 且管电流调制困难, 针对这一问题, 本研究考虑到 DECT 不同能量通道数据之间的冗余性, 提出基于互补扫描的慢速 kV 切换扫描方案, 以降低专有硬件的依赖, 且有望更灵活地适配扫描系统, 同时开发了相应的稀疏角度 DECT 双域优化重建算法, 并设计了 DECT 专用的双流

ResUNet 网络, 其共享编码器能够充分提取和利用不同能量通道数据之间的互补信息, 其高低能编码器可有效针对双能数据进行差别学习。在三种不同稀疏配置下提出方法均表现出了比其他方法更有潜力的伪影移除和细节恢复性能, 使用提出方法重建的 DECT 图像生成的 VNC 图像和碘造影剂图像噪声水平更低, 不同组织之间的边界也更加清晰。

(4) 使用 DECT 技术改进介入手术和放射治疗等应用的兴趣日益高涨, 然而相关设备并没有集成双能成像功能, 且通常采用有限角度扫描采集数据, 针对这一问题, 本研究提出基于双 1/4 圆周扫描的 DECT 采集方案, 并开发了相应的基于双域先验增强的有限角度 DECT 深度迭代重建算法。基于双 1/4 圆周扫描的 DECT 采集方案能够在有限角度范围内采集双能数据, 而且不会增加 X 射线辐射剂量和扫描时间。实验结果表明, 引入的双域先验能够进一步将重建图像的平均绝对误差降低 1.93 HU, 结构相似性提高 0.9%, 峰值信噪比提高 2.30 dB, 采用的对抗学习机制可以有效避免生成过度平滑的结果, 使重建的 DECT 图像更加清晰。与其他方法的比较结果表明提出方法在楔形伪影移除、HU 值校正和图像细节恢复等方面更有潜力。

本研究四项工作虽然针对不同的临床问题, 但整体来看, 后两项工作是前两项工作在 DECT 上的应用扩展, 第二、四项工作分别是第一、三项工作在算法层面的改进, 总体目标是通过深度学习技术实现非理想采样条件下的高质量 CT 成像, 为后续诊断和治疗程序提供精确的影像信息。

6.2 未来工作展望

本研究从临床实际出发, 结合具体问题特性并利用深度学习技术设计了相应的重建算法, 有望在临床上改进相关的成像应用。结合本项研究以及医学成像领域发展现状来看, 下面几项工作值得进一步探讨和深入研究, 具体地:

(1) 可泛化成像

在医学成像中, 基于深度学习的现有解决方案通常在固定的成像几何和采样方式下训练, 泛化能力较弱, 在成像模型未知或者和训练设置不一致时, 算法性能骤降^[101]。然而, 在临床实践中, 往往难以获取大量配对的图像用于深度神经网络训练, 且通常根据需求的不同而改变扫描设置, 这需要模型对未知测量过程有良好的泛化能力。最近, 扩散模型 (Diffusion Model) 展现了解决这一问题的潜力^[202-204]。扩散模型不需要配对数据集进行训练, 不受固定测量过程的限制。一旦训练完成, 它可以用来解决同一个图像域中的任何逆问题 (需要满足图像到测量是线性的), 具有良好的泛化性。目前, 相关研究仍处于起步阶段, 进一步基于扩散模型建立成熟的临床适用的成像框架是一个很有潜力的方向。

(2) 可解释成像

深度学习的黑盒般不可解释的属性一直备受关注, 在大多数情况下, 深度学习模型都是从大量的训练数据中学习输入到输出之间的映射关系, 这种做法已经在很多应用中被证明是成功的, 比如降噪^[13]、金属伪影移除^[80]、有限角度 CT 重建^[69], 然而, 研究人员很难解释深层网络为什么或如何提供具体的结果, 这就导致了难以对模型的可靠性进

行评估，尤其是无法预测模型在什么情况下会失效，这在医学成像环境中是不可取的。提高深度学习模型的可解释性对深度成像算法的临床推广和性能改进都具有重要意义。一种可能的替代方案是将易于理解的模块与特定任务的目标（比如，重建、分割、诊断）结合起来，并对每个目标进行相应的惩罚^[33]。本研究第三章和第五章采用的迭代展开策略也是针对可解释性成像的一种尝试。

（3）光子计数 CT 成像

光子计数探测器（Photon-Counting Detector, PCD）是一种新兴技术，相对于传统的能量积分探测器，PCD 具有更高的 X 射线利用效率和更低的电子噪声，且具有能量分辨功能，基于 PCD 的光子计数 CT 相比于传统 CT 具有明显的优势，是一种很有前途的成像技术^[205]。针对光子计数 CT 的临床应用场景开发相应的数据校正、图像重建、材料分解算法是一项十分有价值的工作，比如采用扩散模型等先进技术来改进光子计数 CT 成像。

（4）图像质量评价

本研究中图像质量评价主要采用的是平均绝对误差、结构相似性和峰值信噪比等三个指标，但是第二章和第五章中的实验结果均出现了视觉评估和定量评估不一致的现象，这说明当前使用的图像质量评价指标不能充分评估图像的质量，至少与人类视觉主观评估有出入。医学图像最终由放射科医生视觉阅片，图像视觉效果十分重要。能否有一项指标能够全面客观地评价图像质量且和人类主观感受一致，还需要进一步探索。

参考文献

- [1] Buzug T M. Computed tomography [M]. Cham: Springer, 2011. 311-425.
- [2] Seeram E. Computed tomography-e-book: Physical principles, clinical applications, and quality control [M]. Amsterdam: Elsevier Health Sciences, 2015. 345-415.
- [3] Carmignato S, Dewulf W, Leach R. Industrial x-ray computed tomography [M]. Cham: Springer, 2018. 142-245.
- [4] 孟博, 郑岚, 刘硕. Ct 安检探测技术的特点及优势 [J]. 中国安防, 2021, 4(1): 78-81.
- [5] Withers P J, Bouman C, Carmignato S, et al. X-ray computed tomography [J]. Nature Reviews Methods Primers, 2021, 1(1): 1-23.
- [6] Brenner D J, Hall E J. Computed tomography—an increasing source of radiation exposure [J]. New England Journal of Medicine, 2007, 357(22): 2277-2284.
- [7] Pearce M S, Salotti J A, Little M P, et al. Radiation exposure from ct scans in childhood and subsequent risk of leukaemia and brain tumours: A retrospective cohort study [J]. The Lancet, 2012, 380(9840): 499-505.
- [8] 韩泽芳, 上官宏, 张雄, et al. 基于深度学习的低剂量 ct 成像算法研究进展 [J]. CT 理论与应用研究, 2022, 31(1): 117-134.
- [9] Kudo H, Suzuki T, Rashed E A. Image reconstruction for sparse-view ct and interior ct—introduction to compressed sensing and differentiated backprojection [J]. Quantitative Imaging in Medicine and Surgery, 2013, 3(3): 147-161.
- [10] Shieh C C, Gonzalez Y, Li B, et al. Spare: Sparse-view reconstruction challenge for 4d cone-beam ct from a 1-min scan [J]. Medical Physics, 2019, 46(9): 3799-3811.
- [11] Chen B, Zhang Z, Xia D, et al. Dual-energy ct imaging with limited-angular-range data [J]. Physics in Medicine & Biology, 2021, 66(18): 185020.
- [12] Chen G, Zhao Y, Huang Q, et al. 4d-airnet: A temporally-resolved cbct slice reconstruction method synergizing analytical and iterative method with deep learning [J]. Physics in Medicine & Biology, 2020, 65(17): 175020.
- [13] Shan H, Padole A, Homayounieh F, et al. Competitive performance of a modularized deep neural network compared to commercial algorithms for low-dose ct image reconstruction [J]. Nature Machine Intelligence, 2019, 1(6): 269-276.
- [14] Geyer L L, Schoepf U J, Meinel F G, et al. State of the art: Iterative ct reconstruction techniques [J]. Radiology, 2015, 276(2): 339-357.
- [15] Wang G, Ye J C, De Man B. Deep learning for tomographic image reconstruction [J]. Nature Machine Intelligence, 2020, 2(12): 737-748.
- [16] Zhu B, Liu J Z, Cauley S F, et al. Image reconstruction by domain-transform manifold

- learning [J]. *Nature*, 2018, 555(7697): 487-492.
- [17] Shen L, Zhao W, Xing L. Patient-specific reconstruction of volumetric computed tomography images from a single projection view via deep learning [J]. *Nature Biomedical Engineering*, 2019, 3(11): 880-888.
- [18] Wang G, Ye J C, Mueller K, et al. Image reconstruction is a new frontier of machine learning [J]. *IEEE Transactions on Medical Imaging*, 2018, 37(6): 1289-1296.
- [19] Mccollough C H, Leng S, Yu L, et al. Dual-and multi-energy ct: Principles, technical approaches, and clinical applications [J]. *Radiology*, 2015, 276(3): 637-653.
- [20] 卢光明, 张龙江. 双能量 ct 临床应用指南 [M]. 北京: 人民卫生出版社, 2015. 142-324.
- [21] Albrecht M H, Vogl T J, Martin S S, et al. Review of clinical applications for virtual monoenergetic dual-energy ct [J]. *Radiology*, 2019, 293(2): 260-271.
- [22] Morhard D, Fink C, Graser A, et al. Cervical and cranial computed tomographic angiography with automated bone removal: Dual energy computed tomography versus standard computed tomography [J]. *Investigative Radiology*, 2009, 44(5): 293-297.
- [23] Li K, Li Y, Qi Z, et al. Quantitative lung perfusion blood volume using dual energy ct-based effective atomic number (zeff) imaging [J]. *Medical Physics*, 2021, 48(11): 6658-6672.
- [24] Kordbacheh H, Baliyan V, Uppot R N, et al. Dual-source dual-energy ct in detection and characterization of urinary stones in patients with large body habitus: Observations in a large cohort [J]. *American Journal of Roentgenology*, 2019, 212(4): 796-801.
- [25] Filippucci E, Reginato A M, Thiele R G. Imaging of crystalline arthropathy in 2020 [J]. *Best Practice & Research Clinical Rheumatology*, 2020, 34(6): 101595.
- [26] Van Elmpt W, Landry G, Das M, et al. Dual energy ct in radiotherapy: Current applications and future outlook [J]. *Radiotherapy and Oncology*, 2016, 119(1): 137-144.
- [27] Cassetta R, Lehmann M, Haytmyradov M, et al. Fast-switching dual energy cone beam computed tomography using the on-board imager of a commercial linear accelerator [J]. *Physics in Medicine & Biology*, 2020, 65(1): 015013.
- [28] Schyns L E, Almeida I P, Van Hoof S J, et al. Optimizing dual energy cone beam ct protocols for preclinical imaging and radiation research [J]. *The British Journal of Radiology*, 2017, 90(1069): 20160480.
- [29] Müller K, Datta S, Ahmad M, et al. Interventional dual-energy imaging—feasibility of rapid kv-switching on a c-arm ct system [J]. *Medical Physics*, 2016, 43(10): 5537-5546.

- [30] Ji X, Feng M, Treb K, et al. Development of an integrated c-arm interventional imaging system with a strip photon counting detector and a flat panel detector [J]. IEEE Transactions on Medical Imaging, 2021, 40(12): 3674-3685.
- [31] Ahmad M, Fahrig R, Pung L, et al. Assessment of a photon-counting detector for a dual-energy c-arm angiographic system [J]. Medical Physics, 2017, 44(11): 5938-5948.
- [32] Feldkamp L A, Davis L C, Kress J W. Practical cone-beam algorithm [J]. Josa A, 1984, 1(6): 612-619.
- [33] Wang G, Jacob M, Mou X, et al. Deep tomographic image reconstruction: Yesterday, today, and tomorrow—editorial for the 2nd special issue “machine learning for image reconstruction” [J]. IEEE Transactions on Medical Imaging, 2021, 40(11): 2956-2964.
- [34] Koetzier L R, Mastrodicasa D, Szczykutowicz T P, et al. Deep learning image reconstruction for ct: Technical principles and clinical prospects [J]. Radiology, 2023, 306(3): e221257.
- [35] 刘进, 赵倩隆, 尹相瑞, et al. 基于特征学习的低剂量 ct 成像算法研究进展 [J]. CT 理论与应用研究, 2019, 28(3): 393-406.
- [36] Moen T R, Chen B, Holmes Iii D R, et al. Low-dose ct image and projection dataset [J]. Medical Physics, 2021, 48(2): 902-911.
- [37] Hugo G D, Weiss E, Sleeman W C, et al. A longitudinal four-dimensional computed tomography and cone beam computed tomography dataset for image-guided radiation therapy research in lung cancer [J]. Medical Physics, 2017, 44(2): 762-771.
- [38] Sidky E Y, Pan X. Report on the aapm deep-learning sparse-view ct grand challenge [J]. Medical Physics, 2022, 49(8): 4935-4943.
- [39] Wang G, Zhang Y, Ye X, et al. Machine learning for tomographic imaging [M]. Philadelphia: IOP Publishing, 2019. 245-378.
- [40] Dong G, Zhang C, Deng L, et al. A deep unsupervised learning framework for the 4d cbct artifact correction [J]. Physics in Medicine & Biology, 2022, 67(5): 055012.
- [41] Liao H, Lin W-A, Zhou S K, et al. Adn: Artifact disentanglement network for unsupervised metal artifact reduction [J]. IEEE Transactions on Medical Imaging, 2019, 39(3): 634-643.
- [42] Lee J, Gu J, Ye J C. Unsupervised ct metal artifact learning using attention-guided β -cyclegan [J]. IEEE Transactions on Medical Imaging, 2021, 40(12): 3932-3944.
- [43] Lee K, Jeong W-K. Iscl: Interdependent self-cooperative learning for unpaired image denoising [J]. IEEE Transactions on Medical Imaging, 2021, 40(11): 3238-3248.
- [44] Jing J, Xia W, Hou M, et al. Training low dose ct denoising network without high quality reference data [J]. Physics in Medicine & Biology, 2022, 67(8): 084002.
- [45] Jung C, Lee J, You S, et al. Patch-wise deep metric learning for unsupervised

- low-dose ct denoising [C]. In: Wang L, Dou Q, Fletcher P T, et al. editors. Processings of the 25th Medical Image Computing and Computer Assisted Intervention (MICCAI). Cham: Springer, 2022. 634-643.
- [46] Kwon T, Ye J C. Cycle-free cyclegan using invertible generator for unsupervised low-dose ct denoising [J]. IEEE Transactions on Computational Imaging, 2021, 7: 1354-1368.
- [47] Zainulina E, Chernyavskiy A, Dylov D V. Self-supervised physics-based denoising for computed tomography [J]. arXiv preprint arXiv:221100745, 2022.
- [48] Wu D, Ren H, Li Q. Self-supervised dynamic ct perfusion image denoising with deep neural networks [J]. IEEE Transactions on Radiation and Plasma Medical Sciences, 2020, 5(3): 350-361.
- [49] Zang G, Idoughi R, Li R, et al. Intratomo: Self-supervised learning-based tomography via sinogram synthesis and prediction [C]. In: Processings of the 18th IEEE/CVF International Conference on Computer Vision (ICCV). New York: IEEE, 2021. 1960-1970.
- [50] Niu C, Li M, Fan F, et al. Noise suppression with similarity-based self-supervised deep learning [J]. IEEE Transactions on Medical Imaging, 2022.
- [51] Hendriksen A A, Pelt D M, Batenburg K J. Noise2inverse: Self-supervised deep convolutional denoising for tomography [J]. IEEE Transactions on Computational Imaging, 2020, 6: 1320-1335.
- [52] Zhou L, Wang X, Hou M, et al. Low-dose ct reconstruction by self-supervised learning in the projection domain [J]. arXiv preprint arXiv:220306824, 2022.
- [53] Lee H, Lee J, Kim H, et al. Deep-neural-network-based sinogram synthesis for sparse-view ct image reconstruction [J]. IEEE Transactions on Radiation and Plasma Medical Sciences, 2018, 3(2): 109-119.
- [54] Dong X, Vekhande S, Cao G. Sinogram interpolation for sparse-view micro-ct with deep learning neural network [C]. In: Schmidt T G, Chen G, Bosmans H editors. Processings of the 2019 SPIE Medical Imaging-Physics of Medical Imaging. Bellingham: SPIE, 2019. 692-698.
- [55] Ghani M U, Karl W C. Deep learning-based sinogram completion for low-dose ct [C]. In: Processings of the 13th IEEE Image, Video, and Multidimensional Signal Processing Workshop (IVMSP). New York: IEEE, 2018. 1-5.
- [56] Li Z, Zhang W, Wang L, et al. A sinogram inpainting method based on generative adversarial network for limited-angle computed tomography [C]. In: Matej S, Metzler S D editors. Processings of the 15th International Meeting on Fully Three-Dimensional Image Reconstruction in Radiology and Nuclear Medicine. Bellingham: SPIE, 2019. 345-349.

- [57] Li Z, Cai A, Wang L, et al. Promising generative adversarial network based sinogram inpainting method for ultra-limited-angle computed tomography imaging [J]. *Sensors*, 2019, 19(18): 3941.
- [58] Tan J, Gao Y, Huo Y, et al. Sharpness preserved sinogram synthesis using convolutional neural network for sparse-view ct imaging [C]. In: Angelini E D, Landman B A editors. *Processings of the 2019 SPIE Medical Imaging-Image Processing*. Bellingham: SPIE, 2019. 102-109.
- [59] Ghani M U, Karl W C. Fast enhanced ct metal artifact reduction using data domain deep learning [J]. *IEEE Transactions on Computational Imaging*, 2019, 6: 181-193.
- [60] Wang Y, Zhang W, Cai A, et al. An effective sinogram inpainting for complementary limited-angle dual-energy computed tomography imaging using generative adversarial networks [J]. *Journal of X-Ray Science and Technology*, 2021, 29(1): 37-61.
- [61] Jin K H, Mccann M T, Froustey E, et al. Deep convolutional neural network for inverse problems in imaging [J]. *IEEE Transactions on Image Processing*, 2017, 26(9): 4509-4522.
- [62] Chen H, Zhang Y, Kalra M K, et al. Low-dose ct with a residual encoder-decoder convolutional neural network [J]. *IEEE Transactions on Medical Imaging*, 2017, 36(12): 2524-2535.
- [63] Zhang Z, Liang X, Dong X, et al. A sparse-view ct reconstruction method based on combination of densenet and deconvolution [J]. *IEEE Transactions on Medical Imaging*, 2018, 37(6): 1407-1417.
- [64] Liu J, Zhang Y, Zhao Q, et al. Deep iterative reconstruction estimation (dire): Approximate iterative reconstruction estimation for low dose ct imaging [J]. *Physics in Medicine & Biology*, 2019, 64(13): 135007.
- [65] Yang Q, Yan P, Zhang Y, et al. Low-dose ct image denoising using a generative adversarial network with wasserstein distance and perceptual loss [J]. *IEEE Transactions on Medical Imaging*, 2018, 37(6): 1348-1357.
- [66] Li M, Hsu W, Xie X, et al. Sacnn: Self-attention convolutional neural network for low-dose ct denoising with self-supervised perceptual loss network [J]. *IEEE Transactions on Medical Imaging*, 2020, 39(7): 2289-2301.
- [67] Kang E, Min J, Ye J C. A deep convolutional neural network using directional wavelets for low-dose x-ray ct reconstruction [J]. *Medical physics*, 2017, 44(10): 360-375.
- [68] Kang E, Chang W, Yoo J, et al. Deep convolutional framelet denosing for low-dose ct via wavelet residual network [J]. *IEEE Transactions on Medical Imaging*, 2018, 37(6): 1358-1369.
- [69] Han Y, Ye J C. Framing u-net via deep convolutional framelets: Application to

- sparse-view ct [J]. IEEE Transactions on Medical Imaging, 2018, 37(6): 1418-1429.
- [70] Huang Z, Liu X, Wang R, et al. Learning a deep cnn denoising approach using anatomical prior information implemented with attention mechanism for low-dose ct imaging on clinical patient data from multiple anatomical sites [J]. IEEE Journal of Biomedical and Health Informatics, 2021, 25(9): 3416-3427.
- [71] Xia W, Lu Z, Huang Y, et al. Ct reconstruction with pdf: Parameter-dependent framework for data from multiple geometries and dose levels [J]. IEEE Transactions on Medical Imaging, 2021, 40(11): 3065-3076.
- [72] Zhu L, Han Y, Xi X, et al. Stednet: Swin transformer-based encoder-decoder network for noise reduction in low-dose ct [J]. Medical Physics, 2023.
- [73] Zhang Y, Hu D, Yan Z, et al. Time-net: Transformer-integrated multi-encoder network for limited-angle artifact removal in dual-energy cbct [J]. Medical Image Analysis, 2023, 83: 102650.
- [74] Zhang Y, Hu D, Lyu T, et al. Pie-arnet: Prior image enhanced artifact removal network for limited-angle dect [J]. IEEE Transactions on Instrumentation and Measurement, 2023, 72(2500412): 1-12.
- [75] Wu W, Hu D, Niu C, et al. Deep learning based spectral ct imaging [J]. Neural Networks, 2021, 144: 342-358.
- [76] Yin X, Zhao Q, Liu J, et al. Domain progressive 3d residual convolution network to improve low-dose ct imaging [J]. IEEE Transactions on Medical Imaging, 2019, 38(12): 2903-2913.
- [77] 蔡宁, 王世杰, 陈璐杰, et al. 基于渐进式网络处理的低剂量 micro-ct 成像方法 [J]. CT 理论与应用研究, 2020, 29(4): 1-12.
- [78] Hu D, Liu J, Lv T, et al. Hybrid-domain neural network processing for sparse-view ct reconstruction [J]. IEEE Transactions on Radiation and Plasma Medical Sciences, 2020, 5(1): 88-98.
- [79] Lin W-A, Liao H, Peng C, et al. Dudonet: Dual domain network for ct metal artifact reduction [C]. In: Processings of the 2019 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). New York: IEEE, 2019. 10512-10521.
- [80] Zhou B, Chen X, Xie H, et al. Dudoufnet: Dual-domain under-to-fully-complete progressive restoration network for simultaneous metal artifact reduction and low-dose ct reconstruction [J]. IEEE Transactions on Medical Imaging, 2022, 41(12): 3587-3599.
- [81] Chao L, Wang Z, Zhang H, et al. Sparse-view cone beam ct reconstruction using dual cnns in projection domain and image domain [J]. Neurocomputing, 2022, 493: 536-547.
- [82] Pan J, Wu W, Gao Z, et al. Mist-net: Multi-domain integrative swin transformer

- network for sparse-view ct reconstruction [J]. arXiv preprint arXiv:2111.14831, 2021.
- [83] Yang L, Li Z, Ge R, et al. Low-dose ct denoising via sinogram inner-structure transformer [J]. IEEE Transactions on Medical Imaging, 2022.
- [84] Zhang R, Zhou J, Yu Z. A cascaded deep-learning reconstruction method for sparse-view kv-switching dual-energy ct [C]. In: Chen G, Bosmans H editors. Processings of the 2020 SPIE Medical Imaging-Physics of Medical Imaging. Bellingham: SPIE, 2020. 499-505.
- [85] Szczykutowicz T P, Chen G-H. Dual energy ct using slow kvp switching acquisition and prior image constrained compressed sensing [J]. Physics in Medicine & Biology, 2010, 55(21): 6411.
- [86] Wang Y, Cai A, Liang N, et al. One half-scan dual-energy ct imaging using the dual-domain dual-way estimated network (doda-net) model [J]. Quantitative Imaging in Medicine and Surgery, 2022, 12(1): 653-674.
- [87] Würfl T, Hoffmann M, Christlein V, et al. Deep learning computed tomography: Learning projection-domain weights from image domain in limited angle problems [J]. IEEE Transactions on Medical Imaging, 2018, 37(6): 1454-1463.
- [88] Li Y, Li K, Zhang C, et al. Learning to reconstruct computed tomography images directly from sinogram data under a variety of data acquisition conditions [J]. IEEE Transactions on Medical Imaging, 2019, 38(10): 2469-2481.
- [89] He J, Wang Y, Ma J. Radon inversion via deep learning [J]. IEEE Transactions on Medical Imaging, 2020, 39(6): 2076-2087.
- [90] Fu L, De Man B. A hierarchical approach to deep learning and its application to tomographic reconstruction [C]. In: Matej S, Metzler S D editors. Processings of the 15th International Meeting on Fully Three-Dimensional Image Reconstruction in Radiology and Nuclear Medicine. Bellingham: SPIE, 2019. 1-11.
- [91] Xie H, Shan H, Cong W, et al. Dual network architecture for few-view ct-trained on imagenet data and transferred for medical imaging [C]. In: Müller B, Wang G editors. Processings of the 12th SPIE Conference on Developments in X-Ray Tomography XII. Bellingham: SPIE, 2019. 184-194.
- [92] Ying X, Guo H, Ma K, et al. X2ct-gan: Reconstructing ct from biplanar x-rays with generative adversarial networks [C]. In: Processings of the 2019 IEEE/CVF conference on computer vision and pattern recognition (CVPR). New York: IEEE, 2019. 10619-10628.
- [93] Tan Z, Li J, Tao H, et al. Xctnet: Reconstruction network of volumetric images from a single x-ray image [J]. Computerized Medical Imaging and Graphics, 2022, 98: 102067.
- [94] Ge R, He Y, Xia C, et al. X-ctrsnet: 3d cervical vertebra ct reconstruction and

- segmentation directly from 2d x-ray images [J]. Knowledge-Based Systems, 2022, 236: 107680.
- [95] Lei Y, Tian Z, Wang T, et al. Deep learning-based real-time volumetric imaging for lung stereotactic body radiation therapy: A proof of concept study [J]. Physics in Medicine & Biology, 2020, 65(23): 235003.
- [96] Henzler P, Rasche V, Ropinski T, et al. Single-image tomography: 3d volumes from 2d cranial x-rays [C]. In: Processings of the Computer Graphics Forum: Wiley Online Library, 2018. 377-388.
- [97] Kasten Y, Doktofsky D, Kovler I. End-to-end convolutional neural network for 3d reconstruction of knee bones from bi-planar x-ray images [C]. In: Deeba F, Johnson P, Würfl T, et al. editors. Processings of the 3rd Machine Learning for Medical Image Reconstruction (MLMIR). Cham: Springer, 2020. 123-133.
- [98] Li X, Wang S, Chen P, et al. 3-d inspection method for industrial product assembly based on single x-ray projections [J]. IEEE Transactions on Instrumentation and Measurement, 2021, 70: 1-14.
- [99] Sun X, Li X, Chen P. An ultra-sparse view ct imaging method based on x-ray2ctnet [J]. IEEE Transactions on Computational Imaging, 2022, 8: 733-742.
- [100] Montoya J C, Zhang C, Li Y, et al. Reconstruction of three-dimensional tomographic patient models for radiation dose modulation in ct from two scout views using deep learning [J]. Medical Physics, 2022, 49(2): 901-916.
- [101] Antun V, Renna F, Poon C, et al. On instabilities of deep learning in image reconstruction and the potential costs of ai [J]. Proceedings of the National Academy of Sciences, 2020, 117(48): 30088-30095.
- [102] Gottschling N M, Antun V, Adcock B, et al. The troublesome kernel: Why deep learning for inverse problems is typically unstable [J]. arXiv preprint arXiv:200101258, 2020.
- [103] Zhang J, Ghanem B. Ista-net: Interpretable optimization-inspired deep network for image compressive sensing [C]. In: Processings of the 2018 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). New York: IEEE, 2018. 1828-1837.
- [104] Xiang J, Dong Y, Yang Y. Fista-net: Learning a fast iterative shrinkage thresholding network for inverse problems in imaging [J]. IEEE Transactions on Medical Imaging, 2021, 40(5): 1329-1339.
- [105] Adler J, Öktem O. Learned primal-dual reconstruction [J]. IEEE Transactions on Medical Imaging, 2018, 37(6): 1322-1332.
- [106] He J, Yang Y, Wang Y, et al. Optimizing a parameterized plug-and-play admm for iterative low-dose ct reconstruction [J]. IEEE Transactions on Medical Imaging, 2018,

- 38(2): 371-382.
- [107] Su T, Cui Z, Yang J, et al. Generalized deep iterative reconstruction for sparse-view ct imaging [J]. *Physics in Medicine & Biology*, 2022, 67(2): 025005.
- [108] Chen H, Zhang Y, Chen Y, et al. Learn: Learned experts' assessment-based reconstruction network for sparse-data ct [J]. *IEEE Transactions on Medical Imaging*, 2018, 37(6): 1333-1347.
- [109] Xia W, Lu Z, Huang Y, et al. Magic: Manifold and graph integrative convolutional network for low-dose ct reconstruction [J]. *IEEE Transactions on Medical Imaging*, 2021, 40(12): 3459-3472.
- [110] Zhang Y, Chen H, Xia W, et al. Learn++: Recurrent dual-domain reconstruction network for compressed sensing ct [J]. *IEEE Transactions on Radiation and Plasma Medical Sciences*, 2023, 7(2): 132-142.
- [111] Wu D, Kim K, Kalra M K, et al. Learned primal-dual reconstruction for dual energy computed tomography with reduced dose [C]. In: Matej S, Metzler S D editors. *Processings of the 15th International Meeting on Fully Three-Dimensional Image Reconstruction in Radiology and Nuclear Medicine*. Bellingham: SPIE, 2019. 21-25.
- [112] Chen X, Xia W, Yang Z, et al. Soul-net: A sparse and low-rank unrolling network for spectral ct image reconstruction [J]. *arXiv preprint arXiv:220712639*, 2022.
- [113] Li Z, Long Y, Chun I Y. An improved iterative neural network for high-quality image-domain material decomposition in dual-energy ct [J]. *Medical Physics*, 2022.
- [114] Wang L, Wang Y, Bian Z, et al. Self-supervised nonlocal spectral similarity induced material decomposition network for dual-energy ct [C]. In: Stayman J W editors. *Processings of the 7th International Conference on Image Formation in X-Ray Computed Tomography*. Bellingham: SPIE, 2022. 192-197.
- [115] Roth S, Black M J. Fields of experts [J]. *International Journal of Computer Vision*, 2009, 82: 205-229.
- [116] Zhang H, Liu B, Yu H, et al. Metainv-net: Meta inversion network for sparse view ct image reconstruction [J]. *IEEE Transactions on Medical Imaging*, 2020, 40(2): 621-634.
- [117] Chen B, Xiang K, Gong Z, et al. Statistical iterative cbct reconstruction based on neural network [J]. *IEEE Transactions on Medical Imaging*, 2018, 37(6): 1511-1521.
- [118] Ma G, Shen C, Jia X. Low dose ct reconstruction assisted by an image manifold prior [J]. *arXiv preprint arXiv:181012255*, 2018.
- [119] Wu D, Kim K, El Fakhri G, et al. Iterative low-dose ct reconstruction with priors trained by artificial neural network [J]. *IEEE Transactions on Medical Imaging*, 2017, 36(12): 2479-2486.
- [120] Wang Y, Liao Y, Zhang Y, et al. Iterative quality enhancement via residual-artifact

- learning networks for low-dose ct [J]. *Physics in Medicine & Biology*, 2018, 63(21): 215004.
- [121] Wu W, Hu D, Cong W, et al. Stabilizing deep tomographic reconstruction: Part a. Hybrid framework and experimental results [J]. *Patterns*, 2022, 3(5): 100474.
- [122] Wu W, Hu D, Cong W, et al. Stabilizing deep tomographic reconstruction: Part b. Convergence analysis and adversarial attacks [J]. *Patterns*, 2022, 3(5): 100475.
- [123] Hu D, Zhang Y, Liu J, et al. Dior: Deep iterative optimization-based residual-learning for limited-angle ct reconstruction [J]. *IEEE Transactions on Medical Imaging*, 2022, 41(7): 1778-1790.
- [124] Hu D, Zhang Y, Liu J, et al. Prior: Prior-regularized iterative optimization reconstruction for 4d cbct [J]. *IEEE Journal of Biomedical and Health Informatics*, 2022, 26(11): 5551-5562.
- [125] Li D, Bian Z, Li S, et al. Noise characteristics modeled unsupervised network for robust ct image reconstruction [J]. *IEEE Transactions on Medical Imaging*, 2022, 41(12): 3849-3861.
- [126] Petrongolo M, Zhu L. Single-scan dual-energy ct using primary modulation [J]. *IEEE Transactions on Medical Imaging*, 2018, 37(8): 1799-1808.
- [127] Lee D, Lee J, Kim H, et al. A feasibility study of low-dose single-scan dual-energy cone-beam ct in many-view under-sampling framework [J]. *IEEE Transactions on Medical Imaging*, 2017, 36(12): 2578-2587.
- [128] Jiang X, Fang C, Hu P, et al. Fast and effective single-scan dual-energy cone-beam ct reconstruction and decomposition denoising based on dual-energy vectorization [J]. *Medical Physics*, 2021, 48(9): 4843-4856.
- [129] Chen B, Zhang Z, Xia D, et al. Dual-energy ct imaging over non-overlapping, orthogonal arcs of limited-angular ranges [J]. *Journal of X-ray Science and Technology*, 2021, 29(6): 975-985.
- [130] Lyu T, Zhao W, Zhu Y, et al. Estimating dual-energy ct imaging from single-energy ct data with material decomposition convolutional neural network [J]. *Medical Image Analysis*, 2021, 70: 102001.
- [131] Liu C-K, Liu C-C, Yang C-H, et al. Generation of brain dual-energy ct from single-energy ct using deep learning [J]. *Journal of Digital Imaging*, 2021, 34(1): 149-161.
- [132] Zhao W, Lv T, Lee R, et al. Obtaining dual-energy computed tomography (ct) information from a single-energy ct image for quantitative imaging analysis of living subjects by using deep learning [C]. In: *Processings of the 2020 Pacific Symposium on Biocomputing (PSB)*: World Scientific, 2019. 139-148.
- [133] Wang Y, Feng Z, Yu X, et al. Image-domain material decomposition for single-energy

- ct images using cascaded network [C]. In: Processings of the 2nd International Conference on Artificial Intelligence and Electromechanical Automation (AIEA). New York: IEEE, 2021. 273-276.
- [134] Wang G, Liu Z, Huang Z, et al. Improved gan: Using a transformer module generator approach for material decomposition [J]. Computers in Biology and Medicine, 2022, 149: 105952.
- [135] Cong W, De Man B, Wang G. X-ray monochromatic imaging from single-spectrum ct via machine learning [J]. arXiv preprint arXiv:200605841, 2020.
- [136] Liu J, Ma J, Zhang Y, et al. Discriminative feature representation to improve projection data inconsistency for low dose ct imaging [J]. IEEE Transactions on Medical Imaging, 2017, 36(12): 2499-2509.
- [137] Wang J, Li T, Lu H, et al. Penalized weighted least-squares approach to sinogram noise reduction and image reconstruction for low-dose x-ray computed tomography [J]. IEEE Transactions on Medical Imaging, 2006, 25(10): 1272-1283.
- [138] Beister M, Kolditz D, Kalender W A. Iterative reconstruction methods in x-ray ct [J]. Physica Medica, 2012, 28(2): 94-108.
- [139] Liu J, Hu Y, Yang J, et al. 3d feature constrained reconstruction for low-dose ct imaging [J]. IEEE Transactions on Circuits and Systems for Video Technology, 2016, 28(5): 1232-1247.
- [140] Chen Y, Shi L, Feng Q, et al. Artifact suppressed dictionary learning for low-dose ct image processing [J]. IEEE Transactions on Medical Imaging, 2014, 33(12): 2271-2292.
- [141] Ma J, Huang J, Feng Q, et al. Low-dose computed tomography image restoration using previous normal-dose scan [J]. Medical Physics, 2011, 38(10): 5713-5731.
- [142] Lee H, Lee J, Cho S. View-interpolation of sparsely sampled sinogram using convolutional neural network [C]. In: Styner M A, Angelini E D editors. Processings of the 2017 SPIE Medical Imaging-Image Processing. Bellingham: SPIE, 2017. 617-624.
- [143] Shan H, Zhang Y, Yang Q, et al. 3-d convolutional encoder-decoder network for low-dose ct via transfer learning from a 2-d trained network [J]. IEEE Transactions on Medical Imaging, 2018, 37(6): 1522-1534.
- [144] Ge Y, Su T, Zhu J, et al. Adaptive-net: Deep computed tomography reconstruction network with analytical domain transformation knowledge [J]. Quantitative Imaging in Medicine and Surgery, 2020, 10(2): 415.
- [145] Zhang Q, Hu Z, Jiang C, et al. Artifact removal using a hybrid-domain convolutional neural network for limited-angle computed tomography imaging [J]. Physics in Medicine & Biology, 2020, 65(15): 155010.

- [146] Zheng A, Gao H, Zhang L, et al. A dual-domain deep learning-based reconstruction method for fully 3d sparse data helical ct [J]. *Physics in Medicine & Biology*, 2020, 65(24): 245030.
- [147] Wolterink J M, Leiner T, Viergever M A, et al. Generative adversarial networks for noise reduction in low-dose ct [J]. *IEEE Transactions on Medical Imaging*, 2017, 36(12): 2536-2545.
- [148] Mathieu M, Couprie C, Lecun Y. Deep multi-scale video prediction beyond mean square error [J]. *arXiv preprint arXiv:151105440*, 2015.
- [149] Huang Z, Chen Z, Zhang Q, et al. Cagan: A cycle-consistent generative adversarial network with attention for low-dose ct imaging [J]. *IEEE Transactions on Computational Imaging*, 2020, 6: 1203-1218.
- [150] Pathak D, Krahenbuhl P, Donahue J, et al. Context encoders: Feature learning by inpainting [C]. In: *Processings of the 2016 IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*. New York: IEEE, 2016. 2536-2544.
- [151] Isola P, Zhu J-Y, Zhou T, et al. Image-to-image translation with conditional adversarial networks [C]. In: *Processings of the 30th IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*. New York: IEEE, 2017. 1125-1134.
- [152] Ledig C, Theis L, Huszár F, et al. Photo-realistic single image super-resolution using a generative adversarial network [C]. In: *Processings of the 30th IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*. New York: IEEE, 2017. 4681-4690.
- [153] Yi X, Walia E, Babyn P. Generative adversarial network in medical imaging: A review [J]. *Medical Image Analysis*, 2019, 58: 101552.
- [154] Elbakri I A, Fessler J A. Statistical image reconstruction for polyenergetic x-ray computed tomography [J]. *IEEE Transactions on Medical Imaging*, 2002, 21(2): 89-99.
- [155] Zhao H, Gallo O, Frosio I, et al. Loss functions for image restoration with neural networks [J]. *IEEE Transactions on Circuits and Systems for Video Technology*, 2016, 3(1): 47-57.
- [156] Johnson J, Alahi A, Fei-Fei L. Perceptual losses for real-time style transfer and super-resolution [C]. In: *Processings of the European Conference on Computer Vision*: Springer, 2016. 694-711.
- [157] Zhou Z, Siddiquee M M R, Tajbakhsh N, et al. Unet++: Redesigning skip connections to exploit multiscale features in image segmentation [J]. *IEEE Transactions on Medical Imaging*, 2019, 39(6): 1856-1867.
- [158] Beck A, Teboulle M. A fast iterative shrinkage-thresholding algorithm for linear

- inverse problems [J]. SIAM Journal on Imaging Sciences, 2009, 2(1): 183-202.
- [159] Gulrajani I, Ahmed F, Arjovsky M, et al. Improved training of wasserstein gans [C]. In: I G, Luxburg U V, Bengio S, et al. editors. Processings of the 31st Annual Conference on Neural Information Processing Systems (NIPS). California: NIPS, 2017. 5769-5779.
- [160] He K, Zhang X, Ren S, et al. Deep residual learning for image recognition [C]. In: Processings of the 2016 IEEE Conference on Computer Vision and Pattern Recognition (CVPR). New York: IEEE, 2016. 770-778.
- [161] Maas A L, Hannun A Y, Ng A Y. Rectifier nonlinearities improve neural network acoustic models [C]. In: Dasgupta S, Mcallester D editors. Processings of the 30th International Conference on Machine Learning (ICML). San Diego: JMLR, 2013. 1-6.
- [162] Ronchetti M. Torchradon: Fast differentiable routines for computed tomography [J]. arXiv preprint arXiv:200914788, 2020.
- [163] Ioffe S, Szegedy C. Batch normalization: Accelerating deep network training by reducing internal covariate shift [C]. In: Bach F, Blei D editors. Processings of the 32nd International Conference on Machine Learning (ICML). San Diego: JMLR, 2015. 448-456.
- [164] Lin M, Chen Q, Yan S. Network in network [C]. In: Bengio Y, Lecun Y editors. Processings of the 2nd International Conference on Learning Representations (ICLR). San Diego: JMLR, 2014.
- [165] Sidky E Y, Pan X. Image reconstruction in circular cone-beam computed tomography by constrained, total-variation minimization [J]. Physics in Medicine & Biology, 2008, 53(17): 4777.
- [166] Li Y, Speidel M A, François C J, et al. Radiation dose reduction in ct myocardial perfusion imaging using smart-recon [J]. IEEE Transactions on Medical Imaging, 2017, 36(12): 2557-2568.
- [167] Yu S, Dong H, Yang G, et al. Dagan: Deep de-aliasing generative adversarial networks for fast compressed sensing mri reconstruction [J]. IEEE Transactions on Medical Imaging, 2018, 37(6): 1310-1321.
- [168] Dietrich L, Jetter S, Tücking T, et al. Linac-integrated 4d cone beam ct: First experimental results [J]. Physics in Medicine & Biology, 2006, 51(11): 2939.
- [169] Panayides A S, Amini A, Filipovic N D, et al. Ai in medical imaging informatics: Current challenges and future directions [J]. IEEE Journal of Biomedical and Health Informatics, 2020, 24(7): 1837-1857.
- [170] Cheng J, Wang H, Zhu Y, et al. Model-based deep medical imaging: The roadmap of generalizing iterative reconstruction model using deep learning [J]. arXiv preprint arXiv:190608143, 2019.

- [171] Sun J, Li H, Xu Z. Deep admm-net for compressive sensing mri [C]. In: Lee D D, Sugiyama M, Luxburg U V, et al. editors. Processings of the 30th Conference on Neural Information Processing Systems (NIPS). California: NIPS, 2016. 10-18.
- [172] Aggarwal H K, Mani M P, Jacob M. Modl: Model-based deep learning architecture for inverse problems [J]. IEEE Transactions on Medical Imaging, 2018, 38(2): 394-405.
- [173] Yang Y, Sun J, Li H, et al. Admm-csnet: A deep learning approach for image compressive sensing [J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2018, 42(3): 521-538.
- [174] Lim H, Chun I Y, Dewaraja Y K, et al. Improved low-count quantitative pet reconstruction with an iterative neural network [J]. IEEE Transactions on Medical Imaging, 2020, 39(11): 3512-3522.
- [175] Gong K, Wu D, Kim K, et al. Emnet: An unrolled deep neural network for pet image reconstruction [C]. In: Schmidt T G, Chen G H, Bosmans H editors. Processings of the 2019 SPIE Medical Imaging-Physics of Medical Imaging. Bellingham: SPIE, 2019. 1203-1208.
- [176] Corda-D'incan G, Schnabel J A, Reader A J. Memory-efficient training for fully unrolled deep learned pet image reconstruction with iteration-dependent targets [J]. IEEE Transactions on Radiation and Plasma Medical Sciences, 2021, 6(5): 552-563.
- [177] Bioucas-Dias J M, Figueiredo M A. A new twist: Two-step iterative shrinkage/thresholding algorithms for image restoration [J]. IEEE Transactions on Image Processing, 2007, 16(12): 2992-3004.
- [178] Boyd S, Parikh N, Chu E, et al. Distributed optimization and statistical learning via the alternating direction method of multipliers [J]. Foundations and Trends® in Machine learning, 2011, 3(1): 1-122.
- [179] Chambolle A, Pock T. A first-order primal-dual algorithm for convex problems with applications to imaging [J]. Journal of Mathematical Imaging and Vision, 2011, 40(1): 120-145.
- [180] Huang Y, Preuhs A, Lauritsch G, et al. Data consistent artifact reduction for limited angle tomography with deep learning prior [C]. In: Knoll F, Maier A, Rueckert D, et al. editors. Processings of the 2nd International Workshop on Machine Learning for Medical Image Reconstruction (MLMIR). Cham: Springer, 2019. 101-112.
- [181] Wu W, Hu D, Niu C, et al. Drone: Dual-domain residual-based optimization network for sparse-view ct reconstruction [J]. IEEE Transactions on Medical Imaging, 2021, 40(11): 3002-3014.
- [182] Zhang Y, Hu D, Zhao Q, et al. Clear: Comprehensive learning enabled adversarial reconstruction for subtle structure enhanced low-dose ct imaging [J]. IEEE

- Transactions on Medical Imaging, 2021, 40(11): 3089-3101.
- [183] Ronneberger O, Fischer P, Brox T. U-net: Convolutional networks for biomedical image segmentation [C]. In: Navab N, Hornegger J, Wells W, et al. editors. Processings of the 18th International Conference on Medical Image Computing and Computer-Assisted Intervention (MICCAI). Cham: Springer, 2015. 234-241.
- [184] Zhang K, Zuo W, Chen Y, et al. Beyond a gaussian denoiser: Residual learning of deep cnn for image denoising [J]. IEEE Transactions on Image Processing, 2017, 26(7): 3142-3155.
- [185] 雷阳, 连茂森, 罗守华. 基于改进 asd-nc-pocs 方法的显微 ct 双能成像研究 [J]. 中国医疗设备, 2019, 34(12): 1-7.
- [186] 雷阳. 基于双能方法的显微 ct 成像研究 [D]: 硕士学位论文. 南京: 东南大学生物科学与医学工程学院, 2019.
- [187] Zhang H, Cisse M, Dauphin Y N, et al. Mixup: Beyond empirical risk minimization [C]. In: Processings of the 6th International Conference on Learning Representations (ICLR), 2018. 1-13.
- [188] Su T, Deng X, Yang J, et al. Dir-dbtnet: Deep iterative reconstruction network for three-dimensional digital breast tomosynthesis imaging [J]. Medical Physics, 2021, 48(5): 2289-2300.
- [189] Chen G H, Tang J, Leng S. Prior image constrained compressed sensing (piccs): A method to accurately reconstruct dynamic ct images from highly undersampled projection data sets [J]. Medical Physics, 2008, 35(2): 660-663.
- [190] 赵倩隆. 基于卷积神经网络的滤波自适应低剂量 ct 成像 [D]: 硕士学位论文. 南京: 东南大学计算机科学与工程学院, 2020.
- [191] Liu Y, Anwar S, Zheng L, et al. Gradnet image denoising [C]. In: Processings of the 2020 IEEE/CVF Conference on Computer Vision and Pattern Recognition Workshops (CVPRW). Los Alamitos: IEEE Computer Society, 2020. 508-509.
- [192] Wu W, Hu D, An K, et al. A high-quality photon-counting ct technique based on weight adaptive total-variation and image-spectral tensor factorization for small animals imaging [J]. IEEE Transactions on Instrumentation and Measurement, 2020, 70(2502114): 1-14.
- [193] Faby S, Kuchenbecker S, Sawall S, et al. Performance of today's dual energy ct and future multi energy ct in virtual non-contrast imaging and in iodine quantification: A simulation study [J]. Medical Physics, 2015, 42(7): 4349-4366.
- [194] Wu D, Kim K, Dong B, et al. End-to-end lung nodule detection in computed tomography [C]. In: Shi Y, Suk H I, Liu M editors. Processings of the 9th International Workshop on Machine Learning in Medical Imaging (MLMI). Cham: Springer, 2018. 37-45.

- [195] Wang C, Zhang H, Li Q, et al. Improving generalizability in limited-angle ct reconstruction with sinogram extrapolation [C]. In: Bruijne M, Cattin P, Cotin S, et al. editors. Processings of the 24th International Conference on Medical Image Computing and Computer Assisted Intervention (MICCAI). Cham: Springer, 2021. 86-96.
- [196] Huang G, Liu Z, Van Der Maaten L, et al. Densely connected convolutional networks [C]. In: Processings of the 30th IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). New York: IEEE, 2017. 4700-4708.
- [197] Chen G, Hong X, Ding Q, et al. Airnet: Fused analytical and iterative reconstruction with deep neural network regularization for sparse-data ct [J]. Medical Physics, 2020, 47(7): 2916-2930.
- [198] Arjovsky M, Chintala S, Bottou L. Wasserstein generative adversarial networks [C]. In: Precup D, Teh Y W editors. Processings of the 34th International Conference on Machine Learning (ICML). San Diego: JMLR, 2017. 214-223.
- [199] Gui J, Sun Z, Wen Y, et al. A review on generative adversarial networks: Algorithms, theory, and applications [J]. IEEE Transactions on Knowledge and Data Engineering, 2021, 35(4): 3313-3332.
- [200] Jia Y, Mcmichael N, Mokarzel P, et al. Superiorization-inspired unrolled sart algorithm with u-net generated perturbations for sparse-view and limited-angle ct reconstruction [J]. Physics in Medicine & Biology, 2022, 67(24): 245004.
- [201] Zhang Y, Lv T, Ge R, et al. Cd-net: Comprehensive domain network with spectral complementary for dect sparse-view reconstruction [J]. IEEE Transactions on Computational Imaging, 2021, 7: 436-447.
- [202] Liu J, Anirudh R, Thiagarajan J J, et al. Dolce: A model-based probabilistic diffusion framework for limited-angle ct reconstruction [J]. arXiv preprint arXiv:221112340, 2022.
- [203] Chung H, Ryu D, Mccann M T, et al. Solving 3d inverse problems using pre-trained 2d diffusion models [J]. arXiv preprint arXiv:221110655, 2022.
- [204] Song Y, Shen L, Xing L, et al. Solving inverse problems in medical imaging with score-based generative models [J]. arXiv preprint arXiv:211108005, 2021.
- [205] Willemink M J, Persson M, Pourmorteza A, et al. Photon-counting ct: Technical principles and clinical prospects [J]. Radiology, 2018, 289(2): 293-312.

毕业/学位论文答辩委员会名单

毕业/学位论文题目		基于深度学习的双域 CT 重建方法研究 Deep Learning Based Dual-Domain CT Reconstruction		
作 者		张谊坤		
专 业		计算机科学与技术		
研究方向		深度学习、医学图像重建		
导 师		陈阳教授		
答辩委员会组成	姓 名	职 称	学科专业	工作单位
	罗守华 (主席)	教授	生物医学工程	东南大学
	陈强	教授	模式识别与智能系统	南京理工大学
	白琮	教授	计算机科学与技术	浙江工业大学
	张敬林	教授	计算机科学与技术	山东大学
	唐晓颖	副研究员	计算机科学与技术	南方科技大学
	薛澄 (秘书)	副研究员	计算机科学与技术	东南大学

心於至善

